

ບົດໂຄງການຈົບຊັ້ນລະດັບປະລິນຍາຕີວິທະຍາສາດ
ສາຂາ ວິທະຍາສາດຄອມພິວເຕີ

ການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍໃຊ້ deep learning
Audio Classification of Lao Instruments Using Deep Learning
Techniques

ນັກສຶກສາ:

ທ້າວ ເອກທະວີພິນ ທອງເພັດ

ທ້າວ ສິດທິພອນ ພຸດຕະວົງ

ນຳພາໂດຍ:

ຮສ.ປອ.ນາງ ລັດສະໝີ ຈິດຕະວົງ

ຊ່ວຍນຳພາໂດຍ:

ອຈ.ປອ. ສິມສັກ ອິນທະສອນ

ຄະນະວິທະຍາສາດທຳມະຊາດ
ພາກວິຊາ ວິທະຍາສາດຄອມພິວເຕີ
ສົກສຶກສາ 2024-2025

**Final Project of Bachelor Degree of Science in
Computer Science**

**ການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍໃຊ້ deep learning
Audio Classification of Lao Instruments Using Deep Learning
Techniques**

Students:

**Mr. Ekthaviphonh THONGPHET
Mr. Sitthiphone PHOUTTAVONG**

Advisor:

Assoc.Prof.Dr.Ms Lathsamy CHIDTAVONG

Co-Advisor:

Ph.D. Somsack INTHASONE

**Faculty of Natural Science
Department of Computer Sciences
Academic Year 2024-2025**

ຄຳນຳ

ເຕັກໂນໂລຊີກາຍເປັນສິ່ງໜຶ່ງຜືນຖານອັນສຳຄັນອັນໜຶ່ງຕໍ່ກັບການດຳລົງຊີວິດຂອງຄົນເຮົາ. ເຕັກໂນໂລຊີໄດ້ມີການຂະຫຍາຍຕົວຢ່າງກວ້າງຂວາງ ແລະ ມີການພັດທະນາຢ່າງບໍ່ຢຸດຢັ້ງ, ບໍ່ວ່າຈະຢູ່ຂົງເຂດວຽກງານໃດກໍໄດ້ມີການນຳເອົາເຕັກໂນໂລຊີເຂົ້າມາເປັນສ່ວນໜຶ່ງເພື່ອຊ່ວຍໃຫ້ ການຮັບສິ່ງຂໍ້ມູນຂ່າວສານທີ່ຢູ່ຫ່າງໄກກັນໄດ້ຢ່າງວ່ອງໄວ, ສະດວກສະບາຍ ແລະ ມີປະສິດທິພາບໂດຍສະເພາະແມ່ນປັນຍາປະດິດທີ່ມີການເວົ້າເຖິງ ແລະ ເປັນທີ່ຍອມຮັບທີ່ຖືກນຳໃຊ້ຢ່າງແຜ່ຫຼາຍເພາະມັນໄດ້ເຂົ້າມາຊ່ວຍເຮັດໃຫ້ຫຼາຍໆຢ່າງມີຄວາມສະດວກຂຶ້ນເຊັ່ນ: ການຄົ້ນຫາຂໍ້ມູນ, ການແນະນຳ ແລະ ຈົນໄປຮອດເປັນຕົວຊ່ວຍໃນການເຜີຍແຜ່ວັດທະນະທຳ ແລະ ຄວາມຮູ້ອີກດ້ວຍ.

ໃນການຂຽນໂຄງການຈົບຊັ້ນຂອງພວກຂ້າພະເຈົ້າໃນຄັ້ງນີ້ແມ່ນຂຽນກ່ຽວກັບການນຳໃຊ້ປັນຍາປະດິດຂັ້ນສູງ ໂດຍມີຫົວຂໍ້ວ່າ “ການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍນຳໃຊ້ເຕັກນິກຂອງປັນຍາປະດິດຂັ້ນສູງ” ຈຸດປະສົງໃນການຂຽນບົດແມ່ນສຶກສາ, ຮຽນຮູ້ວິທີການນຳເອົາສຽງມາຈຳແນກ ປະກອບກັບການນຳໃຊ້ປັນຍາປະດິດຂັ້ນສູງເພື່ອພັດທະນາແບບຈຳລອງຕົວຈຳແນກສຽງຂອງເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດຄື: ແຄນ, ຄ້ອງວົງ, ລະນາດ, ຊໍອູ້, ຊິງ ແລະ ຝົນ ໃຫ້ໄດ້ຮັບຜົນທີ່ມີປະສິດທິພາບທີ່ສຸດພ້ອມກັບໃຫ້ຂໍ້ມູນປະຫວັດກ່ຽວກັບເຄື່ອງດົນຕີລາວແຕ່ລະປະເພດເພື່ອເປັນການສົ່ງເສີມ ແລະ ອະນຸລັກວັດທະນະທຳຂອງຊາດລາວເຮົາ.

ສະນັ້ນ, ພວກຂ້າພະເຈົ້າຈຶ່ງມີຄວາມພາກພູມໃຈເປັນຢ່າງຍິ່ງທີ່ໄດ້ຂຽນບົດໂຄງການຈົບຊັ້ນສະບັບນີ້ຂຶ້ນມາຈົນສຳເລັດ ແລະ ປາສະຈາກບໍ່ໄດ້ໃນຂໍ້ຂາດຕົກບົກຜ່ອງທາງດ້ານເນື້ອໃນບາງປະການທີ່ອະທິບາຍໄດ້ບໍ່ຊັດເຈນ ພວກຂ້າພະເຈົ້າກໍຍິນດີທີ່ຈະຮັບຄຳຕິຊົມ ແລະ ຄວາມຄິດເຫັນຈາກບັນດາທ່ານຜູ້ອ່ານ ແລະ ຜູ້ສົນໃຈທຸກທ່ານ ເພື່ອຈະໄດ້ເປັນບົດຮຽນໃຫ້ພວກຂ້າພະເຈົ້າໃນການພັດທະນາປັບປຸງໃນຄັ້ງຕໍ່ໄປໃຫ້ສົມບູນຍິ່ງຂຶ້ນ ຫວັງຢ່າງຍິ່ງວ່າບົດໂຄງການຈົບຊັ້ນສະບັບນີ້ຈະເປັນປະໂຫຍດໃຫ້ແກ່ຜູ້ທີ່ມີຄວາມສົນໃຈໃນເລື່ອງຂອງການປະມວນຜົນສຽງ ແລະ ເຕັກໂນໂລຊີປັນຍາປະດິດ ທີ່ນຳໃຊ້ຫຼັກການຂອງ Deep Learning ໃຫ້ມີຄວາມສາມາດຕໍ່ຍອດແນວຄວາມຄິດ ແລະ ນຳໃຊ້ຄວາມຮູ້ໃນດ້ານນີ້ພັດທະນາສິ່ງໃໝ່ໃຫ້ເກີດປະໂຫຍດສູງສຸດ.

ບົດຄັດຫຍໍ້

ແອັບພິເຄຊັນຈຳແນກສຽງເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດທີ່ແຕກຕ່າງກັນເຊັ່ນ (ແຄນ, ຄ້ອງວົງ, ຝົນ, ລະນາດ, ຊໍ່ອູ້, ຊິ່ງ) ດ້ວຍສຽງແມ່ນມີຈຸດປະສົງຫຼັກໆຄືການສຶກສາຄົ້ນຄວ້າວິທີການປະມວນຜົນສຽງ ແລະ ການນຳໃຊ້ປັນຍາປະດິດຂັ້ນສູງ (CNN) ເຂົ້າໃນການຈຳແນກເຄື່ອງດົນຕີແຕ່ລະປະເພດພ້ອມທັງໃຫ້ຂໍ້ມູນປະຫວັດຄວາມເປັນມາກ່ຽວກັບເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດເພື່ອເປັນການຊຸກຍູ້ ແລະ ສົ່ງເສີມວັດທະນະທຳ.

ການຝຶກສອນເຄືອຂ່າຍປະສາດທຽມແບບ CNN ຈຶ່ງແຕ່ລະປະເພດສຽງຂອງເຄື່ອງດົນຕີໄດ້ ດ້ວຍຊຸດຂໍ້ມູນຈຳນວນທັງໝົດແມ່ນ 2,113 ຝາຍສຽງທີ່ເປັນຕົວແທນຂອງເຄື່ອງດົນຕີລາວໄດ້ທຳການແບ່ງຂໍ້ມູນອອກເປັນສອງຊຸດສຳລັບການຝຶກສອນ 80% ແລະ 20% ສຳລັບການທົດສອບ. ຫຼັງຈາກການປະມວນຜົນສຽງ ຫຼື ຜ່ານຂະບວນການເຮັດ (Data Preparation) ເບື້ອງຕົ້ນ, ລວມທັງການດຶງເອົາສ່ວນທີ່ດີທີ່ສຸດ 6 ວິນາທີ, ຊຸດຂໍ້ມູນການຝຶກສອນໄດ້ຂະຫຍາຍເປັນ 2,114 ຕົວຢ່າງ ແລະ ຂໍ້ມູນທີ່ໃຊ້ທົດສອບມີ 422 ຕົວຢ່າງ.

ໃນຂັ້ນຕອນຂອງການສະກັດຄຸນລັກສະນະຂອງຝາຍສຽງນັ້ນພວກຂ້າພະເຈົ້າໄດ້ນຳໃຊ້ເທັກນິກການແຍກສ່ວນປະກອບຂອງສຽງ (HPSS) ເພື່ອແຍກສຽງອອກເປັນສ່ວນປະກອບ harmonic ແລະ percussive, ສ້າງຂັ້ນຕອນການດຶງຄຸນລັກສະນະແບບຫຼາຍຊ່ອງ (channel) ທີ່ມີຊ່ອງ (channel) ແຕກຕ່າງກັນ 6 ຊ່ອງທາງ: mel-spectrogram ດັ່ງເດີມ, ສ່ວນປະກອບ harmonic, ສ່ວນປະກອບ percussive, MFCCs, delta ແລະ delta-delta. ວິທີການນີ້ສ້າງຂໍ້ມູນນຳເຂົ້າຂະໜາດ (128×517×6) ສຳລັບແບບຈຳລອງ CNN.

ຜົນຂອງການສ້າງແບບຈຳລອງໂດຍໃຊ້ວິທີ 3-fold cross-validation, ບັນລຸປະສິດທິພາບທີ່ໂດດເດັ່ນດ້ວຍຄວາມຖືກຕ້ອງ 99.81% ແລະ ຜິດພາດ 0.19% ຫລັງຈາກທົດສອບແບບຈຳລອງກັບຊຸດທົດສອບແມ່ນມີຄວາມຖືກຕ້ອງຢູ່ທີ່ 98.34% ແລະ ພະຍາກອນຜິດແມ່ນ 1.66%, ຜົນຂອງການສ້າງແອັບພິເຄຊັນແມ່ນໄດ້ແອັບທີ່ສາມາດບັນທຶກສຽງໄດ້ແບບ real-time ແລະ ສາມາດອັບໂຫຼດຝາຍສຽງໄດ້ເພື່ອວິເຄາະ ແລະ ຈຳແນກສຽງດັ່ງກ່າວ ແລ້ວສົ່ງຜົນລັບກັບໄປຫາຜູ້ໃຊ້ພ້ອມກັບໃຫ້ຂໍ້ມູນປະຫວັດຄວາມເປັນມາທີ່ໜ້າສົນໃຈເພື່ອສົ່ງເສີມຮັກສາ ແລະ ອະນຸລັກວັດທະນະທຳຂອງລາວເຮົາ.

Abstract

The application for classifying six different types of Lao musical instruments (khean, khong vong, pin, ranad, saw, and sing) by sound has the main objective of researching sound processing methods and applying advanced artificial intelligence (CNN) to classify each type of instrument while providing historical background information about all six types of Lao musical instruments to promote and preserve cultural heritage.

The CNN Convolutional Neural Network was trained to recognize each type of instrument sound using a total dataset of 2,113 audio files representing Lao instruments. The data was divided into two sets: 80% for training and 20% for testing. After audio processing or Data preparation, including extracting the best 6-second segments, the training dataset expanded to 2,114 samples and 422 samples for testing.

In the audio feature extraction process, we employed Harmonic-Percussive Source Separation (HPSS) techniques to separate sounds into harmonic and percussive components, creating a multi-channel feature extraction approach with 6 different channels: original mel-spectrogram, harmonic component, percussive component, MFCCs, delta, and delta-delta features. This method generated input data with dimensions (128×517×6) for the CNN model.

The modeling results using 3-fold cross-validation achieved outstanding performance with 99.81% accuracy and 0.19% error. After testing the model with the test set, it achieved 98.34% accuracy with 1.66% prediction error. The resulting application can record sound in real-time and upload audio files for analysis and classification, then return results to users along with interesting historical information to promote and preserve Lao cultural heritage.

ຄຳຂອບໃຈ

ພວກຂ້າພະເຈົ້າ ທ້າວ ເອກທະວິພິນ ທອງເພັດ ແລະ ທ້າວ ສິດທິພອນ ພຸດຕະວົງ ເປັນນັກສຶກສາປີສຸດທ້າຍ ໃນຊຸດຮຽນ 2021-2025 ໃນສາຂາວິທະຍາສາດຄອມພິວເຕີ, ພາກວິຊາວິທະຍາສາດຄອມພິວເຕີ, ຄະນະ ວິທະຍາສາດທຳມະຊາດ, ພວກຂ້າພະເຈົ້າມີຄວາມພາກພູມໃຈ ແລະ ຮູ້ສຶກເປັນກຽດຢ່າງຍິ່ງທີ່ໄດ້ມີໂອກາດຂຽນບົດ ຈົບຊັ້ນໃນຄັ້ງນີ້ ແລະ ບົດໂຄງການຈົບຊັ້ນສະບັບນີ້ໄດ້ສຳເລັດຢ່າງສົມບູນ ກໍ່ຄືການສຳເລັດການສຶກສາໃນລະດັບ ປະລິນຍາຕີ. ດັ່ງນັ້ນ, ພວກຂ້າພະເຈົ້າຂໍຖືເປັນກຽດຂໍສະແດງຄວາມຂອບໃຈ ແລະ ຂໍສະແດງຄວາມຮູ້ບຸນຄຸນເປັນຢ່າງ ສູງມາຍັງ ຮສ.ປອ. ລັດສະຫມິ ຈິດຕະວົງ ອາຈານນຳພາ ແລະ ອຈ.ປອ ສົມສັກ ອິນທະສອນ ຜູ້ຊ່ວຍນຳພາ ທີ່ໄດ້ ຊ່ວຍໃຫ້ຄຳແນະນຳ ແລະ ຄຳປຶກສາ ແລະ ເປັນທັງອາຈານທີ່ສົດສອນພວກຂ້າພະເຈົ້າມາຕະຫຼອດໃນໄລຍະເວລາທີ່ ຜ່ານມາຈົນສຳເລັດການຂຽນບົດໂຄງການຈົບຊັ້ນໃນຄັ້ງນີ້ຢ່າງຈົບງາມ.

ພ້ອມກັນນີ້ຂໍຂອບໃຈມາຍັງບັນດາ ພະນັກງານ-ຄູອາຈານ ພາຍໃນຄະນະວິທະຍາສາດທຳມະຊາດໂດຍ ສະເພາະແມ່ນໃນ ພາກວິຊາວິທະຍາສາດຄອມພິວເຕີທີ່ເອົາໃຈໃສ່ປະຕິບັດໜ້າທີ່ສົດສອນພວກຂ້າພະເຈົ້າ, ລວມທັງຜູ້ ທີ່ຢູ່ເບື້ອງຫຼັງໃນການອຳນວຍຄວາມສະດວກໃຫ້ກັບການສຶກສາຮ່ຳຮຽນຂອງພວກຂ້າພະເຈົ້າໃນຄັ້ງນີ້ໃຫ້ໄດ້ຮັບ ຜົນສຳເລັດຢ່າງຈົບງາມ.

ຂໍສະແດງຄວາມຮູ້ບຸນຄຸນ ແລະ ຂອບໃຈຢ່າງລື້ນເຫຼືອມາຍັງພໍ່ແມ່, ອ້າຍເອື້ອຍນ້ອງ, ຜູ້ທີ່ຢູ່ຄຽງຂ້າງ, ພ້ອມ ດ້ວຍຍາດຕິຜົນ້ອງຜູ້ທີ່ເປັນແຮງກາຍແຮງໃຈ, ຜູ້ທີ່ຊ່ວຍສະໜັບສະໜູນທາງດ້ານທຶນຮອນ ແລະ ຊ່ວຍແກ້ໄຂບັນຫາ ຈົນຮອດຕອນສຸດທ້າຍຂອງການສຶກສາຄັ້ງນີ້, ຂໍຂອບໃຈໄປຍັງໝູ່ເພື່ອນສະຫາຍທຸກຄົນທີ່ຄ່ອຍເອົາໃຈໃສ່ຊ່ວຍເຫຼືອ ເຊິ່ງກັນ ແລະ ກັນ. ສຸດທ້າຍນີ້, ຂໍອວຍພອນໃຫ້ກັບຜູ້ທີ່ມີສ່ວນກ່ຽວຂ້ອງທຸກພາກສ່ວນໃຫ້ມີຄວາມສຸກກາຍ, ສະບາຍໃຈ, ມີສຸຂະພາບທີ່ແຂງແຮງ ແລະ ປະສົບຜົນສຳເລັດໃນໜ້າວຽກການງານທຸກດ້ານ.

ທ້າວ ເອກທະວິພິນ ທອງເພັດ

ທ້າວ ສິດທິພອນ ພຸດຕະວົງ

ສາລະບານ

ຄຳນຳ	i
ບົດຄັດຫຍໍ້.....	ii
Abstract.....	iii
ຄຳຂອບໃຈ	iv
ສາລະບານ	v
ສາລະບານຮູບຟາບ	vii
ສາລະບານຕາຕະລາງ	x
ຄຳຫຍໍ້	xi
ບົດທີ 1 ບົດສະເໜີ	1
1.1. ຄວາມສຳຄັນຂອງບັນຫາ.....	1
1.2. ຈຸດປະສົງຂອງການຄົ້ນຄວ້າ (Objectives).....	2
1.3. ຂອບເຂດຂອງການຄົ້ນຄວ້າ (Scope)	2
1.4. ປະໂຫຍດຄາດວ່າຈະໄດ້ຮັບ (Expected Outcome of the Project)	3
ບົດທີ 2 ທົບທວນເອກະສານ ແລະ ບົດຄົ້ນຄວ້າທີ່ກ່ຽວຂ້ອງ	5
2.1. ທົບທວນເອກະສານ	5
2.1.1. ເຄື່ອງມືນິຍາມເມືອງລາວ.....	5
2.1.2. ພື້ນຖານທິດສະດີຂອງໂຄງຂ່າຍປະສາດທຽມເຊິງເລິກ (Deep Neural Networks)	8
2.1.3. ການປຽບທຽບໂຄງຂ່າຍປະສາດທຽມແບບເລິກ (DNN) ແລະ ໂຄງຂ່າຍປະສາດທຽມແບບຄອນ ໂວລູຊັນ (CNN).....	13
2.1.4. ການປະເມີນແບບຈຳລອງ (Model Evaluation)	14
2.1.5. ການປະມວນຜົນສຽງ (Audio Processing)	18
2.1.6. Unified Modeling Language (UML).....	24
2.1.7. ພາສາ ແລະ ເຄື່ອງມືຕ່າງໆທີ່ໃຊ້ໃນການພັດທະນາລະບົບ	28
2.2. ບົດຄົ້ນຄວ້າທີ່ກ່ຽວຂ້ອງ	30
ບົດທີ 3 ວິທີດຳເນີນການຄົ້ນຄວ້າ	32
3.1. ວິທີການສຶກສາ ແລະ ຄົ້ນຄວ້າ.....	32
3.1.1. ຄວາມເຂົ້າໃຈຕໍ່ກັບບັນຫາ (Business Understanding)	33

3.1.2.	ຄວາມເຂົ້າໃຈຕໍ່ກັບຂໍ້ມູນ (Data Understanding)	33
3.1.3.	ການກະກຽມຂໍ້ມູນ (Data Preparation)	41
3.1.4.	ການສ້າງແບບຈຳລອງ (Modeling).....	53
3.1.5.	ການປະເມີນຜົນ (Evaluation)	60
3.1.6.	ການນຳໄປໃຊ້ (Deployment).....	60
3.2.	ເຄື່ອງມືທີ່ໃຊ້ໃນການຄົ້ນຄວ້າ.....	61
3.2.1.	Hardware	61
3.2.2.	Software	61
3.3.	ການວິເຄາະລະບົບ	62
3.3.1.	ແຜນວາດລວມຂອງລະບົບ.....	62
3.3.2.	ແຜນວາດ Use Case Diagram	63
3.3.3.	ແຜນວາດ Sequence Diagram	66
3.3.4.	ແຜນວາດ Activity Diagram	69
3.4.	ການອອກແບບ.....	74
3.4.1.	ການອອກແບບຮ່າງສະແດງຜົນ	74
ບົດທີ 4	ຜົນຂອງການສຶກສາ ແລະ ອະທິບາຍຜົນ	79
4.1.	ລາຍງານຜົນການສຶກສາ ແລະ ອະທິບາຍຜົນ.....	79
4.1.1.	ລາຍງານຜົນສະຖິຕິຂອງຂໍ້ມູນ	79
4.1.2.	ລາຍງານຜົນການຝຶກສອນແບບຈຳລອງ	80
4.1.3.	ລາຍງານການປະເມີນແບບຈຳລອງ.....	83
4.2.	ລາຍງານ ແລະ ອະທິບາຍຜົນການສ້າງແອັບພິເຄຊັນ	85
4.2.1.	ລາຍງານຜົນການສ້າງແອັບພິເຄຊັນ	85
4.2.2.	ອະທິບາຍຜົນການສ້າງແອັບພິເຄຊັນ	86
ບົດທີ 5	ສະຫຼຸບ ແລະ ຂໍ້ສະເໜີ.....	93
5.1.	ສະຫຼຸບຜົນການຄົ້ນຄວ້າ	93
5.2.	ຂໍ້ຈຳກັດຂອງການຄົ້ນຄວ້າ.....	94
5.3.	ຂໍ້ສະເໜີໃນການຄົ້ນຄວ້າຕໍ່ໄປ	95

ສາລະບານຮູບພາບ

ຮູບທີ 2.1 ເຄື່ອງດົນຕີລາວແຄນ (ມະນີຣັດ ວັດຕະນະມົງຄົນ, 2013)	5
ຮູບທີ 2.2 ເຄື່ອງດົນຕີລາວຊຸູ້້ ((Wikipedia, 2024).....	6
ຮູບທີ 2.3 ເຄື່ອງດົນຕີລາວຊຶ່ງ (Rajadamnern Stadium, 2025).....	6
ຮູບທີ 2.4 ເຄື່ອງດົນຕີລາວພິນ (Academic Office of Roi Et Rajabhat University, n.d.)	7
ຮູບທີ 2.5 ເຄື່ອງດົນຕີລາວຄ້ອງວົງ (ຄຸຕຸ້ຍ, 2017)	7
ຮູບທີ 2.6 ເຄື່ອງດົນຕີລາວລະນາດ (Wikipedia, 2025)	8
ຮູບທີ 2.7 ສະແດງໂຄງສ້າງພື້ນຖານຂອງໂຄງຂ່າຍປະສາດທຽມແບບເລິກ (AltexSoft Team, 2021)	9
ຮູບທີ 2.8 ໂຄງສ້າງພື້ນຖານຂອງໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ (Shamik Tiwari et.al, 2021) ...	11
ຮູບທີ 2.9 Confusion Matrix (Shamik Tiwari et.al, 2021).....	15
ຮູບທີ 2.10 ສະແດງການແບ່ງສ່ວນຂໍ້ມູນ ຂອງ K-Fold Cross Validation (Pedregosa et al., 2011)	17
ຮູບທີ 2.11 ສະແດງ Early Stopping ເມື່ອຄ່າມີການແຍກໂຕອອກຈາກກັນ (Prechelt, 1998).....	18
ຮູບທີ 2.12 Spectrogram Dimensions: ຄວາມຖີ່, ເວລາ ແລະ ສີ (Ashames and Ergin, 2021).....	20
ຮູບທີ 2.13 ສະແດງພາບກ່ອນ ແລະ ຫຼັງເພີ່ມສຽງລົບກວນ (Ashames ແລະ Ergin ,2021)	23
ຮູບທີ 2.14 ອົງປະກອບຂອງ UML	24
ຮູບທີ 2.15 ຮູບສະແດງສັນຍາລັກ Use Case	24
ຮູບທີ 2.16 ຮູບສະແດງສັນຍາລັກ Actor	25
ຮູບທີ 2.17 ຮູບສະແດງສັນຍາລັກ System Boundary.....	25
ຮູບທີ 2.18 ຮູບສະແດງຄວາມສໍາພັນ Include	25
ຮູບທີ 2.19 ຮູບສະແດງຄວາມສໍາພັນ Extend.....	26
ຮູບທີ 2.20 ຮູບສະແດງຄວາມສໍາພັນ Class Diagram.....	26
ຮູບທີ 2.21 ຮູບສະແດງ Class Diagram	27
ຮູບທີ 2.22 ຮູບສະແດງ Sequence Diagram	27
ຮູບທີ 3.1 CRISP-DM (Cross-industry standard process for data mining)	32
ຮູບທີ 3.2 ຮູບພາບເຄື່ອງດົນຕີທີ່ພວກຂ້າພະເຈົ້າມີ.....	36
ຮູບທີ 3.3 ສຽງແຄນໃນຮູບແບບຂອງພາບ Mel Spectrogram	37
ຮູບທີ 3.4 ສຽງຄ້ອງໃນຮູບແບບຂອງພາບ Mel Spectrogram	37
ຮູບທີ 3.5 ສຽງພິນໃນຮູບແບບຂອງພາບ Mel Spectrogram	37

ຮູບທີ 3.6 ສຽງລະນາດໃນຮູບແບບຂອງພາບ Mel Spectrogram	37
ຮູບທີ 3.7 ສຽງຊໍ້ອູ້ໃນຮູບແບບຂອງພາບ Mel Spectrogram.....	38
ຮູບທີ 3.8 ສຽງຊິງໃນຮູບແບບຂອງພາບ Mel Spectrogram	38
ຮູບທີ 3.9 ແອັບ Voice Recorder ທີ່ໃຊ້ເກັບຂໍ້ມູນສຽງປັບຄວາມລະອຽດໄດ້ສູງສຸດ 44Khz	40
ຮູບທີ 3.10 ແອັບ ZArchiver ທີ່ໃຊ້ຈັດການຟາຍໃຫ້ຢູ່ໃນແຕ່ລະພາກສ່ວນ	41
ຮູບທີ 3.11 ສະແດງການກະຈາຍຂອງຄວາມຍາວຟາຍສຽງໂດຍໃຊ້ histogram.....	42
ຮູບທີ 3.12 ສະແດງຕົວຢ່າງການຄັດເລືອກຊ່ວງສຽງ ທີ່ມີຄວາມຍາວ 8.10 ວິນາທີ	44
ຮູບທີ 3.13 ສະແດງຕົວຢ່າງການຄັດເລືອກຊ່ວງສຽງທີ່ມີຄວາມຍາວ 6.80 ວິນາທີ	44
ຮູບທີ 3.14 ສະແດງສະຖິຕິການປະມວນຜົນແບບ bar chart ແລະ pie chart	45
ຮູບທີ 3.15 ສະແດງການກະຈາຍຂອງຂໍ້ມູນແຕ່ລະປະເພດເຄື່ອງດົນຕີ	47
ຮູບທີ 3.16 ສະແດງ ຂະບວນການສະກັດ feature ແບບ 6-channel.....	48
ຮູບທີ 3.17 ສະແດງອົງປະກອບຂອງ HPSS ຈາກເຄື່ອງດົນຕີທັງ 6 ປະເພດ	49
ຮູບທີ 3.18 ລາຍລະອຽດຂໍ້ມູນທີ່ມີການແບ່ງໄວ້ສໍາລັບການຝຶກສອນແບບຈໍາລອງ ແລະ ການທົດສອບ.....	50
ຮູບທີ 3.19 ສະແດງ class weights ຂອງແຕ່ລະເຄື່ອງດົນຕີ.....	52
ຮູບທີ 3.20 ສະແດງຂະບວນການກະກຽມຂໍ້ມູນທັງໝົດທີ່ສະແດງການໄຫລຂອງຂໍ້ມູນ	53
ຮູບທີ 3.21 ລາຍລະອຽດການສະແດງຜົນ Compile ຂອງແບບຈໍາລອງທີ່ດີທີ່ສຸດໃນທັງ 3 k.....	57
ຮູບທີ 3.22 ແຜນວາດລວມຂອງລະບົບ	62
ຮູບທີ 3.23 Use Case Diagram ສະແດງໃຫ້ເຫັນການໂຕ້ຕອບລະຫວ່າງຜູ້ໃຊ້ກັບລະບົບ	63
ຮູບທີ 3.24 Sequence Diagram ບັນທຶກສຽງເຄື່ອງດົນຕີ ແລະ ການວິເຄາະຜົນລັບ.....	67
ຮູບທີ 3.25 Sequence Diagram ການນຳເຂົ້າຟາຍສຽງ ແລະ ການວິເຄາະຜົນລັບ	68
ຮູບທີ 3.26: Activity Diagram ການວິເຄາະເຄື່ອງດົນຕີລາວ.	70
ຮູບທີ 3.27: Activity Diagram ການຈັດການຂໍ້ຜິດພາດ	72
ຮູບທີ 3.28 ໂຄງຜັງການນຳທາງຫຼັກຂອງແອັບຈຳແນກເຄື່ອງດົນຕີລາວ	74
ຮູບທີ 3.29 ໜ້າຫຼັກສະແດງຂໍ້ມູນໂຄງການ ແລະ ປຸ່ມການດຳເນີນງານຕ່ວນ	74
ຮູບທີ 3.30 ອອກແບບໜ້າບັນທຶກສຽງຜ່ອມຄຳແນະນຳ ແລະ ການສະແດງຜົນ	75
ຮູບທີ 3.31 ອອກແບບຜົນການວິເຄາະລະອຽດຜ່ອມຄະແນນຄວາມເຊື່ອໝັ້ນ.....	76
ຮູບທີ 3.32 ອອກແບບໜ້າຄຸ້ມການໃຊ້ງານ	77
ຮູບທີ 3.33 ອອກແບບໜ້າຕັ້ງຄ່າແອັບ.....	78
ຮູບທີ 4.1 ການກະຈາຍຕົວຂອງຟາຍສຽງແຕ່ລະເຄື່ອງດົນຕີ ແລະ ສຽງອື່ນ.....	79
ຮູບທີ 4.2 ການກະຈາຍຕົວຂອງຂໍ້ມູນຕົວຢ່າງແຕ່ລະເຄື່ອງດົນຕີ ແລະ ສຽງອື່ນ ພາຍຫລັງການປະມວນຜົນສຽງ..	80

ຮູບທີ 4.3 ສະແດງຄ່າການກວດຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງ ແລະ ຄ່າການກວດສອບການສູນເສຍຂອງ ແບບຈຳລອງທັງ 3 Fold	81
ຮູບທີ 4.4 ສະແດງຄ່າຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງ ແລະ ຄ່າການກວດສອບຄວາມຖືກຕ້ອງພ້ອມບອກຮອບ ຂອງການຝຶກທີ່ດີທີ່ສຸດ	81
ຮູບທີ 4.5 ສະແດງຄ່າການສູນເສຍຂອງແບບຈຳລອງ ແລະ ຄ່າການກວດສອບການສູນເສຍຂອງແບບຈຳລອງ	82
ຮູບທີ 4.6 Confusion Matrix ຂອງການຝຶກສອນແບບຈຳລອງ	83
ຮູບທີ 4.7 Confusion Matrix ຂອງການທົດສອບແບບຈຳລອງ	84
ຮູບທີ 4.8: ໜ້າຈໍຫຼັກຂອງ Application (Home Screen)	86
ຮູບທີ 4.9: ໜ້າຈໍການດຳເນີນງານດ່ວນ ແລະ ການເຊື່ອມຕໍ່	87
ຮູບທີ 4.10 ໜ້າຈໍການບັນທຶກສຽງ ແລະ ອັບໂຫລດໄຟລ໌	88
ຮູບທີ 4.11: ໜ້າຈໍການວິເຄາະຜົນລັບ (Results Dialog)	88
ຮູບທີ 4.12: ໜ້າຈໍຜົນລັບການວິເຄາະທີ່ຍັງບໍ່ມີຂໍ້ມູນ	89
ຮູບທີ 4.13: ໜ້າຈໍຜົນລັບການວິເຄາະສໍາເລັດ (Successful Analysis Results)	89
ຮູບທີ 4.14: Tutorial & Guide - ຄູ່ມືການໃຊ້ງານແອັບ	90
ຮູບທີ 4.15: ໜ້າຈໍຄູ່ມືລະອຽດ & FAQ - ການແກ້ໄຂບັນຫາ	91
ຮູບທີ 4.16: ໜ້າຈໍການຕັ້ງຄ່າ & ການເລືອກພາສາ (Settings Screen)	92

ສາລະບານຕາຕະລາງ

ຕາຕະລາງທີ 3.1 ສະແດງການກະຈາຍຕົວຂອງຂໍ້ມູນຂອງແຕ່ລະໝວດໝູ່.....	39
ຕາຕະລາງທີ 3.2: ການຈັດໝວດໝູ່ເຄື່ອງດົນຕີລາວ.....	46
ຕາຕະລາງທີ 3.3: ລາຍລະອຽດ Use Case - ບັນທຶກສຽງ.....	63
ຕາຕະລາງທີ 3.4: ລາຍລະອຽດ Use Case - ນຳເຂົ້າຟາຍສຽງ.....	64
ຕາຕະລາງທີ 3.5: ລາຍລະອຽດ Use Case - ຈຳແນກເຄື່ອງດົນຕີ.....	65
ຕາຕະລາງທີ 3.6: ລາຍລະອຽດ Use Case - ເບິ່ງຜົນລັບ.....	65
ຕາຕະລາງທີ 3.7: ປະເພດຂໍ້ມູນທີ່ລະບົບຮອງຮັບ.....	73
ຕາຕະລາງທີ 4.1: ຜົນການປະເມີນລະອຽດຂອງແຕ່ລະປະເພດເຄື່ອງດົນຕີຈາກ fold ທີ 1.....	85

ຄຳຫຍໍ້

CNN = Convolutional Neural Network

DNN = Deep Neural Network

HPSS = Harmonic-Percussive Source Separation

OOD = Out of Distribution

MFCC = Mel-Frequency Cepstral Coefficients

UML = Unified Modeling Language

FFT = Fast Fourier Transform

STFT = Short-Time Fourier Transform

TP = True Positive

FP = False Negative

TN = True Negative

FN = False Negative

ບົດທີ 1

ບົດສະເໜີ

1.1. ຄວາມສໍາຄັນຂອງບັນຫາ.

ດິນຕີພື້ນເມືອງລາວເປັນມໍລະດົກທາງວັດທະນະທຳອັນລ້ຳຄ່າທີ່ສືບທອດກັນມາແຕ່ບູຮານ, ເຊິ່ງສະແດງເຖິງເອກະລັກຂອງຊາດລາວ. ເຄື່ອງດົນຕີພື້ນເມືອງລາວມີຫຼາກຫຼາຍປະເພດທີ່ມີເອກະລັກສະເພາະ ເຊັ່ນ: ແຄນ ເຊິ່ງໄດ້ຮັບການຂຶ້ນທະບຽນເປັນມໍລະດົກທາງວັດທະນະທຳທຳອິດຂອງລາວ ໂດຍອົງການ UNESCO ໃນປີ 2017, ຊໍອູ້ ເຄື່ອງດົນຕີປະເພດສີ່ທີ່ມີສຽງທີ່ມີຄວາມມ່ວນລະມຸນ, ຊິ່ງ ແລະ ຊິງ ເຄື່ອງດົນຕີປະເພດຕີ, ຄ້ອງວົງ ທີ່ໃຊ້ໃນພິທີກຳຕ່າງໆ ແລະ ລະນາດ ທີ່ມີບົດບາດສໍາຄັນໃນວົງດົນຕີພື້ນເມືອງລາວ. ເຄື່ອງດົນຕີແຕ່ລະຊະນິດມີເອກະລັກທັງທາງດ້ານຮູບຮ່າງ, ສຽງ ແລະ ບົດບາດ ເຊິ່ງສະທ້ອນໃຫ້ເຫັນເຖິງຄວາມອຸດົມສົມບູນທາງດ້ານວັດທະນະທຳຂອງຊາດລາວ.

ໃນຍຸກປັດຈຸບັນ ເຕັກໂນໂລຊີການຮຽນຮູ້ເຊິ່ງເລິກ (Deep Learning) ໄດ້ມີການພັດທະນາຢ່າງກ້າວກະໂດດ ໂດຍສະເພາະໃນດ້ານການປະມວນຜົນສຽງ (Audio Processing). ເຕັກໂນໂລຊີດັ່ງກ່າວໄດ້ຖືກນຳມາປະຍຸກໃຊ້ໃນຫຼາຍວົງການ ເຊັ່ນ: ການຈຳແນກປະເພດສຽງດິນຕີ, ການວິເຄາະອົງປະກອບຂອງສຽງ, ການຈຳແນກເຄື່ອງດົນຕີຕ່າງໆ ແລະ ການສ້າງລະບົບຊ່ວຍເຫຼືອທາງດ້ານດິນຕີ. ການນຳໃຊ້ເຕັກນິກ Deep Learning ສາມາດຊ່ວຍໃຫ້ການຈຳແນກສຽງມີຄວາມແນ່ນອນຢ່າງສູງ ແລະ ມີຄວາມສາມາດໃນການຮຽນຮູ້ໃນຮູບແບບທີ່ຊັບຊ້ອນ. ໃນຕ່າງປະເທດ, ໄດ້ມີການພັດທະນາລະບົບການຈຳແນກເຄື່ອງດົນຕີໂດຍໃຊ້ປັນຍາປະດິດຢ່າງແຜ່ຫຼາຍ ແລະ ປະສິບຜົນສຳເລັດໃນການນຳໄປໃຊ້ງານຈິງ. ເຖິງຢ່າງໃດກໍຕາມ, ໃນຂະນະທີ່ເຕັກໂນໂລຊີດັ່ງກ່າວໄດ້ຖືກນຳໃຊ້ຢ່າງແຜ່ຫຼາຍໃນການຈຳແນກ ແລະ ວິເຄາະສຽງດິນຕີໃນຫຼາຍວັດທະນະທຳທົ່ວໂລກ, ແຕ່ການເຂົ້າເຖິງຂໍ້ມູນກ່ຽວກັບເຄື່ອງດົນຕີພື້ນເມືອງລາວຍັງມີຂໍ້ຈຳກັດຫຼາຍດ້ານ. ໃນຄັ້ງທຳອິດແມ່ນ, ວິທີການສຶກສາ ແລະ ຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີພື້ນເມືອງແບບດັ້ງເດີມອາດບໍ່ດຶງດູດຄວາມສົນໃຈຂອງຄົນລຸ້ນໃໝ່ເທົ່າທີ່ຄວນ ເນື່ອງຈາກຂາດການນຳສະເໜີໃນຮູບແບບທີ່ທັນສະໄໝ ແລະ ເຂົ້າເຖິງໄດ້ງ່າຍ. ສອງແມ່ນ, ການຂາດເຄື່ອງມືທີ່ທັນສະໄໝທີ່ຈະຊ່ວຍໃນການຈຳແນກ ແລະ ຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີພື້ນເມືອງລາວເຮັດໃຫ້ການສຶກສາຄົ້ນຄວ້າ ແລະ ການເຜີຍແຜ່ຂໍ້ມູນເປັນໄປໄດ້ຊ້າ. ນອກຈາກນີ້, ການຂາດແຄນຖານຂໍ້ມູນສຽງເຄື່ອງດົນຕີພື້ນເມືອງລາວທີ່ເປັນລະບົບ ແລະ ໄດ້ມາດຕະຖານ ກໍເປັນອີກໜຶ່ງອຸປະສັກສໍາຄັນໃນການພັດທະນາລະບົບການຈຳແນກສຽງເຄື່ອງດົນຕີລາວ. ການເກັບກຳ ແລະ ຈັດລະບົບຂໍ້ມູນສຽງຂອງເຄື່ອງດົນຕີແຕ່ລະຊະນິດຕ້ອງໃຊ້ເວລາ ແລະ ຊັບພະຍາກອນຈຳນວນຫຼາຍ. ອີກປະການໜຶ່ງ, ຄວາມຫຼາກຫຼາຍຂອງວິທີການຫຼິ້ນ ແລະ ເທັກນິກການສະແດງຂອງເຄື່ອງດົນຕີແຕ່ລະຊະນິດ ເຮັດໃຫ້ການສ້າງແບບຈຳລອງການຮຽນຮູ້ທີ່ມີຄວາມແນ່ນອນຢ່າງສູງເປັນສິ່ງທ້າທາຍ. ໃນຂະນະດຽວກັນ, ການເຕີບໂຕຂອງເຕັກໂນໂລຊີສະມາດໂຟນ ແລະ ການເຂົ້າເຖິງອິນເຕີເນັດທີ່ສະດວກສະບາຍຂຶ້ນ ໄດ້ເປີດໂອກາດໃໝ່ໃນການພັດທະນາເຄື່ອງມືດິຈິຕອນເພື່ອການອະນຸລັກວັດທະນະທຳ. ການພັດທະນາແອັບພລິເຄຊັນມືຖືທີ່ໃຊ້ເຕັກໂນໂລຊີ Deep Learning ໃນການ

ຈຳແນກສຽງເຄື່ອງດົນຕີລາວ ອາດເປັນວິທີການໜຶ່ງທີ່ມີປະສິດທິພາບໃນການແກ້ໄຂບັນຫາທີ່ກ່າວມາຂ້າງເທິງ. ເຕັກໂນໂລຊີນີ້ສາມາດຊ່ວຍໃຫ້ການຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີພື້ນເມືອງລາວມີຄວາມໜ້າສົນໃຈຫຼາຍຂຶ້ນ, ເຂົ້າເຖິງໄດ້ງ່າຍ, ແລະ ສາມາດນຳໄປໃຊ້ໃນການສຶກສາຄົ້ນຄວ້າໄດ້ຢ່າງມີປະສິດທິພາບ.

ຈາກບັນຫາ ແລະ ໂອກາດທີ່ກ່າວມາຂ້າງເທິງ, ພວກນັ້ນຈຶ່ງມີແນວຄິດໃນການພັດທະນາແອັບພລິເຄຊັນມີຖືກທີ່ສາມາດຈຳແນກເຄື່ອງດົນຕີລາວໂດຍໃຊ້ເຕັກນິກ Deep Learning ໃນການປະມວນຜົນສຽງ. ແອັບພລິເຄຊັນນີ້ຈະເປັນການປະສົມປະສານລະຫວ່າງວັດທະນະທຳດັ້ງເດີມ ແລະ ເຕັກໂນໂລຊີທັນສະໄໝ, ເພື່ອສົ່ງເສີມການອະນຸລັກ ແລະ ການຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີພື້ນເມືອງລາວໃຫ້ແກ່ຄົນລຸ້ນໃໝ່ ແລະ ຜູ້ທີ່ສົນໃຈທົ່ວໄປ. ການພັດທະນານີ້ຈະເນັ້ນໃສ່ການສ້າງລະບົບທີ່ມີຄວາມແມ່ນຍຳສູງໃນການຈຳແນກປະເພດເຄື່ອງດົນຕີ, ພ້ອມທັງນຳສະເໜີຂໍ້ມູນໃນຮູບແບບທີ່ເຂົ້າໃຈງ່າຍ ແລະ ໜ້າສົນໃຈ. ນອກຈາກການຈຳແນກປະເພດເຄື່ອງດົນຕີແລ້ວ, ແອັບພລິເຄຊັນຍັງຈະລວມເອົາຂໍ້ມູນປະຫວັດຄວາມເປັນມາ, ບົດບາດ, ແລະ ຄວາມສຳຄັນຂອງເຄື່ອງດົນຕີແຕ່ລະຊະນິດ, ເຊິ່ງຈະຊ່ວຍໃຫ້ຜູ້ໃຊ້ສາມາດເຂົ້າໃຈ ແລະ ຮຽນຮູ້ກ່ຽວກັບມໍລະດົກທາງວັດທະນະທຳດ້ານດົນຕີພື້ນເມືອງລາວໄດ້ຢ່າງເລິກເຊິ່ງ. ໂຄງການນີ້ຈະເປັນກ້າວສຳຄັນໃນການນຳເອົາເຕັກໂນໂລຊີທັນສະໄໝມາປະຍຸກໃຊ້ໃນການອະນຸລັກ ແລະ ສົ່ງເສີມວັດທະນະທຳລາວ, ເຮັດໃຫ້ການຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີພື້ນເມືອງລາວມີຄວາມໜ້າສົນໃຈ ແລະ ເຂົ້າເຖິງໄດ້ງ່າຍສຳລັບຄົນທຸກເພດທຸກໄວ.

1.2. ຈຸດປະສົງຂອງການຄົ້ນຄວ້າ (Objectives)

ຈຸດປະສົງຂອງການຄົ້ນຄວ້າ ເພື່ອພັດທະນາລະບົບຈຳແນກເຄື່ອງດົນຕີພື້ນເມືອງລາວ ໃຫ້ທັນສະໄໝ ແລະ ງ່າຍຕໍ່ການນຳໃຊ້ສຳລັບການຮຽນຮູ້ ແລະ ອະນຸລັກວັດທະນະທຳລາວ. ຈຸດປະສົງຫຼັກຂອງການຄົ້ນຄວ້າຄື:

- ເພື່ອສຶກສາ ແລະ ພັດທະນາລະບົບການຈຳແນກປະເພດເຄື່ອງດົນຕີພື້ນເມືອງລາວດ້ວຍສຽງໂດຍນຳໃຊ້ເຕັກໂນໂລຊີການຮຽນຮູ້ເຊິ່ງເລິກ (Deep Learning).
- ເພື່ອສ້າງແອັບພລິເຄຊັນສຳລັບມືຖື ທີ່ສາມາດຈຳແນກປະເພດເຄື່ອງດົນຕີພື້ນເມືອງລາວ ພ້ອມທັງສະແດງຂໍ້ມູນ, ປະຫວັດຄວາມເປັນມາ.
- ເພື່ອສະແດງຜົນການຈຳແນກປະເພດເຄື່ອງດົນຕີລາວໃນຮູບແບບທີ່ເຂົ້າໃຈງ່າຍລວມເຖິງການສະແດງຄ່າຄວາມແໜ້ນຍຳ ແລະ ຂໍ້ມູນທີ່ກ່ຽວຂ້ອງ

1.3. ຂອບເຂດຂອງການຄົ້ນຄວ້າ (Scope)

1) ຂອບເຂດຂອງຂໍ້ມູນ (Data Set)

ກຸ່ມເປົ້າໝາຍທີ່ພວກຂ້າພະເຈົ້າໃຊ້ເປັນຕົວຢ່າງໃນໂຄງການຈະເປັນປະເພດເຄື່ອງດົນຕີລາວ 6 ຊະນິດ ແລະ ສຽງລົບກວນອີກ 1 class ເພື່ອຫຼຸດອາການບໍ່ຮູ້ຈັກຈຳແນກສຽງກໍລະນີມີສຽງອື່ນ ຫຼື ເອີ້ນວ່າ OOD (Out of Distribution) ໄດ້ແກ່:

- ແຄນ: 295 ຝາຍ
- ຊິອູ້: 314 ຝາຍ
- ຊິງ: 295 ຝາຍ
- ຟິນ: 285 ຝາຍ

- ຄ້ອງວົງ: 314 ຝາຍ
- ລະນາດ: 302 ຝາຍ
- ສຽງລົບກວນ (unknown) 308 ຝາຍ

ລວມທັງໝົດ: 2,113 ຝາຍ ທີ່ສະເພາະເປັນ raw data

ເຊິ່ງໃນແຕ່ລະຕົວຢ່າງຈະທຳການເກັບເປັນ file .wav ທີ່ມີຂະໜາດຄວາມຍາວຂອງຄືບສຽງປະມານ 6-8 ວິນາທີໂດຍສ່ວນຫຼາຍ.

ຫຼັງຈາກການເພີ່ມຂໍ້ມູນ ພວກຂ້າພະເຈົ້າຍັງຕ້ອງໄດ້ທຳການເອົາຂໍ້ມູນທີ່ເປັນຂໍ້ມູນດິບຂອງສຽງເຄື່ອງດົນຕີແຕ່ລະປະເພດ ມາທຳການດັດແປງເພີ່ມຈຳນວນຂໍ້ມູນຕົວຢ່າງໂດຍນຳໃຊ້ເຕັກນິກ Data Augmentation.

2) ທີ່ມາຂອງຂໍ້ມູນ

ຂໍ້ມູນສຽງສ່ວນໃຫຍ່ຈະເກັບກຳຈາກແຫຼ່ງຂໍ້ມູນອິນເຕີເນັດ ໂດຍສະເພາະຈາກເວັບໄຊ YouTube. ພວກຂ້າພະເຈົ້າຈະທຳການຄັດເລືອກ ແລະ ເກັບບັນທຶກສຽງສະເພາະຂອງເຄື່ອງດົນຕີແຕ່ລະປະເພດ ໂດຍກຳນົດໄລຍະ ເວລາຂອງແຕ່ລະຕົວຢ່າງປະມານ 6-8 ວິນາທີ. ນອກຈາກນີ້, ຍັງຈະມີການເກັບຂໍ້ມູນຈາກການບັນທຶກສຽງເຄື່ອງດົນຕີໂດຍກົງ.

3) ວິທີການເບື້ອງຕົ້ນ

- ທຳການສະກັດຄຸນລັກສະນະສຽງໂດຍນຳໃຊ້ Mel-spectrograms ເພື່ອປ່ຽນຮູບແບບສຽງໃຫ້ກາຍເປັນຮູບພາບທີ່ເປັນຄືນ ຫຼື ເອີ້ນວ່າ spectrograms ແລະ ຍັງໄດ້ນຳໃຊ້ MFCC, Delta Features, Delta-Delta Features ເພື່ອໃຫ້ໄດ້ການສະກັດຄຸນລັກສະນະທີ່ດີທີ່ສຸດໃຫ້ກັບການຝຶກແບບຈຳລອງ.
- ສ້າງຂັ້ນຕອນວິທີການໃນການສ້າງແບບຈຳລອງໂດຍນຳໃຊ້ ເຕັກນິກ CNN (Convolutional neural Network) ເພື່ອຈຳແນກ ແລະ ຈົດຈຳຄຸນລັກສະນະຂອງສຽງແຕ່ລະປະເພດ.
- ປະເມີນປະສິດທິພາບ ແລະ ການທົດສອບແບບຈຳລອງການຈຳແນກສຽງເຄື່ອງດົນຕີແຕ່ລະປະເພດ.
- ສຶກສາການນຳເອົາຂໍ້ມູນເຂົ້າແບບຈຳລອງແບບ real time ເພື່ອເພີ່ມປະສິດທິພາບໃຫ້ກັບ application ໃຫ້ມີລູກຫຼິ້ນຫຼາຍຂຶ້ນ.
- ສ້າງ App ທີ່ສາມາດຈຳແນກ ສຽງຂອງເຄື່ອງດົນຕີທັງ 6 ປະເພດໄດ້ຢ່າງແມ່ນຢາພ້ອມສະແດງຂໍ້ມູນປະຫວັດຄວາມເປັນມາຂອງແຕ່ລະເຄື່ອງດົນຕີ.

1.4. ປະໂຫຍດຄາດວ່າຈະໄດ້ຮັບ (Expected Outcome of the Project)

ຫຼັງຈາກສຳເລັດໂຄງການຜົນທີ່ຄາດວ່າຈະໄດ້ຮັບມີດັ່ງນີ້:

1) ດ້ານເຕັກນິກ ແລະ ການພັດທະນາ:

- ໄດ້ຮູ້ເຖິງຂະບວນການເຮັດວຽກຂອງແບບຈຳລອງການຈຳແນກປະເພດສຽງເຄື່ອງດົນຕີລາວໂດຍໃຊ້ເຕັກນິກ Deep Learning.
- ໄດ້ຮູ້ເຖິງບັນຫາ ແລະ ວິທີການແກ້ໄຂທີ່ເກີດຂຶ້ນໃນຂະບວນການພັດທະນາ.
- ໄດ້ແບບຈຳລອງທີ່ເໝາະສົມສຳລັບການຈຳແນກສຽງເຄື່ອງດົນຕີລາວ.

2) ດ້ານການນຳໃຊ້:

- ໄດ້ແອັບພລິເຄຊັນທີ່ສາມາດຈຳແນກສຽງຂອງເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດໄດ້ຢ່າງແມ່ນຍຳ.
- ໄດ້ລະບົບທີ່ສາມາດວິເຄາະ ແລະ ປະມວນຜົນສຽງແບບ Real-time.
- ໄດ້ແອັບພລິເຄຊັນທີ່ໃຊ້ງານງ່າຍ ແລະ ເໝາະສົມກັບຜູ້ໃຊ້ທົ່ວໄປ.

3) ດ້ານການອະນຸລັກວັດທະນະທຳ:

- ສົ່ງເສີມການອະນຸລັກວັດທະນະທຳທີ່ກ່ຽວພັນກັບເຄື່ອງດົນຕີຜື່ນເມືອງລາວ.
- ເຜີຍແຜ່ຂໍ້ມູນປະຫວັດຄວາມເປັນມາຂອງເຄື່ອງດົນຕີແຕ່ລະປະເພດ.
- ສ້າງຄວາມເຂົ້າໃຈ ແລະ ການຮັບຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີຜື່ນເມືອງລາວ.

ບົດທີ 2

ທົບທວນເອກະສານ ແລະ ບົດຄົ້ນຄວ້າທີ່ກ່ຽວຂ້ອງ

2.1. ທົບທວນເອກະສານ

2.1.1. ເຄື່ອງດົນຕີຜື້ນເມືອງລາວ

ເຄື່ອງດົນຕີຜື້ນເມືອງລາວແມ່ນມໍລະດົກທາງວັດທະນະທຳທີ່ສຳຄັນຂອງປະເທດລາວ, ເຊິ່ງເປັນສິ່ງທີ່ສະທ້ອນໃຫ້ເຫັນເຖິງເອກະລັກ ແລະ ປະຫວັດສາດອັນຍາວນານຂອງວັດທະນະທຳລາວ. ເຄື່ອງດົນຕີເຫຼົ່ານີ້ບໍ່ພຽງແຕ່ເປັນເຄື່ອງມືສຳລັບສ້າງສຽງດົນຕີເທົ່ານັ້ນ, ແຕ່ຍັງເປັນສ່ວນໜຶ່ງຂອງພິທີກຳທາງສາສະໜາ, ງານສະຫຼອງ ແລະ ກິດຈະກຳທາງສັງຄົມຕ່າງໆ. ໃນພາກນີ້, ພວກຂ້າພະເຈົ້າຈະສຶກສາກ່ຽວກັບເຄື່ອງດົນຕີຜື້ນເມືອງລາວທີ່ສຳຄັນທັງ 6 ຊະນິດທີ່ຈະນຳໃຊ້ໃນໂຄງການນີ້.

1) ແຄນ (Khean)

ແຄນແມ່ນເຄື່ອງດົນຕີທີ່ຖືວ່າເປັນເຄື່ອງດົນຕີປະຈຳຊາດຂອງລາວ. ມັນຖືກສ້າງຂຶ້ນຈາກທໍ່ໄມ້ໄຜ່ຫຼາຍອັນທີ່ຖືກຕິດຕັ້ງດ້ວຍລິ້ນໂລຫະ. ແຄນມີຕົ້ນກຳເນີດຈາກເຂດຊົນນະບົດ ແລະ ມີຄວາມສຳພັນກັບເຄື່ອງດົນຕີປະເພດອື່ນໆທີ່ພົບເຫັນໃນເຂດອາຊີຕາເວັນອອກ ແລະ ອາຊີຕາເວັນອອກສຽງໃຕ້, ອາດມີຕົ້ນກຳເນີດມາຈາກເຄື່ອງດົນຕີຈີນທີ່ເອີ້ນວ່າ "sheng". ມັນຖືກນຳໃຊ້ເປັນເວລາຫຼາຍສະຕະວັດໃນລາວ ແລະ ພາກຕາເວັນອອກສຽງເໜືອຂອງໄທ (ອີສານ), ມັກຈະເຂົ້າຄູ່ກັບນັກຮ້ອງ (ໝໍລຳ) ໃນສະພາບແວດລ້ອມທາງສັງຄົມ ແລະ ພິທີກຳຕ່າງໆ. ດົນຕີແຄນເປັນສ່ວນສຳຄັນຂອງຊີວິດຄົນລາວ, ສົ່ງເສີມຄວາມສາມັກຄີໃນຄອບຄົວ ແລະ ສັງຄົມ.

UNESCO. (n.d.). ໃນປີ 2017, ແຄນລາວໄດ້ຖືກຂຶ້ນທະບຽນເປັນມໍລະດົກທາງວັດທະນະທຳທີ່ບໍ່ແມ່ນວັດຖຸຂອງມວນມະນຸດຈາກອົງການ UNESCO. ແຄນສາມາດສ້າງສຽງທີ່ອຸດົມສົມບູນດ້ວຍສຽງຄູ່ (polyphonic) ທີ່ມີທັງສຽງຜື້ນ (drone) ແລະ ສຽງທຳນອງ. ນັກດົນຕີຈະເປົ່າ ຫຼື ດຶງອາກາດຜ່ານກ່ອງລົມໃນຂະນະທີ່ປັດຮູ້ນື້ວຢູ່ທໍ່ໄມ້ໄຜ່ເພື່ອສ້າງລະດັບສຽງທີ່ແຕກຕ່າງກັນ. ສຽງສາມາດທັງນຸ່ມນວນ ແລະ ມີຊີວິດຊີວາ, ຂຶ້ນກັບວິທີການຫຼິ້ນ ແລະ ໄລ (lai) ຫຼື ໂໜດ (mode) ສະເພາະທີ່ໃຊ້.




ຮູບທີ 2.1 ເຄື່ອງດົນຕີລາວແຄນ (ມະນີຣັດ ວັດທະນະມົງຄົນ, 2013)

2) ຊໍອູ້ (So U)

ຊໍອູ້ແມ່ນເຄື່ອງດົນຕີສາຍແບບໃຊ້ຄັນຊັກທີ່ມີຕົ້ນກຳເນີດໃນລາວ ແລະ ໄທ. ມັນມີສຽງຕໍ່າກວ່າຊໍດ້ວງ ແລະ ເປັນເຄື່ອງດົນຕີໃນຕະກູນຊໍທີ່ມີສຽງຕໍ່າທີ່ສຸດ. ຫຼັກຖານຊໍໃຫ້ເຫັນວ່າການອອກແບບຂອງມັນອາດຈະໄດ້ຮັບການດັດແປງຈາກເຄື່ອງດົນຕີສາຍສອງເສັ້ນຂອງຈີນທີ່ເອີ້ນວ່າ "ຮູຮູ" (hu hu), ອາດຈະໃນຊ່ວງຕົ້ນສະໄໝກຸງເທບ (ປະມານປີ 1782) ຫຼື ປາຍສະໄໝອະຍຸທະຍາ. ພາຍໃນຊ່ວງທ້າຍຂອງສະຕະວັດທີ 19, ມັນຖືກລວມເຂົ້າໃນວົງປີຟາດໄມ້ນວມ. ຊໍ "ຊໍອູ້" ມາຈາກສຽງລັກສະນະສະເພາະທີ່ຄົນໄທເຊື່ອມໂຍງກັບມັນ.

ຊໍອູ້ມີສຽງທີ່ເລິກ, ແລະ ນຸ້ມນວນ. ມັນຖືກໃຊ້ເລື້ອຍໆເພື່ອເປັນຜືນຖານຂອງວົງດົນຕີ, ໂດຍສະເພາະສໍາລັບທຳນອງທີ່ມີຈັງຫວະຊ້າຫາປານກາງ. ກ່ອງສຽງທີ່ເຮັດຈາກໝາກຝາວປະກອບສ່ວນໃຫ້ເກີດສຽງກ້ອງສະເພາະຕົວຂອງມັນ.



ຮູບທີ 2.2 ເຄື່ອງດົນຕີລາວຊໍອູ້ ((Wikipedia, 2024)

3) ຊິ່ງ (Sing)

ໃນບໍລິບົດຂອງດົນຕີລາວ, "ຊິ່ງ" ໝາຍເຖິງເຄື່ອງທີ່ໃຊ້ເພື່ອສ້າງຈັງຫວະ. ໃນວົງເຊບໃຫຍ່ (ວົງດົນຕີຜືນເມືອງລາວ), ມີແຜ່ນສອງຊຸດ (ຊິ່ງ, ຄ້າຍຄື ໄທຫຼື "ຈິ່ງ") ທີ່ຖືກລວມເຂົ້າເປັນເຄື່ອງດົນຕີທີ່ເນັ້ນຈັງຫວະ. ຊິ່ງມີປະຫວັດສາດອັນຍາວນານໃນຫຼາຍວັດທະນະທຳ ແລະ ການໃຊ້ຊິ່ງໃນດົນຕີຜືນເມືອງລາວເປັນສ່ວນໜຶ່ງຂອງປະເພນີວົງເຄື່ອງດົນຕີ.

ຊິ່ງສ້າງສຽງທີ່ແຈ້ງກະຈ່າງ, ກະທົບ ແລະ ກ້ອງທີ່ໃຊ້ເພື່ອກຳນົດວົງຈອນຂອງຈັງຫວະ ແລະ ເນັ້ນຈຸດສໍາຄັນໃນດົນຕີ. ສຽງສະເພາະຂຶ້ນກັບຂະໜາດ, ຄວາມໜາ ແລະ ໂລຫະປະສົມຂອງຊິ່ງ ເຊັ່ນດຽວກັບວິທີການຕີ.



ຮູບທີ 2.3 ເຄື່ອງດົນຕີລາວຊິ່ງ (Rajadamnern Stadium, 2025)

4) ຝິນ (Pin)

ຝິນແມ່ນເຄື່ອງດົນຕີປະເພດລູດທີ່ມີຮູບຮ່າງຄ້າຍຄືໝາກສາລີ, ມີຕົ້ນກຳເນີດໃນລາວ ແລະ ພາກອີສານຂອງໄທ ສ່ວນໃຫຍ່ຫຼິ້ນໂດຍຄົນເຊື້ອຊາດລາວໃນໄທ ແລະ ລາວ. ໂດຍທົ່ວໄປ, ມັນມີສາຍໂລຫະສອງຫຼືສາມເສັ້ນທີ່ຖືກຂົງຜ່ານຄໍທີ່ມີເຟຣັດ ແລະ ຖືກຕິດດ້ວຍວິ ຫຼື ປີກ. ມັນມັກຈະຫຼິ້ນຄູ່ກັບແຄນໃນດົນຕີໝໍລຳ ແລະ ລູກທຸ່ງ. ໂຕ ແລະ ຄໍມັກຈະຖືກແກະສະຫຼັກຈາກໄມ້ທ່ອນດຽວ.

ຝິນສ້າງສຽງທີ່ແຈ້ງ, ແຫລມ, ທີ່ມີສຽງສັ້ນພໍສົມຄວນ. ສຽງຂອງມັນເປັນລັກສະນະສະເພາະຂອງດົນຕີໝໍລຳ ແລະ ລູກທຸ່ງ, ໃຫ້ການປະກອບຈັງຫວະ ແລະ ທຳນອງໃຫ້ກັບສຽງຮ້ອງ ແລະ ແຄນ.



ຮູບທີ 2.4 ເຄື່ອງດົນຕີລາວຝິນ (Academic Office of Roi Et Rajabhat University, n.d.)

5) ຄ້ອງວົງ (Khong Vong)

ຄ້ອງວົງໝາຍເຖິງຊຸດຄ້ອງທີ່ຈັດວາງໃນກອບວົງມົນ. ເຄື່ອງດົນຕີປະເພດນີ້ມີຮູບແບບຕ່າງໆໃນທົ່ວອາຊີຕາເວັນອອກສຽງໃຕ້. ໃນວົງດົນຕີຄລາສສິກລາວ (ເຊບໃຫຍ່), ໂດຍທົ່ວໄປມີຊຸດຄ້ອງ (ຄ້ອງວົງ) ສອງຊຸດ. ວົງຄ້ອງເຫຼົ່ານີ້ອາດມີຕົ້ນກຳເນີດບູຮານ, ພັດທະນາຜ່ານຫຼາຍສະຕະວັດ ແລະ ຖືກລວມເຂົ້າໃນດົນຕີລາຊະອານະຈັກ ແລະ ດົນຕີປະກອບພິທີກຳ.

ຄ້ອງວົງສ້າງສຽງຄ້ອງທີ່ປັບລະດັບສຽງຊຶ່ງສາມາດສ້າງທັງຮູບແບບທຳນອງ ແລະ ຈັງຫວະ. ສຽງກ້ອງ ແລະ ລະດັບສຽງຂອງຄ້ອງແຕ່ລະໜ່ວຍຂຶ້ນກັບຂະໜາດ ແລະ ວັດສະດຸທີ່ໃຊ້ (ໂດຍທົ່ວໄປແມ່ນທອງແດງຫຼືທອງເຫຼືອງ). ໃນວົງດົນຕີ, ຄ້ອງວົງສອງຊຸດ (ຊຸດໜຶ່ງສຽງສູງກວ່າ, ອີກຊຸດສຽງຕໍ່າກວ່າ) ຮ່ວມກັນສ້າງທຳນອງ ແລະ ລວດລາຍທີ່ຊັບຊ້ອນ.



ຮູບທີ 2.5 ເຄື່ອງດົນຕີລາວຄ້ອງວົງ (ຄູຕຸ້ຍ, 2017)

6) ລະນາດ (Ranad)

ລະນາດແມ່ນຄຳທົ່ວໄປສຳລັບເຄື່ອງດົນຕີປະເພດເຄາະທີ່ມີຮູບຄືບອດໃນດົນຕີລາວ. ໄມ້ຕີສາມາດເຮັດຈາກໄມ້ແຂງຫຼືໄມ້ໄຜ່ (ລະນາດເອກ ແລະ ລະນາດທຸ່ມ), ໂລຫະ (ລະນາດເອກເຫຼັກ ແລະ ລະນາດທຸ່ມເຫຼັກ), ຫຼືບາງຄັ້ງກໍ່ເຮັດຈາກແກ້ວ (ລະນາດແກ້ວ). ຮູບແບບດັ້ງເດີມທີ່ສຸດໄດ້ວິວັດທະນາຈາກເຄື່ອງດົນຕີແບບງ່າຍໆທີ່ໃຊ້ຮັກສາຈັງຫວະ ໄປເປັນຊຸດໄມ້ທີ່ປັບລະດັບສຽງ.

ສຽງຂອງລະນາດແຕກຕ່າງກັນໄປຂຶ້ນກັບວັດສະດຸຂອງໄມ້ຕີ ແລະ ໄມ້ທີ່ໃຊ້. ໄມ້ສ້າງສຽງທີ່ສົດໃສ, ແລະກະທົບ, ໃນຂະນະທີ່ໂລຫະມີສຽງທີ່ແຈ້ງກະຈ່າງ, ກ້ອງກວ່າ. ໄມ້ຕີຕ່າງໆ (ແຂງຫຼືນຸ່ມ) ຖືກໃຊ້ເພື່ອໃຫ້ໄດ້ສື່ສຽງທີ່ແຕກຕ່າງກັນ. ລະນາດເອກໂດຍທົ່ວໄປຫຼິ້ນທຳນອງຫຼັກດ້ວຍສຽງທີ່ຄົມ ແລະ ແຈ້ງຊັດ, ໃນຂະນະທີ່ລະນາດທຸ່ມໃຫ້ສຽງທີ່ຕຳກວ່າ, ມັກຈະເປັນທຳນອງປະກອບ.



ຮູບທີ 2.6 ເຄື່ອງດົນຕີລາວລະນາດ (Wikipedia, 2025)

2.1.2. ພື້ນຖານທິດສະດີຂອງໂຄງຂ່າຍປະສາດທຽມເຊິງເລິກ (Deep Neural Networks)


ຄວາມໝາຍຫຼັກຂອງ Deep learning ແທ້ຈິງແລ້ວແມ່ນ artificial Neural Network (ANN) ທີ່ຢູ່ໃນຮູບແບບການຕໍ່ກັນເລິກໆຫຼາຍໆຊັ້ນ (Layer), ແນວຄວາມຄິດນີ້ແມ່ນມີຮາກຖານມາຈາກທຳມະຊາດ, ກໍຄືໃນສະໝອງຂອງສິ່ງທີ່ມີຊີວິດນັ້ນຈະມີເຊວປະສາດທີ່ມີຄວາມຊັບຊ້ອນຫຼາຍ ມັນສົ່ງຖ່າຍສັນຍານປະສາດ ແລ້ວສົ່ງຜົນໄດ້ຮັບອອກມາ (ຄຳສະໄໝ ໄຊຍະວົງ, 2022)

ການຮຽນຮູ້ເຊິງເລິກ (Deep Learning) ແມ່ນເຕັກນິກການຮຽນຮູ້ຂອງເຄື່ອງ (Machine Learning) ທີ່ນຳໃຊ້ໂຄງຂ່າຍປະສາດທຽມຫຼາຍຊັ້ນເພື່ອການວິເຄາະຂໍ້ມູນທີ່ຊັບຊ້ອນ. ໃນຊ່ວງປີທີ່ຜ່ານມາ, ວິທີການນີ້ໄດ້ກາຍເປັນມາດຕະຖານຄຳໃນຊຸມຊົນການຮຽນຮູ້ຂອງເຄື່ອງຈັກ, ສາມາດບັນລຸຜົນລັບທີ່ໂດດເດັ່ນໃນຫຼາຍໆວຽກງານທີ່ຊັບຊ້ອນ ແລະ ໃນບາງກໍລະນີສາມາດເອົາຊະນະຄວາມສາມາດຂອງມະນຸດໄດ້ (Khan et al., 2020).

1) ໂຄງຂ່າຍປະສາດທຽມແບບເລິກ (Deep Neural Networks - DNN)

ໂຄງຂ່າຍປະສາດທຽມແບບເລິກ (DNN) ແມ່ນໂຄງຂ່າຍປະສາດທຽມທີ່ມີຢ່າງໜ້ອຍສາມຫຼັກຫຼາຍຊັ້ນ ເຊື່ອງ (hidden layer) ລະຫວ່າງຊັ້ນຮັບຂໍ້ມູນເຂົ້າ (input layer) ແລະຊັ້ນຂໍ້ມູນອອກ (output layer). ໂຄງສ້າງພື້ນຖານຂອງ DNN ປະກອບດ້ວຍໜ່ວຍປະສາດທຽມທີ່ເຊື່ອມຕໍ່ກັນຢ່າງເຕັມຮູບແບບລະຫວ່າງຊັ້ນຕ່າງໆ,

ໂດຍແຕ່ລະການເຊື່ອມຕໍ່ມີຄ່າຖ່ວງນ້ຳໜັກ (weight) ທີ່ສາມາດປັບປຸງໄດ້ໃນລະຫວ່າງການຮຽນຮູ້ (O'Shea & Nash, 2015).



ຮູບທີ 2.7 ສະແດງໂຄງສ້າງຜືນຖານຂອງໂຄງຂ່າຍປະສາດທຽມແບບເລິກ (AltexSoft Team, 2021)

ຫຼັກການການເຮັດວຽກຂອງເຄືອຂ່າຍປະສາດທຽບຈະເລີ່ມຈາກຊັ້ນນຳເຂົ້າ (Input layer) ຂໍ້ມູນມາຈາກພາຍນອກ ແຕ່ລະNode ໃນຊັ້ນນຳເຂົ້າ (Input layer) ຈະສົ່ງຂໍ້ມູນໄປໃຫ້ Node ອື່ນໆຢູ່ໃນຊັ້ນເຊື່ອງ (hidden layer) ແລະ ພາຍໃນຊັ້ນເຊື່ອງນີ້ຈະນຳເອົາຂໍ້ມູນນຳເຂົ້າທຸກໂຕມາຄູນກັບຄ່າຖ່ວງໜັກ (weight) ຂອງໂຕມັນເອງຫຼັງຈາກຄູນຄົບທຸກ Node ກໍຈະນຳຜົນທັງໝົດມາລວມກັນ (sum) ຈາກນັ້ນກໍເອົາຜົນລວມມາບວກໃຫ້ກັບຄ່າໄບແອດ ດັ່ງສົມຜົນ 2.1 ຈາກນັ້ນກໍເອົາຜົນໄດ້ຮັບໄປເຂົ້າສູ່ Activation Function ເຊິ່ງມີຫຼາຍສົມຜົນ, ເຊິ່ງສົມຜົນທີ່ພົບເຫັນຫຼາຍສຸດໄດ້ແກ່ Sigmoid (ສົມຜົນ 2.2), Tanh (ສົມຜົນ 2.3) , ReLu (ສົມຜົນ 2.4). ຜົນໄດ້ຮັບຈາກ Activation Function ຈະຖືກສົ່ງໄປຊັ້ນຕໍ່ໄປອາດຈະເປັນຊັ້ນເຊື່ອງອີກຊັ້ນ (hidden layer) ຫຼື ຈະເປັນຊັ້ນສົ່ງອອກ (output layer) ກໍໄດ້ຂຶ້ນກັບຄວາມຊັບຊ້ອນຂອງເຄືອຂ່າຍປະສາດທຽມແບບເລິກ.

$$z = \sum_{i=1}^N (w_i \cdot x_i) + b \quad (2.1)$$

z ແມ່ນຄ່າຜົນລວມຂອງການຖ່ວງນ້ຳໜັກທັງໝົດ.

i ແມ່ນລຳດັບຂອງອິນພຸດໃນຊັ້ນນຳເຂົ້າ.

N ແມ່ນຈຳນວນຂອງອິນພຸດນຳເຂົ້າໃນຊັ້ນນຳເຂົ້າ.

w_i ແມ່ນຄ່າຖ່ວງນ້ຳໜັກຈາກ Node ລຳດັບທີ i

x_i ແມ່ນຄ່າອິນພຸດຈາກຊັ້ນນຳເຂົ້າ (Input)

b ແມ່ນຄ່າໄບແອດ

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (2.2)$$

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \quad (2.3)$$

$$\text{ReLU}(z) = \max(0, z) \quad (2.4)$$

ໂຄງຂ່າຍປະສາດທຽມແບບເລິກມີຄຸນລັກສະນະສໍາຄັນດັ່ງນີ້:

ກ. ໂຄງສ້າງຫຼາຍຊັ້ນ (Multilayer Architecture)

DNN ປະກອບດ້ວຍຊັ້ນຮັບຂໍ້ມູນເຂົ້າ, ຊັ້ນເຊື່ອງຫຼາຍຊັ້ນ, ແລະຊັ້ນຂໍ້ມູນອອກ. ຍິ່ງມີຈຳນວນຊັ້ນຫຼາຍ, ໂຄງຂ່າຍປະສາດທຽມກໍ່ສາມາດຮຽນຮູ້ຮູບແບບທີ່ຊັບຊ້ອນຂຶ້ນ (Vakalopoulou et al., 2023).

ຂ. ຝັງຊັ້ນເຮັດໃຫ້ບໍ່ເປັນເສັ້ນຊື່ (Non-linear Activation Functions)

ແຕ່ລະໜ່ວຍປະສາດທຽມໃນ DNN ນຳໃຊ້ຝັງຊັ້ນເຮັດໃຫ້ບໍ່ເປັນເສັ້ນຊື່ເຊັ່ນ: ReLU (Rectified Linear Unit), Sigmoid, ຫຼື Tanh ເພື່ອສາມາດຮຽນຮູ້ຄວາມສໍາພັນທີ່ບໍ່ເປັນເສັ້ນຊື່ລະຫວ່າງຂໍ້ມູນເຂົ້າແລະຂໍ້ມູນອອກ (Sufian et al., 2020).

ຄ. ການເຮັດໃຫ້ກວມລວມ (Generalization)

DNN ມີຄວາມສາມາດໃນການເຮັດໃຫ້ກວມລວມຂໍ້ມູນທີ່ບໍ່ເຄີຍເຫັນມາກ່ອນ, ເຊິ່ງເຮັດໃຫ້ເໝາະສົມກັບການຈຳແນກປະເພດຂໍ້ມູນ (classification) ແລະການທຳນາຍ (prediction) (Khan et al., 2020).


ງ. ການຮຽນຮູ້ຄຸນລັກສະນະອັດຕະໂນມັດ (Automatic Feature Learning)

DNN ສາມາດຮຽນຮູ້ຄຸນລັກສະນະທີ່ສໍາຄັນຈາກຂໍ້ມູນດິບໄດ້ໂດຍອັດຕະໂນມັດ, ຫຼຸດຄວາມຈຳເປັນໃນການອອກແບບຄຸນລັກສະນະດ້ວຍຕົນເອງ (O'Shea & Nash, 2015).

ໃນການປະຍຸກໃຊ້ DNN ສໍາລັບການວິເຄາະສຽງ, ຂໍ້ມູນສຽງຈະຖືກແປງໃຫ້ເປັນຄຸນລັກສະນະຕ່າງໆເຊັ່ນ: MFCC (Mel-frequency cepstral coefficients) ຫຼື Mel-spectrogram ກ່ອນທີ່ຈະນຳເຂົ້າສູ່ໂຄງຂ່າຍປະສາດທຽມ. ການນຳໃຊ້ DNN ສໍາລັບການຈຳແນກປະເພດສຽງນັ້ນສາມາດໃຫ້ຜົນລັບທີ່ດີ, ແຕ່ມີຂໍ້ຈຳກັດໃນດ້ານການຈັບຄວາມສໍາພັນທາງດ້ານເວລາ (temporal relationships) ແລະ ລັກສະນະທາງດ້ານພື້ນທີ່ (spatial characteristics) ຂອງຂໍ້ມູນສຽງ (Piczak, 2015).

2) ໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ (Convolutional Neural Networks - CNN)

ໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ (CNN) ແມ່ນປະເພດຂອງໂຄງຂ່າຍປະສາດທຽມເລິກທີ່ໄດ້ຮັບການອອກແບບສະເພາະສໍາລັບການປະມວນຜົນຂໍ້ມູນທີ່ມີໂຄງສ້າງແບບຕາຕະລາງເຊັ່ນ: ຮູບພາບ ຫຼື spectrogram. CNN ມີຄວາມແຕກຕ່າງຈາກ DNN ໃນຫຼາຍດ້ານ, ໂດຍມີຄຸນລັກສະນະພິເສດຄື ການນຳໃຊ້ຊັ້ນຄອນໂວລູຊັນ (convolution layers) ແລະຊັ້ນການ pooling (pooling layers) (Krizhevsky et al., 2012).



ຮູບທີ 2.8 ໂຄງສ້າງພື້ນຖານຂອງໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ (Shamik Tiwari et.al, 2021)

ຫຼັກການການເຮັດວຽກຂອງເຄືອຂ່າຍປະສາດທຽມແບບ Convolutional (CNN) ຈະເລີ່ມຈາກການນຳເຂົ້າຂອງຮູບພາບໃນຮູບແບບເມທຣິກ 3 ມິຕິ (Width × Height × Channel) ເຂົ້າສູ່ຊັ້ນນຳເຂົ້າ (Input layer). ຫຼັງຈາກນັ້ນແຕ່ລະ Pixel ຂອງຮູບພາບຈະຖືກປະມວນຜົນໂດຍຊັ້ນ Convolution ເຊິ່ງເປັນການໃຊ້ຕົວກອງ (kernel/filter) ຂະໜາດ $m \times n$ ເລື່ອນໄປທົ່ວພາບເພື່ອຄຳນວນຄ່າ feature map ໂດຍໃຊ້ຫຼັກການຄູນແບບປະສານ. ໃນແຕ່ລະຕຳແໜ່ງຂອງການເລື່ອນຕົວກອງຈະມີການຄຳນວນດັ່ງສົມຜົນ 2.5:

$$z = \sum_i \sum_j (k_{ij} \cdot x_{ij}) + b \quad (2.5)$$

z ແມ່ນຄ່າຜົນລວມຂອງການຄຳນວນຂອງຕົວກອງໃນຕຳແໜ່ງນັ້ນ.

k_{ij} ແມ່ນຄ່າຂອງນ້ຳໜັກໃນຕົວກອງທີ່ຕຳແໜ່ງ i, j

x_{ij} ແມ່ນຄ່າ pixel ຂອງຮູບພາບນຳເຂົ້າທີ່ຕຳແໜ່ງ i, j

b ແມ່ນຄ່າໄບແອດ

ຫຼັງຈາກຜ່ານຊັ້ນ Convolution ແລ້ວ ຄ່າທີ່ໄດ້ຈະຖືກສົ່ງຜ່ານຝັງຊັນກະຕຸ້ນ (Activation Function) ເຊັ່ນ ReLU ດັ່ງສົມຜົນ 2.4 ເພື່ອເພີ່ມຄວາມບໍ່ເປັນເສັ້ນຊື່ໃຫ້ລະບົບ. ຕໍ່ມາ ຄ່າເຫຼົ່ານີ້ຈະຖືກສົ່ງໄປຍັງຊັ້ນ Pooling ເຊິ່ງຈະຫຼຸດຂະໜາດຂອງຂໍ້ມູນລົງ ໂດຍຈະເລືອກເອົາຄ່າທີ່ເໝາະສົມຈາກແຕ່ລະພື້ນທີ່ນ້ອຍໆ, ເຊັ່ນ:

$$\text{Max Pooling: output} = \max(z_1, z_2, \dots, z_n) \quad (2.6)$$

$$\text{Average Pooling: output} = \frac{z_1 + z_2 + \dots + z_n}{n} \quad (2.7)$$

ການຊ້ອນຊ້ັນ Convolution ແລະ Pooling ຫຼາຍຊັ້ນຊ້ອນກັນຈະຊ່ວຍໃຫ້ລະບົບສາມາດຮຽນຮູ້ລັກສະນະທີ່ຊັບຊ້ອນຂຶ້ນເລື້ອຍໆ. ຫຼັງຈາກຜ່ານຊັ້ນກຳນົດລັກສະນະຄົບແລ້ວ, ຂໍ້ມູນ Feature Map ຈະຖືກປ່ຽນໃຫ້ເປັນເວັກເຕີ 1 ມິຕິໂດຍຊັ້ນປັບໃຫ້ແບບລາບ (Flatten) ແລ້ວສົ່ງໄປຫາຊັ້ນເຊື່ອມຕໍ່ເຕັມ (Fully Connected Layer) ເຊິ່ງຈະທຳງານຄ້າຍຄືກັບເຄືອຂ່າຍປະສາດທຽມແບບທົ່ວໄປ. ສຸດທ້າຍຜົນລັບທີ່ໄດ້ຈາກ

ຊັ້ນສຸດທ້າຍຈະຖືກສົ່ງໄປຍັງຊັ້ນສົ່ງອອກ (Output Layer) ເຊິ່ງຈະໃຊ້ຝັງຊັ້ນທີ່ເໝາະສົມກັບງານ ເຊັ່ນ Softmax ສໍາລັບການຈຳແນກຫຼາຍກຸ່ມ ຫຼື Sigmoid ສໍາລັບການຈຳແນກສອງກຸ່ມ.

ຄຸນລັກສະນະສໍາຄັນຂອງ CNN ປະກອບດ້ວຍ:

ກ. ຊັ້ນຄອນໂວລູຊັນ (Convolutional Layers)

ຊັ້ນນີ້ນຳໃຊ້ການດຳເນີນການຄອນໂວລູຊັນ (convolution operation) ເພື່ອສະກັດຄຸນລັກສະນະ ຈາກຂໍ້ມູນໂດຍການນຳໃຊ້ເຕັກນິກການແບ່ງປັນພາຣາມິເຕີ (parameter sharing) ແລະການເຊື່ອມຕໍ່ແບບ local (local connectivity). ນີ້ເຮັດໃຫ້ CNN ສາມາດຈັບຄຸນລັກສະນະທາງດ້ານພື້ນທີ່ (spatial features) ໄດ້ຢ່າງມີປະສິດທິພາບ (Sufian et al., 2020).

ຂ. ຊັ້ນ Pooling

ຊັ້ນນີ້ມີໜ້າທີ່ຫຼຸດຂະໜາດຂອງຂໍ້ມູນ (downsample) ໂດຍການເລືອກຄ່າສູງສຸດ (max pooling) ຫຼື ຄ່າສະເລ່ຍ (average pooling) ຈາກພື້ນທີ່ໃກ້ຄຽງ. ນີ້ເຮັດໃຫ້ໂຄງຂ່າຍມີຄວາມທົນທານຕໍ່ການປ່ຽນແປງ ຂອງຕຳແໜ່ງຂອງຄຸນລັກສະນະ (translation invariance) ແລະຫຼຸດຈຳນວນພາຣາມິເຕີທີ່ຕ້ອງຮຽນຮູ້ (Vakalopoulou et al., 2023).

ຄ. ການແບ່ງປັນພາຣາມິເຕີ (Parameter Sharing)

CNN ນຳໃຊ້ filter ດຽວກັນໃນທຸກຕຳແໜ່ງຂອງຂໍ້ມູນເຂົ້າ, ເຊິ່ງຫຼຸດຈຳນວນພາຣາມິເຕີທີ່ຕ້ອງຮຽນຮູ້ຢ່າງຫຼວງຫຼາຍເມື່ອທຽບກັບ DNN (Wu, 2017).

ງ. ຄວາມທົນທານຕໍ່ການປ່ຽນແປງ (Invariance Properties)

CNN ມີຄວາມທົນທານຕໍ່ການປ່ຽນແປງຂອງຕຳແໜ່ງ, ຂະໜາດ, ແລະມຸມມອງຂອງຄຸນລັກສະນະ, ເຊິ່ງເປັນປະໂຫຍດສໍາລັບການຈຳແນກຮູບພາບ ແລະສຽງ (O'Shea & Nash, 2015).

ຈ. ການຮຽນຮູ້ຄຸນລັກສະນະລຳດັບຊັ້ນ (Hierarchical Feature Learning)

CNN ຮຽນຮູ້ຄຸນລັກສະນະຈາກລະດັບພື້ນຖານ (ເຊັ່ນ: ເສັ້ນ ແລະຂອບ) ໄປຫາລະດັບທີ່ຊັບຊ້ອນ ຂຶ້ນໃນຊັ້ນທີ່ລຶກຂຶ້ນ (Gu et al., 2018).

ໃນການນຳໃຊ້ CNN ສໍາລັບການຈຳແນກປະເພດສຽງ, ຂໍ້ມູນສຽງມັກຈະຖືກແປງເປັນຮູບແບບ spectrogram ເພື່ອໃຫ້ສາມາດນຳໃຊ້ CNN ທີ່ໄດ້ຮັບການອອກແບບສໍາລັບການປະມວນຜົນຮູບພາບໄດ້. ການແປງຂໍ້ມູນສຽງເປັນ Mel-spectrogram ຫຼື MFCC spectrogram ເຮັດໃຫ້ CNN ສາມາດຈັບລັກສະນະຂອງສຽງໃນຮູບແບບທີ່ເປັນພື້ນທີ່ 2 ມິຕິໄດ້ຢ່າງມີປະສິດທິພາບ (Piczak, 2015).

2.1.3. ການປຽບທຽບໂຄງຂ່າຍປະສາດທຽມແບບເລີກ (DNN) ແລະ ໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັ້ນ (CNN)

ເຖິງແມ່ນວ່າທັງ DNN ແລະ CNN ຈະເປັນປະເພດຂອງໂຄງຂ່າຍປະສາດທຽມເລີກ, ແຕ່ທັງສອງມີຄວາມແຕກຕ່າງກັນໃນຫຼາຍດ້ານທີ່ສໍາຄັນ, ໂດຍສະເພາະແມ່ນເນື່ອງມາໃຊ້ສໍາລັບການຈຳແນກປະເພດສຽງ.

1) ໂຄງສ້າງແລະການອອກແບບ

DNN ມີໂຄງສ້າງທີ່ປະກອບດ້ວຍຊັ້ນທີ່ເຊື່ອມຕໍ່ກັນຢ່າງເຕັມຮູບແບບ (fully connected layers), ເຊິ່ງໝາຍຄວາມວ່າແຕ່ລະໜ່ວຍປະສາດທຽມໃນຊັ້ນໜຶ່ງຈະເຊື່ອມຕໍ່ກັບທຸກໜ່ວຍປະສາດທຽມໃນຊັ້ນຕໍ່ໄປ. ນີ້ເຮັດໃຫ້ DNN ມີຈຳນວນພາຣາມິເຕີຫຼາຍ, ໂດຍສະເພາະເມື່ອຂະໜາດຂອງຂໍ້ມູນເຂົ້າມີຂະໜາດໃຫຍ່ (Wu, 2017).

CNN ມີໂຄງສ້າງທີ່ປະກອບດ້ວຍຊັ້ນຄອນໂວລູຊັ້ນແລະຊັ້ນ pooling ທີ່ອອກແບບສະເພາະສໍາລັບການຈັບຄຸນລັກສະນະທາງດ້ານພື້ນທີ່. ການອອກແບບນີ້ນໍາໃຊ້ການເຊື່ອມຕໍ່ແບບທ້ອງຖິ່ນແລະການແບ່ງປັນພາຣາມິເຕີ, ເຊິ່ງເຮັດໃຫ້ CNN ມີຈຳນວນພາຣາມິເຕີໜ້ອຍກວ່າ DNN ທີ່ມີຂະໜາດທຽບເທົ່າກັນ (Gu et al., 2018).

2) ຄວາມສາມາດໃນການຈັບຄຸນລັກສະນະ

DNN ມີຄວາມສາມາດໃນການຈັບຄວາມສໍາພັນທີ່ຊັບຊ້ອນລະຫວ່າງຄຸນລັກສະນະຕ່າງໆໃນຂໍ້ມູນເຂົ້າ, ແຕ່ບໍ່ໄດ້ອອກແບບມາສະເພາະສໍາລັບການຈັບຄວາມສໍາພັນທາງດ້ານພື້ນທີ່. ໃນການວິເຄາະສຽງ, DNN ຕ້ອງອາໄສການສະກັດຄຸນລັກສະນະທີ່ອອກແບບມາເປັນພິເສດກ່ອນ ເຊັ່ນ MFCC ຫຼື Mel-spectrogram (Khan et al., 2020).

CNN ມີຄວາມສາມາດໃນການຈັບຄຸນລັກສະນະທາງດ້ານພື້ນທີ່ແລະຮູບແບບທີ່ເກີດຂຶ້ນໃນຂໍ້ມູນເຂົ້າໄດ້ຢ່າງມີປະສິດທິພາບ. ໃນການຈຳແນກປະເພດສຽງ, CNN ສາມາດຈັບລັກສະນະຂອງສຽງໃນ spectrogram ເຊັ່ນ: ຮູບແບບຄວາມຖີ່, ລັກສະນະການເບິ່ງສຽງ, ແລະການປ່ຽນແປງຂອງສຽງຕາມເວລາໄດ້ດີກວ່າ DNN (Piczak, 2015).

ຕາຕະລາງທີ 2.1: ການປຽບທຽບຄຸນລັກສະນະລະຫວ່າງ DNN ແລະ CNN

ຄຸນລັກສະນະ	DNN	CNN
ໂຄງສ້າງພື້ນຖານ	ຊັ້ນທີ່ເຊື່ອມຕໍ່ກັນຢ່າງເຕັມຮູບແບບ	ຊັ້ນຄອນໂວລູຊັ້ນ, ຊັ້ນ Pooling, ແລະຊັ້ນເຊື່ອມຕໍ່ເຕັມຮູບແບບ
ການເຊື່ອມຕໍ່	ເຊື່ອມຕໍ່ທຸກໜ່ວຍປະສາດທຽມລະຫວ່າງຊັ້ນ	ເຊື່ອມຕໍ່ແບບ local ໃນຊັ້ນຄອນໂວລູຊັ້ນ
ຈຳນວນພາຣາມິເຕີ	ສູງ	ຕໍ່າກວ່າ (ເນື່ອງຈາກການແບ່ງປັນພາຣາມິເຕີ)
ຄວາມສາມາດໃນການຈັບລັກສະນະທາງພື້ນທີ່	ຈຳກັດ	ສູງ
ຄວາມສາມາດໃນການຈຳແນກຂໍ້ມູນຮູບພາບຫຼື spectrogram	ຕໍ່າກວ່າ	ສູງກວ່າ

ຄວາມໄວໃນການຝຶກແບບຈຳລອງ	ຊ້າກວ່າສຳລັບຂໍ້ມູນຮູບພາບ ຫຼື spectrogram	ໄວກວ່າສຳລັບຂໍ້ມູນຮູບພາບຫຼື spectrogram
ຄວາມສາມາດໃນການປະມວນຜົນຂໍ້ ມູນລຳດັບເວລາ	ຕ້ອງການການດັດແປງເພີ່ມ ເຕີມ	ສາມາດຈັດການກັບຂໍ້ມູນ 1D ຫຼື 2D ທີ່ມີມິຕິຂອງເວລາ

3) ປະສິດທິພາບໃນການຈຳແນກສຽງເຄື່ອງດົນຕີ

ໃນການຈຳແນກປະເພດສຽງເຄື່ອງດົນຕີ, ທັງ DNN ແລະ CNN ໄດ້ຖືກນຳໃຊ້ຢ່າງແຜ່ຫຼາຍ, ແຕ່ຫຼາຍການສຶກສາໄດ້ສະແດງໃຫ້ເຫັນວ່າ CNN ມັກຈະມີປະສິດທິພາບສູງກວ່າ. ນີ້ເນື່ອງຈາກຄວາມສາມາດຂອງ CNN ໃນການຈັບລັກສະນະເສັ້ນສຽງ (spectral patterns) ໃນ spectrogram ທີ່ເປັນເອກະລັກສຳລັບເຄື່ອງດົນຕີແຕ່ລະຊະນິດ (Wang et al., 2021).

Piczak (2015) ໄດ້ນຳສະເໜີການຈຳແນກປະເພດສຽງແວດລ້ອມດ້ວຍໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ ແລະສະແດງໃຫ້ເຫັນວ່າ CNN ສາມາດໃຫ້ຄວາມແມ່ນຍຳທີ່ສູງກວ່າເຕັກນິກແບບດັ້ງເດີມ. ການສຶກສານີ້ໄດ້ນຳໃຊ້ CNN ທີ່ປະກອບດ້ວຍ 2 ຊັ້ນຄອນໂວລູຊັນ, 2 ຊັ້ນ max-pooling, ແລະ 2 ຊັ້ນເຊື່ອມຕໍ່ເຕັມຮູບແບບ (fully connected layers). ຜົນການທົດລອງສະແດງໃຫ້ເຫັນວ່າ CNN ສາມາດບັນລຸຄວາມແມ່ນຍຳທີ່ສູງກວ່າການນຳໃຊ້ MFCC ປະມານ 7.8% ໃນຊຸດຂໍ້ມູນ ESC-10 ແລະ 20.6% ໃນຊຸດຂໍ້ມູນ ESC-50 (Khan et al., 2020).

Khan et al. (2020) ໄດ້ນຳສະເໜີການທົບທວນຢ່າງຄົບຖ້ວນກ່ຽວກັບສະຖາປັດຕະຍະກຳຂອງ CNN ເລີ່ມຕັ້ງແຕ່ AlexNet ຈົນເຖິງ High-Resolution network (HR.Net). ການສຶກສານີ້ໄດ້ອະທິບາຍຮູບແບບຕ່າງໆຂອງໂຄງຂ່າຍປະສາດທຽມ ແລະ ນຳສະເໜີວິທີການເລືອກໂຄງສ້າງທີ່ເໝາະສົມສຳລັບແຕ່ລະປະເພດຂອງບັນຫາ.

Wang et al. (2021) ໄດ້ສະເໜີໂຄງຂ່າຍປະສາດທຽມແບບ CNN ທີ່ໃຊ້ຄວາມສົນໃຈທາງດ້ານເວລາແລະຄວາມຖີ່ (temporal-frequency attention) ສຳລັບການຈຳແນກສຽງແວດລ້ອມ. ວິທີການນີ້ມີປະສິດທິພາບໃນການຮຽນຮູ້ລັກສະນະທາງດ້ານເວລາແລະຄວາມຖີ່ຈາກ Log-Mel spectrogram. ຜົນການທົດລອງສະແດງໃຫ້ເຫັນວ່າການນຳໃຊ້ຄວາມສົນໃຈ (attention) ສາມາດປັບປຸງຄວາມແມ່ນຍຳຂອງການຈຳແນກໄດ້ຢ່າງມີນິຍາມສຳຄັນ.

Sufian et al. (2020) ໄດ້ນຳສະເໜີແນວຄິດພື້ນຖານຂອງໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ, ລວມທັງພື້ນຖານທຸລະກິດຂອງ CNN, ຄວາມກ້າວໜ້າໃນປັດຈຸບັນ, ແລະ ຂອບເຂດການນຳໃຊ້ທີ່ສຳຄັນ. ປົດຄວາມນີ້ໄດ້ອະທິບາຍລາຍລະອຽດກ່ຽວກັບອົງປະກອບຕ່າງໆຂອງ CNN ເຊັ່ນການດຳເນີນການຄອນໂວລູຊັນ, ການ pooling, ແລະຊັ້ນເຊື່ອມຕໍ່ເຕັມຮູບແບບ.

2.1.4. ການປະເມີນແບບຈຳລອງ (Model Evaluation)

1) Confusion Matrix

Confusion Matrix ເປັນເຄື່ອງມືສຳຄັນໃນການປະເມີນປະສິດທິພາບຂອງແບບຈຳລອງການຈຳແນກປະເພດ (classification model), ຂັ້ນຕອນນີ້ຈະຖືກນຳໃຊ້ພາຍຫຼັງການຝຶກສອນແບບຈຳລອງເພື່ອກວດສອບວ່າມີປະສິດທິພາບດີພໍທີ່ຈະເອົາໄປນຳໃຊ້ແລ້ວບໍ່. ຈຸດຕັດລະຫວ່າງແຖວຕັ້ງ ແລະ ແຖວນອນຈະບອກຈຳນວນກໍລະນີທີ່ແບບຈຳລອງທຳນາຍຖືກ ຫຼື ຜິດ. ຈາກ confusion matrix ເຮົາສາມາດຄຳນວນຄ່າວັດແທກທີ່ສຳຄັນ

ຕ່າງໆເຊັ່ນ: precision, recall, F1-score ແລະ ຄວາມແມ່ນຍຳ (accuracy) ເພື່ອປະເມີນປະສິດທິພາບຂອງ ແບບຈຳລອງໃນມຸມມອງທີ່ແຕກຕ່າງກັນ.

Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

ຮູບທີ 2.9 Confusion Matrix (Shamik Tiwari et.al, 2021)

2) ຄ່າວັດແທກໃນການປະເມີນຜົນແບບຈຳລອງ

ກ. ຄວາມແມ່ນຍຳ (Accuracy)

ຄວາມແມ່ນຍຳເປັນຄ່າວັດແທກທີ່ໃຊ້ກັນແຜ່ຫຼາຍທີ່ສຸດໃນການຈຳແນກປະເພດ, ອະທິບາຍເຖິງອັດຕາສ່ວນຂອງການທຳນາຍທີ່ຖືກຕ້ອງເມື່ອທຽບກັບຈຳນວນຕົວຢ່າງທັງໝົດ. ມັນຖືກຄຳນວນໂດຍສູດ:

$$\frac{TP + TN}{TP + TN + FP + FN} \quad (2.8)$$

- *True Positive (TP)* ຄື ຕາມທີ່ທາຍວ່າແມ່ນ ແລ້ວກໍຖືກແທ້ (Hit)
- *True Negative (TN)* ຄື ຕາມທີ່ທາຍວ່າແມ່ນ ແລ້ວບໍ່ແມ່ນແທ້ (Correct Rejection)
- *False Positive (FP)* ຄື ຕາມທີ່ທາຍວ່າແມ່ນ ແຕ່ແທ້ຈິງແລ້ວບໍ່ແມ່ນ (False Alarm, Type I error)
- *False Negative (FN)* ຄື ຕາມທີ່ທາຍວ່າບໍ່ແມ່ນ ແຕ່ແທ້ຈິງແລ້ວແມ່ນແມ່ນ (Miss, Type II error)
- *Condition Positive (P)* ແມ່ນຈຳນວນທີ່ຖືກທີ່ຖືກທັງໝົດຢູ່ໃນຮູບ = $TP + FN$
- *Condition Negative (N)* ແມ່ນຈຳນວນທີ່ຖືກທີ່ຖືກທັງໝົດຢູ່ໃນຮູບ = $FP + TN$

ຂ. Precision (ຄວາມແມ່ນຍຳໃນການທຳນາຍດ້ານບວກ)

Precision ເປັນຕົວວັດແທກຄວາມແມ່ນຍຳໃນການທຳນາຍຜົນດ້ານບວກຂອງແບບຈຳລອງການຈຳແນກ, ຄິດໄລ່ໂດຍການຫາອັດຕາສ່ວນຂອງການທຳນາຍຜົນດ້ານບວກທີ່ຖືກຕ້ອງ (TP) ຕໍ່ຈຳນວນການທຳນາຍຜົນດ້ານບວກທັງໝົດ ($TP + FP$).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.9)$$

ມັນສະແດງເຖິງຄວາມສາມາດຂອງແບບຈຳລອງໃນການຫຼີກລ້ຽງການທຳນາຍຜິດພາດດ້ານບວກ, ເຊິ່ງມີຄວາມສຳຄັນໃນກໍລະນີທີ່ຕ້ອງການຄວາມເຊື່ອຖືສູງໃນຜົນທຳນາຍດ້ານບວກ. ຕົວຢ່າງ: ໃນລະບົບວິນິດໄສພະຍາດ, Precision ສູງໝາຍຄວາມວ່າເມື່ອລະບົບທຳນາຍວ່າຄົນເຈັບມີພະຍາດ, ພວກເຂົາມີແນວໂນ້ມສູງທີ່ຈະມີພະຍາດນັ້ນຈິງ.

ຄ. Recall (ຄວາມອ່ອນໄຫວ ຫຼື Sensitivity)

Recall ຫຼື Sensitivity ເປັນຕົວວັດແທກຄວາມສາມາດຂອງແບບຈຳລອງໃນການຈຳແນກກໍລະນີດ້ານບວກທີ່ແທ້ຈິງທັງໝົດ, ຄິດໄລ່ໂດຍການຫາອັດຕາສ່ວນຂອງກໍລະນີດ້ານບວກທີ່ທຳນາຍຖືກຕ້ອງ (TP) ຕໍ່ກໍລະນີດ້ານບວກທີ່ແທ້ຈິງທັງໝົດ (TP + FN).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.10)$$

ຄ່ານີ້ວັດແທກຄວາມອ່ອນໄຫວຂອງແບບຈຳລອງໃນການພົບກໍລະນີດ້ານບວກທຸກກໍລະນີ, ເຊິ່ງສຳຄັນຫຼາຍໃນກໍລະນີທີ່ຕ້ອງການຈຳແນກຕົວຢ່າງດ້ານບວກໃຫ້ໄດ້ຫຼາຍທີ່ສຸດ. ຕົວຢ່າງ: ໃນການກວດຫາພະຍາດຮ້າຍແຮງ, Recall ສູງໝາຍຄວາມວ່າແບບຈຳລອງສາມາດກວດພົບຄົນເຈັບທີ່ມີພະຍາດຫຼາຍທີ່ສຸດເທົ່າທີ່ຈະເປັນໄປໄດ້.

ງ. F1-Score (ຄ່າ F1)

F1-Score ເປັນຄ່າສະເລ່ຍຮາໂມນິກຂອງ Precision ແລະ Recall, ເຊິ່ງສະໜອງຄ່າດຽວທີ່ສົມດຸນລະຫວ່າງທັງສອງຕົວວັດແທກ. ຄ່າ F1 ມີປະໂຫຍດເມື່ອຕ້ອງການດຸນດ່ຽງລະຫວ່າງ Precision ແລະ Recall, ໂດຍສະເພາະໃນກໍລະນີທີ່ມີຄວາມບໍ່ສົມດຸນໃນການກະຈາຍຕົວຂອງຊັ້ນຂໍ້ມູນ.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.11)$$

ຄ່າ F1 ຈະເຂົ້າໃກ້ 1 ເມື່ອທັງ Precision ແລະ Recall ມີຄ່າສູງ, ແລະຈະເຂົ້າໃກ້ 0 ເມື່ອຕົວໃດຕົວໜຶ່ງມີຄ່າຕ່ຳ, ເຮັດໃຫ້ມັນເປັນຕົວວັດແທກທີ່ມີປະສິດທິພາບສຳລັບການປະເມີນປະສິດທິພາບຂອງແບບຈຳລອງການຈຳແນກໂດຍລວມ.

ຈ. Train-Test Split (ການແບ່ງຂໍ້ມູນຝຶກແລະທົດສອບ)


ການແບ່ງຂໍ້ມູນເປັນຊຸດຝຶກ (training set) ແລະຊຸດທົດສອບ (test set) ແມ່ນວິທີການທີ່ສຳຄັນໃນການປະເມີນຄວາມສາມາດໃນການເຮັດໃຫ້ເປັນກໍລະນີທົ່ວໄປ (generalization) ຂອງແບບຈຳລອງ. ໂດຍທົ່ວໄປຈະແບ່ງຂໍ້ມູນປະມານ 70-80% ສຳລັບການຝຶກແບບຈຳລອງ ແລະສ່ວນທີ່ເຫຼືອ 20-30% ສຳລັບການທົດສອບ. ການແບ່ງຂໍ້ມູນນີ້ຊ່ວຍໃຫ້ເຮົາປະເມີນວ່າແບບຈຳລອງສາມາດຮຽນຮູ້ແລະທຳນາຍຂໍ້ມູນທີ່ບໍ່ເຄີຍເຫັນມາກ່ອນໄດ້ດີ (Xu & Goodacre, 2018).

ສ. K-Fold Cross-Validation (ການຕິດຕາມແບບຂວາງໂດຍໃຊ້ K ສ່ວນ)

K-Fold Cross-Validation ເປັນເຕັກນິກທີ່ມີປະສິດທິພາບໃນການປະເມີນຄວາມສາມາດຂອງແບບຈຳລອງໂດຍການແບ່ງຂໍ້ມູນອອກເປັນ K ສ່ວນເທົ່າໆກັນ, ຈາກນັ້ນໝູນວຽນການຝຶກແບບຈຳລອງດ້ວຍ

K-1 ສ່ວນແລະທົດສອບດ້ວຍສ່ວນທີ່ເຫຼືອ. ວິທີການນີ້ຊ່ວຍຫຼຸດຜ່ອນຄວາມບັງເອີນໃນການແບ່ງຂໍ້ມູນແລະໃຫ້ການປະເມີນທີ່ໜ້າເຊື່ອຖືກວ່າ (Baumgartner et al., 2022).

K-Fold Cross Validation ເປັນວິທີການແກ້ໄຂບັນຫາທີ່ບໍ່ຊ້ຳຊ້ອນເຊິ່ງການເຮັດວຽກແມ່ນຈະແບ່ງຂໍ້ມູນແບບຊຸ່ມອອກເປັນສ່ວນຊວນໃນນີ້ຖືກແທນຄ່າດ້ວຍເຄື່ອງໂດຍໃນແຕ່ລະສ່ວນຕ້ອງມີການກະຈາຍຂໍ້ມູນໃຫ້ເທົ່າກັນໂດຍສ່ວນໃຫຍ່ແລ້ວຄ່າຂອງ k ມັກຈະເປັນ 5 ຫຼື 10, ເມື່ອແບ່ງຂໍ້ມູນໄດ້ແລ້ວຕ້ອງໄດ້ເຮັດການຝຶກແບບຈຳລອງໂດຍເຫຼືອສ່ວນໜຶ່ງ ($1/k$) ເອົາໄວ້ເປັນສ່ວນໃນການທົດສອບໃນເມື່ອ ການຝຶກແບບຈຳລອງຮອບທຳອິດສຳເລັດແລ້ວຂໍ້ມູນສ່ວນທັງໝົດຈະນຳກັບເຂົ້າມາເປັນ training set ແລ້ວແບ່ງອີກສ່ວນໄວ້ສຳລັບ ທົດສອບ. ດັ່ງນັ້ນ, ການຝຶກແບບຈຳລອງຈະເຮັດການວິນຊຳໄປຈົນເທົ່າກັບຈຳນວນ k ດັ່ງຮູບ 2.2




ຮູບທີ 2.10 ສະແດງການແບ່ງສ່ວນຂໍ້ມູນ ຂອງ K-Fold Cross Validation (Pedregosa et al., 2011)

ຊ. Early Stopping (ການຢຸດກ່ອນກຳນົດ)

Early Stopping ເປັນເຕັກນິກການຄວບຄຸມ overfitting ທີ່ສຳຄັນໃນການຝຶກແບບຈຳລອງການຮຽນຮູ້ເຊິ່ງເລິກ. ເຕັກນິກນີ້ຕິດຕາມປະສິດທິພາບຂອງແບບຈຳລອງເທິງຊຸດຂໍ້ມູນກວດສອບ (validation set) ແລະຢຸດການຝຶກເມື່ອປະສິດທິພາບເລີ່ມຫຼຸດລົງ (Prechelt, 1998).

Early Stopping (ການຢຸດກ່ອນກຳນົດ) ເປັນເຕັກນິກທີ່ໃຊ້ໃນການຝຶກແບບຈຳລອງການຮຽນຮູ້ເຄື່ອງຈັກເພື່ອປ້ອງກັນການເກີດ Overfitting, ເຊິ່ງເປັນບັນຫາທີ່ training model ດີເກີນໄປຈົນບໍ່ສາມາດທຳນາຍຂໍ້ມູນໃໝ່ໄດ້ດີ. ວິທີການນີ້ຈະຕິດຕາມຄ່າຄວາມຜິດພາດຂອງຊຸດຂໍ້ມູນກວດສອບ (Validation set) ໃນລະຫວ່າງການຝຶກ, ແລະຈະຢຸດການຝຶກອີບຣົມທັນທີເມື່ອເຫັນວ່າຄ່າຄວາມຜິດພາດໃນຊຸດກວດສອບເລີ່ມເພີ່ມຂຶ້ນແທນທີ່ຈະຫຼຸດລົງ. ຈຸດທີ່ຄ່າຄວາມຜິດພາດໃນຊຸດກວດສອບຕ່ຳສຸດຈະຖືກພິຈາລະນາວ່າເປັນຈຸດທີ່ແບບຈຳລອງມີຄວາມສົມດຸນດີທີ່ສຸດລະຫວ່າງ Underfitting ແລະ Overfitting. ການນຳໃຊ້ Early Stopping

ຊ່ວຍປະຢັດເວລາແລະຊັບພະຍາກອນໃນການຝຶກແບບຈຳລອງອີກດ້ວຍ, ເນື່ອງຈາກບໍ່ຈຳເປັນຕ້ອງຝຶກຈົນຄົບຕາມຈຳນວນຮອບທີ່ກຳນົດໄວ້.



ຮູບທີ 2.11 ສະແດງ Early Stopping ເມື່ອຄຳມີການແຍກໂຕອອກຈາກກັນ (Prechelt, 1998)

ຍ. Batch Normalization (ການເຮັດໃຫ້ເປັນມາດຕະຖານແບບຊຸດ)

Batch Normalization ແມ່ນເຕັກນິກທີ່ປັບປຸງການຝຶກແບບຈຳລອງການຮຽນຮູ້ເລິກໂດຍການປັບປຸງການກະຈາຍຂອງຂໍ້ມູນເຂົ້າໃນແຕ່ລະຊັ້ນຂອງໂຄງຂ່າຍ. ວິທີການນີ້ຊ່ວຍໃຫ້ແບບຈຳລອງຮຽນຮູ້ໄດ້ໄວຂຶ້ນ, ມີຄວາມຄົງທີ່ສູງຂຶ້ນ, ແລະຫຼຸດຜ່ອນບັນຫາ vanishing/exploding gradients (Ioffe & Szegedy, 2015). ໃນການຈຳແນກສຽງເຄື່ອງດົນຕີ, Batch Normalization ມີຄວາມສຳຄັນເນື່ອງຈາກຂໍ້ມູນສຽງມັກມີການປ່ຽນແປງຂອງຄ່າຫຼາຍ, ແລະການເຮັດໃຫ້ເປັນມາດຕະຖານຊ່ວຍໃຫ້ແບບຈຳລອງສາມາດຮຽນຮູ້ລັກສະນະສຳຄັນໄດ້ດີຂຶ້ນ.

ດ. Dropout (ການລະເວັ້ນ)

Dropout ເປັນເຕັກນິກການຄວບຄຸມ overfitting ທີ່ສຳຄັນໃນໂຄງຂ່າຍປະສາດທຽມເລິກ. ເຕັກນິກນີ້ສຸມບົດການເຮັດວຽກຂອງໜ່ວຍປະສາດທຽມຈຳນວນໜຶ່ງໃນລະຫວ່າງການຝຶກ, ບັງຄັບໃຫ້ໂຄງຂ່າຍຮຽນຮູ້ຮູບແບບທີ່ທົນທານກວ່າແລະຫຼຸດການຝັງຜາໜ່ວຍປະສາດທຽມສະເພາະ.

2.1.5. ການປະມວນຜົນສຽງ (Audio Processing)

ການປະມວນຜົນສຽງ (Audio Processing) ເປັນຂະບວນການວິເຄາະແລະປັບປຸງສັນຍານສຽງດິຈິຕອນ. ໃນຂົງເຂດການຈຳແນກເຄື່ອງດົນຕີ, ການປະມວນຜົນສຽງແມ່ນຂັ້ນຕອນພື້ນຖານທີ່ເຮັດໃຫ້ລະບົບສາມາດວິເຄາະແລະຈຳແນກສຽງເຄື່ອງດົນຕີໄດ້ຢ່າງແມ່ນຍຳ (McFee et al., 2015). ການປະມວນຜົນສຽງປະກອບດ້ວຍຫຼາຍຂັ້ນຕອນສຳຄັນ ເລີ່ມຕົ້ນແຕ່ການບັນທຶກສຽງຈົນເຖິງການສະກັດຄຸນລັກສະນະທີ່ເໝາະສົມສຳລັບການຈຳແນກປະເພດຂອງເຄື່ອງດົນຕີລາວແຕ່ລະຊະນິດ.

1) ການສະກັດຄຸນລັກສະນະຂອງສຽງ (Feature Extraction)

ການສະກັດຄຸນລັກສະນະຂອງສຽງເປັນຂັ້ນຕອນສໍາຄັນໃນການຫຼຸດຂະໜາດຂອງຂໍ້ມູນນໍາເຂົ້າໃຫ້ນ້ອຍລົງ ແລະ ຈັບລັກສະນະທີ່ສໍາຄັນສໍາລັບການຈຳແນກ (Li et al., 2015). ຄຸນລັກສະນະທີ່ຖືກສະກັດຈາກສຽງຂອງເຄື່ອງດົນຕີລາວຈະເປັນຕົວແທນຂອງລັກສະນະສຽງທີ່ເປັນເອກະລັກຂອງເຄື່ອງດົນຕີແຕ່ລະຊະນິດ.

ກ. Mel-frequency Cepstral Coefficients (MFCCs) MFCCs

Mel Frequency Cepstral Coefficient (MFCCs) ຄືຄ່າຜະລິດງານສະເປັກຕຣັມຂອງສັນຍານສຽງໃນຊ່ວງສັ້ນໆ, ເຊິ່ງເປັນຄຸນລັກສະນະທີ່ສໍາຄັນໃນການຈຳແນກເຄື່ອງດົນຕີລາວ. MFCCs ຖືກພັດທະນາໂດຍ Davis ແລະ Mermelstein ໃນປີ ຄ.ສ. 1980 ແລະ ໄດ້ກາຍເປັນວິທີການມາດຕະຖານໃນການສະກັດຄຸນລັກສະນະສຽງສໍາລັບການຈຳແນກສຽງດົນຕີ (Deng et al., 2014).

MFCCs ມີຄວາມເໝາະສົມສໍາລັບການຈຳແນກເຄື່ອງດົນຕີລາວ ເນື່ອງຈາກວິທີການນີ້ອີງໃສ່ລະບົບການໄດ້ຍິນຂອງມະນຸດ, ເຊິ່ງໃຫ້ນໍ້າໜັກກັບຄວາມຖີ່ທີ່ມະນຸດຮັບຮູ້ໄດ້ດີ. ລັກສະນະພິເສດນີ້ຊ່ວຍໃຫ້ລະບົບສາມາດຈຳແນກຄວາມແຕກຕ່າງລະຫວ່າງສຽງຂອງແຄນ, ຊໍອູ້, ຊິງ, ພິນ, ຄ້ອງວົງ, ແລະ ລະນາດຕໍ່ໄດ້ຢ່າງມີປະສິດທິພາບ. ຂັ້ນຕອນການຄຳນວນ MFCCs ສໍາລັບໂຄງການຈຳແນກເຄື່ອງດົນຕີລາວປະກອບມີ:

- ໃຊ້ວິນໂດວ໌ຟັງກ໌ຊັນ (ເຊັ່ນ Hamming window) ກັບສັນຍານສຽງເຄື່ອງດົນຕີລາວ
- ຄຳນວນຫາຄ່າຜະລິດງານສະເປັກຕຣັມໂດຍໃຊ້ວິທີແປງຟຸເຣຍວ໌ແບບໄວ (FFT) ເພື່ອວິເຄາະອົງປະກອບຄວາມຖີ່ຂອງສຽງເຄື່ອງດົນຕີລາວ
- ໃຊ້ mel-filter bank ເພື່ອປັບຄ່າຄວາມຖີ່ໃຫ້ສອດຄ່ອງກັບການຮັບຮູ້ຂອງມະນຸດ ເຊິ່ງສໍາຄັນສໍາລັບການຈັບລັກສະນະສຽງທີ່ເປັນເອກະລັກຂອງເຄື່ອງດົນຕີພື້ນເມືອງລາວ
- ໃຊ້ການແປງໂຄໄຊນ໌ແບບໄມຕ໌ເນື່ອງ (DCT) ເພື່ອຫຼຸດຄວາມຊໍ້າຊ້ອນຂອງຂໍ້ມູນແລະເນັ້ນຄຸນລັກສະນະທີ່ສໍາຄັນ
- ນໍາຄ່າ MFCCs ທີ່ໄດ້ໄປໃຊ້ເປັນຂໍ້ມູນນໍາເຂົ້າສໍາລັບການຝຶກແບບຈຳລອງການຮຽນຮູ້ເຊິ່ງເລິກສໍາລັບການຈຳແນກເຄື່ອງດົນຕີລາວ


$$MFCC_i = \sum_{k=1}^N X_k \cos \left[i \left(k - \frac{1}{2} \right) \frac{\pi}{N} \right], i = 1, 2, \dots, M \quad (2.12)$$

ການຈຳແນກເຄື່ອງດົນຕີລາວໂດຍໃຊ້ MFCCs ສາມາດເພີ່ມປະສິດທິພາບໃນການຈຳແນກ ເນື່ອງຈາກເຄື່ອງດົນຕີລາວແຕ່ລະຊະນິດມີລັກສະນະສະເພາະຂອງຮູບແບບ MFCCs ທີ່ແຕກຕ່າງກັນ.

ຂ. Mel-Spectrograms

Spectrogram ແມ່ນການສະແດງສຽງແບບສອງມິຕິທີ່ສະແດງໃຫ້ເຫັນຄວາມເຂັ້ມຂອງສຽງໃນແຕ່ລະຄວາມຖີ່ ແລະ ເວລາ. ຕາມທີ່ O'Shaughnessy (1987) ໄດ້ອະທິບາຍໄວ້, Spectrogram ມີຄວາມສໍາຄັນຍ້ອນວ່າການໄດ້ຍິນຂອງມະນຸດແມ່ນອີງໃສ່ການວິເຄາະສຽງທີ່ຄ້າຍຄືກັບ spectrogram ທີ່ເກີດຂຶ້ນໃນຫູຊັ້ນໃນຂອງມະນຸດ.

Spectrogram ປະກອບດ້ວຍສາມມິຕິຫຼັກ: ຄວາມຖີ່ (frequency) ທີ່ສະແດງໃນແກນຕັ້ງ, ເວລາ (time) ທີ່ສະແດງໃນແກນນອນ, ແລະ ຄວາມເຂັ້ມຂອງສຽງ (amplitude) ທີ່ສະແດງດ້ວຍສີ. ສີເຂັ້ມແມ່ນຕົວແທນຂອງຄວາມເຂັ້ມຕໍ່າ ແລະ ສີແຈ້ງກວ່າຈົນເຖິງສີແດງແມ່ນຕົວແທນຂອງຄວາມເຂັ້ມທີ່ສູງຂຶ້ນ.



ຮູບທີ 2.12 Spectrogram Dimensions: ຄວາມຖີ່, ເວລາ ແລະ ສີ (Ashames and Ergin, 2021)

ການສ້າງ Spectrogram ແມ່ນນຳໃຊ້ການແປງ Fourier ແບບໄລຍະສັ້ນ (Short-Time Fourier Transform ຫຼື STFT), ເຊິ່ງເປັນການແປງສັນຍານສຽງອອກເປັນສ່ວນນ້ອຍໆ ແລະ ນຳໃຊ້ການແປງ Fourier ກັບແຕ່ລະສ່ວນ. ຂັ້ນຕອນນີ້ປະກອບມີ:

- ການແປງສັນຍານສຽງເປັນສ່ວນ (windows) ໂດຍທົ່ວໄປແລ້ວຈະມີຄວາມທັບຊ້ອນກັນປະມານ 25-50%
- ການນຳໃຊ້ Fast Fourier Transform (FFT) ກັບແຕ່ລະສ່ວນ
- ການຈັດລຽງຜົນຮັບຂອງ FFT ເພື່ອສ້າງເປັນກຣາຟທີ່ສະແດງຄວາມເຂັ້ມຂອງສຽງໃນແຕ່ລະຄວາມຖີ່ ແລະ ເວລາ

ໃນການຄົ້ນຄວ້າຂອງ Ashames ແລະ Ergin (2021), ພວກເຂົາໄດ້ສ້າງ spectrogram ໂດຍການແປງສັນຍານສຽງອອກເປັນໜ້າຕ່າງຂະໜາດ 2048 ຕົວຢ່າງ (ເຊິ່ງກົງກັບໄລຍະເວລາ 93 ມິລິວິນາທີ ທີ່ອັດຕາການຊັກຕົວຢ່າງ 22050 Hz), ແລະ ເຮັດການເຄື່ອນໄປທົ່ວ 512 ຕົວຢ່າງແຕ່ລະຄັ້ງ, ເຮັດໃຫ້ມີຄວາມທັບຊ້ອນກັນປະມານ 25%.

Mel-Spectrogram ແມ່ນ spectrogram ທີ່ໄດ້ຮັບການດັດແກ້ໃຫ້ເຂົ້າກັບລະບົບການໄດ້ຍິນຂອງມະນຸດ. ມະນຸດສາມາດຈຳແນກຄວາມແຕກຕ່າງຂອງຄວາມຖີ່ໃນລະດັບຕໍ່າໄດ້ດີກວ່າຄວາມຖີ່ສູງ. ຕົວຢ່າງ, ຄົນເຮົາສາມາດຈຳແນກຄວາມແຕກຕ່າງລະຫວ່າງ 500 Hz ແລະ 1000 Hz ໄດ້ງ່າຍກວ່າລະຫວ່າງ 10,000 Hz ແລະ 10,500 Hz ເຖິງແມ່ນວ່າຈະມີຄວາມແຕກຕ່າງ 500 Hz ເທົ່າກັນກໍຕາມ.

Mel-Scale ແມ່ນມາດຕາສ່ວນທີ່ຖືກອອກແບບມາເພື່ອຮຽນແບບການຮັບຮູ້ສຽງຂອງມະນຸດ. ສຽງທີ່ມີໄລຍະຫ່າງເທົ່າກັນໃນ Mel-Scale ຈະຖືກຮັບຮູ້ວ່າມີໄລຍະຫ່າງເທົ່າກັນສຳລັບມະນຸດ. ຄວາມສຳພັນລະຫວ່າງຄວາມຖີ່ (Hertz) ແລະ Mel-Scale ແມ່ນສາມາດຄຳນວນໄດ້ຈາກສູດ:

$$M = 1127 \times \log(1 + f / 700) \quad (2.13)$$

ສູດຄຳນວນ Mel-Scale

ເພື່ອສ້າງ Mel-Spectrogram, ຂັ້ນຕອນແມ່ນ:

- ສ້າງ spectrogram ປົກກະຕິກ່ອນ
- ຈັດແປງສເປັກຕຣັມຄວາມຖີ່ເປັນ 128 ຄວາມຖີ່ທີ່ມີໄລຍະຫ່າງເທົ່າກັນໃນ Mel-Scale
- ສ້າງແຜນທີ່ຄວາມຖີ່ຈາກ Hertz ເປັນ Mel-Scale
- ປ່ຽນແຜນຕັ້ງ (ຄວາມຖີ່) ເປັນ Mel-Scale

ການນຳໃຊ້ Mel-Spectrograms ເຮັດໃຫ້ການວິເຄາະສຽງມີປະສິດທິພາບຫຼາຍຂຶ້ນເນື່ອງຈາກມັນສາມາດສະທ້ອນເຖິງການຮັບຮູ້ຂອງມະນຸດໄດ້ດີກວ່າ spectrogram ທຳມະດາ, ເຊິ່ງເຮັດໃຫ້ແບບຈຳລອງການຮຽນຮູ້ (Deep learning) ສາມາດຈຳແນກລັກສະນະສຽງໄດ້ດີກວ່າ.

ໂດຍສະຫຼຸບແລ້ວ Mel-Spectrogram ເປັນການສະແດງສັນຍານສຽງໃນຮູບແບບພາບທີ່ອີງໃສ່ຄວາມຖີ່ແບບ Mel-scale. Pons et al. (2017) ພົບວ່າ Mel-Spectrograms ໃຫ້ຜົນການຈຳແນກທີ່ດີກວ່າ MFCCs ເມື່ອນຳໃຊ້ກັບ Deep Neural Networks ສຳລັບການຈຳແນກດິນຕີ. Mel-Spectrograms ສາມາດຈັບການປ່ຽນແປງຂອງໂຄງສ້າງຄວາມຖີ່ຕາມເວລາໄດ້ດີ, ເຊິ່ງມີຄວາມສຳຄັນສຳລັບລັກສະນະສຽງຂອງເຄື່ອງດົນຕີລາວທີ່ມີການຜັນແປຕາມເວລາ.

ຄ. ການແປງສັນຍານແບບຟູຣີເອ (Fourier Transform)

Fast Fourier Transform (FFT) ແມ່ນອັລກໍລິທຶມທີ່ມີປະສິດທິພາບສຳລັບການຄຳນວນການແປງ Fourier ແບບຕິດສູງ (Discrete Fourier Transform ຫຼື DFT). FFT ມີຄວາມສຳຄັນຫຼາຍໃນການປະມວນຜົນສັນຍານດິຈິຕອນ ແລະ ເປັນພື້ນຖານສຳຄັນໃນການສ້າງ spectrogram.

ການແປງ Fourier ແບບຕິດສູງ (DFT) ແມ່ນເຄື່ອງມືທາງຄະນິດສາດທີ່ສາມາດແປງສັນຍານຈາກໂດເມນເວລາ (time domain) ໄປເປັນໂດເມນຄວາມຖີ່ (frequency domain). ສຳລັບລຳດັບຂໍ້ມູນ $x[n]$ ທີ່ມີຄວາມຍາວ N ຈຸດ, ການຄຳນວນ DFT ແມ່ນ:

$$X_k = \sum_{n=0}^{N-1} x_n \cdot e^{-i2\pi \frac{k}{N}n} \quad (2.14)$$

ເຊິ່ງ $k = 0, 1, 2, \dots, N-1$

ການຄຳນວນໂດຍກົງໂດຍໃຊ້ສູດນີ້ຈະໃຊ້ເວລາປະມານ $O(N^2)$ ເຊິ່ງບໍ່ມີປະສິດທິພາບສຳລັບລຳດັບຂໍ້ມູນທີ່ຍາວ. FFT ແກ້ໄຂບັນຫານີ້ໂດຍການແບ່ງບັນຫາອອກເປັນສ່ວນຍ່ອຍໆ ແລະ ນຳໃຊ້ຄຸນສົມບັດຕ່າງໆຂອງການຄຳນວນ DFT ເພື່ອຫຼຸດຈຳນວນການຄຳນວນລົງ, ເຮັດໃຫ້ຄວາມຊັບຊ້ອນຂອງການຄຳນວນລົດລົງເຫຼືອ $O(N \log N)$.

ອັລກໍລິທຶມ FFT ທີ່ນິຍົມໃຊ້ຫຼາຍທີ່ສຸດແມ່ນອັລກໍລິທຶມ Cooley-Tukey, ເຊິ່ງເຮັດວຽກໄດ້ດີທີ່ສຸດເມື່ອຂະໜາດຂອງຂໍ້ມູນ N ເປັນກຳລັງຂອງ 2 (ເຊັ່ນ 512, 1024, 2048). ອັລກໍລິທຶມນີ້ແບ່ງລຳດັບຂໍ້ມູນອອກເປັນສ່ວນຍ່ອຍຂອງຕົວຢ່າງຂໍ້ມູນທີ່ມີເລກຕັດຊະນີຄູ່ ແລະ ຄືກ, ຄຳນວນ DFT ຂອງແຕ່ລະສ່ວນຍ່ອຍ, ແລ້ວຈຶ່ງລວມຜົນໄດ້ຮັບເຂົ້າກັນ.

ໃນບໍລິບົດຂອງການສ້າງ spectrogram, FFT ຖືກນຳໃຊ້ໃນການແປງຂໍ້ມູນສຽງຈາກໂດເມນເວລາເປັນໂດເມນຄວາມຖີ່ສຳລັບແຕ່ລະໜ້າຕ່າງຂອງສັນຍານສຽງ. ຕາມທີ່ Ashames ແລະ Ergin (2021)

ໄດ້ອະທິບາຍໄວ້, ອັລກໍລິທິມ FFT ຖືກນຳໃຊ້ກັບແຕ່ລະໜ້າຕ່າງຂອງສັນຍານສຽງທີ່ມີຂະໜາດ 2048 ຕົວຢ່າງ. ເຊິ່ງຂັ້ນຕອນການສ້າງ spectrogram ໂດຍໃຊ້ FFT ປະກອບມີ:

- **ການແບ່ງສັນຍານສຽງອອກເປັນໜ້າຕ່າງ (Windowing):** ສັນຍານສຽງຖືກແບ່ງອອກເປັນໜ້າຕ່າງສັ້ນໆທີ່ທັບຊ້ອນກັນ. ແຕ່ລະໜ້າຕ່າງມັກຈະມີຂະໜາດເປັນກຳລັງຂອງ 2 (ເຊັ່ນ 1024 ຫຼື 2048 ຕົວຢ່າງ) ເພື່ອໃຫ້ເໝາະສົມກັບອັລກໍລິທິມ FFT. ໂດຍທົ່ວໄປແລ້ວໜ້າຕ່າງເຫຼົ່ານີ້ຈະທັບຊ້ອນກັນປະມານ 25-50% ເພື່ອຫຼີກລ່ຽງການສູນເສຍຂໍ້ມູນທີ່ຂອບຂອງແຕ່ລະໜ້າຕ່າງ.

- **ການນຳໃຊ້ຟັງຊັນໜ້າຕ່າງ (Window Function):** ເພື່ອຫຼຸດຜົນກະທົບຈາກລັກສະນະບໍ່ຕໍ່ເນື່ອງທີ່ຂອບຂອງແຕ່ລະໜ້າຕ່າງ, ຟັງຊັນໜ້າຕ່າງ (ເຊັ່ນ Hann, Hamming, ຫຼື Blackman) ຈະຖືກນຳໃຊ້ກັບແຕ່ລະໜ້າຕ່າງ. ຟັງຊັນເຫຼົ່ານີ້ຈະຄ່ອຍໆຫຼຸດຄ່າຂອງສັນຍານໃກ້ກັບຂອບຂອງໜ້າຕ່າງລົງເປັນສູນ.

- **ການນຳໃຊ້ FFT:** ຈະຖືກນຳໃຊ້ກັບແຕ່ລະໜ້າຕ່າງທີ່ຜ່ານການນຳໃຊ້ຟັງຊັນໜ້າຕ່າງແລ້ວ, ເພື່ອຄຳນວນຄ່າ spectrum ຂອງແຕ່ລະໜ້າຕ່າງ. ຜົນໄດ້ຮັບຈະເປັນຄ່າ complex numbers ທີ່ສະແດງເຖິງຄວາມເຂັ້ມ ແລະ ເຟສຂອງແຕ່ລະຄວາມຖີ່.

- **ການຄຳນວນຄວາມເຂັ້ມ (Magnitude Calculation):** ເນື່ອງຈາກ spectrogram ສະແດງພຽງແຕ່ຄວາມເຂັ້ມຂອງສັນຍານໃນແຕ່ລະຄວາມຖີ່, ຄ່າຂະໜາດຂອງຄ່າ complex numbers ຈະຖືກຄຳນວນໂດຍໃຊ້ສູດ

$$|X[k]| = \sqrt{(\text{Re}(X[k]))^2 + (\text{Im}(X[k]))^2} \quad (2.15)$$

- **ການແປງເປັນໂດເມນລັອກ (Logarithmic Scale):** ຄວາມເຂັ້ມຂອງສັນຍານມັກຈະຖືກແປງເປັນໂດເມນລັອກ (dB) ເພື່ອໃຫ້ສອດຄ່ອງກັບການຮັບຮູ້ຂອງມະນຸດ ແລະ ເພີ່ມຄວາມຊັດເຈນຂອງສັນຍານທີ່ມີຄວາມເຂັ້ມຕ່ຳ.

- **ການຈັດລຽງຜົນໄດ້ຮັບ:** ຜົນໄດ້ຮັບຈາກແຕ່ລະໜ້າຕ່າງຈະຖືກຈັດລຽງຕາມລຳດັບເວລາ, ເຮັດໃຫ້ໄດ້ຮັບ spectrogram ທີ່ສະແດງການປ່ຽນແປງຂອງຄວາມເຂັ້ມໃນແຕ່ລະຄວາມຖີ່ຕາມເວລາ.

ການນຳໃຊ້ FFT ແທນ DFT ໂດຍກົງແມ່ນມີຄວາມສຳຄັນຫຼາຍສຳລັບການປະມວນຜົນສຽງແບບຕົວຈິງ, ເນື່ອງຈາກວ່າຄວາມຊັບຊ້ອນຂອງການຄຳນວນທີ່ຕ່ຳກວ່າຫຼາຍ ($O(N \log N)$ ແທນທີ່ຈະເປັນ $O(N^2)$) ເຮັດໃຫ້ສາມາດສ້າງ spectrogram ໄດ້ຢ່າງວ່ອງໄວ, ເຊິ່ງເປັນສິ່ງຈຳເປັນສຳລັບການນຳໃຊ້ໃນລະບົບທີ່ເຮັດວຽກແບບ real-time ຫຼື ສຳລັບການປະມວນຜົນຊຸດຂໍ້ມູນຂະໜາດໃຫຍ່.

ງ. ການແຍກສຽງດິນຕີອອກເປັນອົງປະກອບສຽງ (Harmonic-Percussive Source Separation – HPSS)


HPSS ເປັນເທັກນິກທີ່ແຍກສັນຍານສຽງອອກເປັນສອງອົງປະກອບຫຼັກຄື: ອົງປະກອບສຽງດິນຕີ (harmonic) ແລະ ອົງປະກອບສຽງເຄາະ (percussive). ສຽງດິນຕີມັກຈະມີໂຄງສ້າງຄວາມຖີ່ທີ່ຄົງທີ່ ແລະ ມີການຄ້າງຄືນ (repeating patterns) ໃນຂະນະທີ່ສຽງເຄາະຈະມີລັກສະນະເປັນສຽງທີ່ເກີດຂຶ້ນສັ້ນໆ ແລະ ມີພະລັງງານແຜ່ກະຈາຍໃນຊ່ວງຄວາມຖີ່ກວ້າງ. ການແຍກນີ້ມີປະໂຫຍດຢ່າງຍິ່ງໃນການວິເຄາະ ແລະ ປະມວນຜົນສຽງດິນຕີ, ໂດຍສະເພາະສຳລັບການຈຳແນກເຄື່ອງດິນຕີທີ່ມີທັງສຽງດິນຕີ ແລະ ສຽງເຄາະປະສົມກັນ.

ວິທີການ HPSS ໂດຍທົ່ວໄປແມ່ນອີງໃສ່ການວິເຄາະ spectrogram ຂອງສັນຍານສຽງ. ເທັກນິກນີ້ໃຊ້ຄຸນສົມບັດທີ່ສຽງດິນຕີມີແນວໂນ້ມທີ່ຈະຄົງທີ່ຕາມແນວນອນ (ເວລາ) ໃນ spectrogram ໃນຂະນະທີ່ສຽງເຄາະມີແນວໂນ້ມທີ່ຈະຄົງທີ່ຕາມແນວຕັ້ງ (ຄວາມຖີ່). ອັລກໍລິທຶມ HPSS ມັກຈະໃຊ້ຕົວກອງ Median (Median Filtering) ໃນສອງທິດທາງທີ່ແຕກຕ່າງກັນຄື: ໜຶ່ງສໍາລັບແນວນອນເພື່ອສະກັດອົງປະກອບສຽງດິນຕີ, ແລະອີກໜຶ່ງສໍາລັບແນວຕັ້ງເພື່ອສະກັດອົງປະກອບສຽງເຄາະ (Fitzgerald, 2010). ຫຼັງຈາກນັ້ນ, ອົງປະກອບທັງສອງຈະຖືກນໍາມາລວມກັນເພື່ອສ້າງສັນຍານສຽງຕົ້ນສະບັບຄືນໃໝ່.

2) Audio Data Augmentation

ການເພີ່ມຈຳນວນຂໍ້ມູນສຽງແມ່ນເຕັກນິກສໍາຄັນໃນການປັບປຸງປະສິດທິພາບຂອງແບບຈຳລອງ Deep Learning. ເນື່ອງຈາກແບບຈຳລອງ CNN ຕ້ອງການຂໍ້ມູນຈຳນວນຫຼາຍເພື່ອການຝຶກສອນ, ການເພີ່ມຂໍ້ມູນຈະຊ່ວຍໃຫ້ແບບຈຳລອງມີຄວາມແມ້ນຍຳຫຼາຍຂຶ້ນ ແລະ ຫຼີກລ່ຽງບັນຫາ overfitting.

ໃນການຄົ້ນຄວ້າຂອງ Ashames ແລະ Ergin (2021), ພວກເຂົາໄດ້ນຳໃຊ້ການເພີ່ມສຽງລົບກວນແບບ Gaussian (ຫຼື white noise) ເຂົ້າໄປໃນຂໍ້ມູນສຽງ, ເຊິ່ງເປັນວິທີການທີ່ມີປະສິດທິພາບໃນການເພີ່ມຈຳນວນຂໍ້ມູນ. ໂດຍການເພີ່ມສຽງລົບກວນເຂົ້າໄປໃນແຕ່ລະຝາຍສຽງ, ພວກເຂົາສາມາດເພີ່ມຈຳນວນຂໍ້ມູນໄດ້ເປັນສອງເທົ່າ.



ຮູບທີ 2.13 ສະແດງຝາບກ່ອນ ແລະ ຫຼັງເພີ່ມສຽງລົບກວນ (Ashames ແລະ Ergin ,2021)

ດັ່ງຮູບທີ 2.13 (a) Mel-Spectrogram ທີ່ຍັງບໍ່ໄດ້ເພີ່ມເຕັກນິກການເພີ່ມສຽງລົບກວນ, (b) ຝາບຫຼັງຈາກເພີ່ມແລ້ວ.

ທີ່ຈົງແລ້ວ, ມີເຕັກນິກການເພີ່ມຈຳນວນຂໍ້ມູນສຽງຫຼາຍວິທີທີ່ສາມາດນຳໃຊ້ໄດ້, ເຊັ່ນ:


- **Time Stretching (ການຍືດຂະຫຍາຍເວລາ):** ການປັບຄວາມໄວຂອງສຽງໂດຍບໍ່ກະທົບຕໍ່ລະດັບສຽງ, ເຊັ່ນ ການຍືດຫຼືຫຍໍ້ສຽງປະມານ 0.85-1.15 ເທົ່າ.
- **Pitch Shifting (ການປ່ຽນລະດັບສຽງ):** ການປັບລະດັບສຽງຂຶ້ນຫຼືລົງໂດຍບໍ່ກະທົບຕໍ່ຄວາມໄວຂອງສຽງ, ເຊັ່ນ ການປັບລະດັບສຽງຂຶ້ນຫຼືລົງ ± 3 semitones.
- **Adding Noise (ການເພີ່ມສຽງລົບກວນ):** ການເພີ່ມສຽງລົບກວນໃນລະດັບຕ່າງໆ, ເຊັ່ນ ສຽງລົບກວນແບບ Gaussian.
- **Time Shifting (ການຍ້າຍເວລາ):** ການຍ້າຍສຽງໄປທາງຊ້າຍຫຼືຂວາໃນແຖວເວລາ, ເຊັ່ນ ການຍ້າຍສຽງປະມານ $\pm 25\%$ ຂອງຄວາມຍາວສຽງ.

- **Volume Adjustment (ການປັບລະດັບຄວາມດັງ):** ການປັບລະດັບຄວາມດັງຂອງສຽງ, ເຊັ່ນ ປັບລະຫວ່າງ 0.7-1.3 ເທົ່າ.
- **Masking (ການປິດບັງແບບຊ່ວງສຽງ):** ປິດບັງໃນຊ່ວງຂອງຄວາມຖີ່ໃດໜຶ່ງ ຫຼື ໃນໄລຍະເວລາໃດໜຶ່ງເພື່ອໃຫ້ແບບຈຳລອງບໍ່ເກີດ Overfitting.

ການເພີ່ມຈຳນວນຂໍ້ມູນສຽງຊ່ວຍໃຫ້ແບບຈຳລອງ Deep Learning ມີຄວາມແຂງແກ່ນຕໍ່ຄວາມຫຼາກຫຼາຍຂອງສຽງທີ່ອາດເກີດຂຶ້ນໃນສະພາບແວດລ້ອມຈິງ, ເຊັ່ນ ສຽງລົບກວນຈາກຜືນຫຼັງ, ຄວາມແຕກຕ່າງໃນການບັນທຶກສຽງ, ແລະ ການປ່ຽນແປງຂອງສຽງຈາກຜູ້ຫຼິ້ນທີ່ແຕກຕ່າງກັນ.

2.1.6. Unified Modeling Language (UML)

UML (Unified Modeling Language) ເປັນພາສາແບບຮູບພາບຫຼື ສັນຍາລັກທີ່ໃຊ້ ເພື່ອສະແດງຄວາມຄິດຂອງເຮົາທີ່ມີຕໍ່ລະບົບອອກມາເປັນແຜນພາບ, ເຊິ່ງປະກອບໄປດ້ວຍຮູບ ພາບ ຫຼື ສັນຍາລັກ, ເພື່ອໃຊ້ໃນການວິເຄາະ ແລະ ອອກແບບລະບົບແບບວັດຖຸໂດຍສະເພາະໃນ ລະບົບທີ່ມີຂະໜາດໃຫຍ່ ແລະ ມີຄວາມຊັບຊ້ອນ ໃຫ້ສາມາດເຂົ້າໃຈໄດ້ງ່າຍຂຶ້ນ.




ຮູບທີ 2.14 ອົງປະກອບຂອງ UML

- ທິດສະດີກ່ຽວກັບການແຕ້ມແຜນວາດຂໍ້ມູນ

1) Use Case Diagram ແມ່ນຫຍັງ

ແຜນວາດທີ່ສະແດງໃຫ້ເຫັນເຖິງພຶດຕິກຳຂອງລະບົບທີ່ ມີຕໍ່ການກະທຳຂອງຜູ້ທີ່ກ່ຽວຂ້ອງ ຫຼື ເວົ້າອີກຢ່າງໜຶ່ງວ່າ ແມ່ນແຜນພາບທີ່ສະແດງໃຫ້ເຫັນວ່າ ລະບົບມີການເຮັດວຽກ ຫຼື ມີໜ້າທີ່ໃດແດ່.

ກ. Use Case: ແມ່ນໜ້າທີ່ແຕ່ລະອັນຂອງລະບົບທີ່ຕ້ອງເຮັດ, ສັນຍາລັກດ້ວຍຮູບແອນລິບ.




ຮູບທີ 2.15 ຮູບສະແດງສັນຍາລັກ Use Case

ຂ. Actor: ແມ່ນຜູ້ກະທຳຕໍ່ລະບົບ, ໃຊ້ສັນຍາລັກຮູບຄົນ



ຮູບທີ 2.16 ຮູບສະແດງສັນຍາລັກ Actor


ຄ. System Boundary: ແມ່ນເສັ້ນແບ່ງຂອບເຂດລະຫວ່າງລະບົບ ແລະ ຜູ້ກະທຳ ລະບົບ, ສັນຍາລັກດ້ວຍຮູບສີ່ແຈສາກ.



ຮູບທີ 2.17 ຮູບສະແດງສັນຍາລັກ System Boundary


2) ຄວາມສຳພັນໃນ Use Case Diagram

ກ. Include Relationship: ເປັນຄວາມສຳພັນລະຫວ່າງ Use Case ລັກສະນະເປັນໃຊ້ເກີດຂຶ້ນ ເມື່ອ Use Case ຫນຶ່ງເອີ້ນໄປໃຊ້ Use Case ອື່ນເພື່ອເຮັດໃຫ້ການ ປະມວນຜົນໃນ ຕົ້ນສຳເລັດ.




ຮູບທີ 2.18 ຮູບສະແດງຄວາມສຳພັນ Include

ຂ. Extend Relationship: ເປັນຄວາມສຳພັນລະຫວ່າງ Use Case ແບບເພີ່ມເຕີມ ຫຼື ຫນ້າທີ່ ພິເສດເພີ່ມ (ບໍ່ໄດ້ເກີດຂຶ້ນເປັນປະຈຳ).



ຮູບທີ 2.19 ຮູບສະແດງຄວາມສໍາພັນ Extend


ຄ. Generalization/specialization Relationship: ແມ່ນແນວຄິດທີ່ໃຊ້ສະແດງຄວາມສໍາພັນ ແບບຈຳແນກປະເພດຂອງ Use Case ຫຼື Actor ໂດຍ Use Case / Actor ທີ່ເປັນຫຼັກຂອງ ການຈຳແນກ ປະເພດ ຈະເອີ້ນວ່າ “Parent” ສ່ວນ Use Case / Actor ທີ່ຖືກຈຳແນກ ຈະເອີ້ນວ່າ “Child” ສໍາຫຼັບ ສັນຍະລັກທີ່ໃຊ້ຈະເປັນເສັ້ນຊື່ມີຫົວລູກສອນລາກຈາກ Child ຊື່ໄປທີ່ Parent.



ຮູບທີ 2.20 ຮູບສະແດງຄວາມສໍາພັນ Class Diagram

3) Class Diagram


ແມ່ນແຜນພາບທີ່ໃຊ້ສະແດງ ແລະ ຄວາມສໍາພັນລະຫວ່າງ Class ຂອງລະບົບທີ່ເຮົາສົນໃຈ. ສັນຍາລັກຂອງ Class Diagram ປະກອບໄປດ້ວຍ Class name, Attributes, Operation ຫຼື Methods ແລະ ຍັງມີສັນຍາລັກ Visibility ກໍຄື Private (-), Public (+) Protected (#) Sequence Diagram



ຮູບທີ 2.21 ຮູບສະແດງ Class Diagram

4) Sequence Diagram

ໃຊ້ສໍາຫຼັບການສ້າງການຈຳລອງແບບວັດຖຸ, ເປັນແຜ່ນພາບ ທີ່ ປະກອບໄປດ້ວຍ Class ຫຼື Object ເສັ້ນທີ່ໃຊ້ເພື່ອສະແດງລຳດັບເວລາ ແລະ ເສັ້ນທີ່ໃຊ້ ເພື່ອ ສະແດງ ກິດຈະກຳທີ່ເກີດຂຶ້ນຈາກ Class ຫຼື Object ໃນແຜ່ນພາບການເຮັດວຽກ ພາຍໃນ Sequence Diagram ຈະໃຊ້ສີ່ຫຼ່ຽມແທນໃຫ້ Class ແລະ ວັດຖຸ ໂດຍພາຍໃນຈະມີຊື່ຂອງ Class



ຮູບທີ 2.22 ຮູບສະແດງ Sequence Diagram

5) Activity Diagram

ແມ່ນແຜ່ນພາບກິດຈະກຳທີ່ໃຊ້ອະທິບາຍກິດຈະກຳທີ່ເກີດ ຂຶ້ນໃນ ລັກສະນະກະແສການໄຫຼການເຮັດວຽກ (Workflow) ແລະ ສະແດງຂັ້ນຕອນການເຮັດວຽກ ຂອງ ລະບົບ. Activity Diagram ຈະມີສັນຍາລັກດຽວກັບ Flowchart ໂດຍຂັ້ນຕອນການເຮັດວຽກ ແຕ່ລະຂັ້ນຕອນເອີ້ນວ່າ Activity.

2.1.7.ພາສາ ແລະ ເຄື່ອງມືຕ່າງໆທີ່ໃຊ້ໃນການພັດທະນາລະບົບ

1) ຄວາມຮູ້ກ່ຽວກັບພາສາ Python

Python ແມ່ນພາສາໂປຣແກຣມຄອມພິວເຕີລະດັບສູງ, ເຊິ່ງໄດ້ຖືກອອກແບບເປັນ ພາສາ Script ທີ່ອ່ານງ່າຍ ໂດຍການຕັດຄວາມຊັບຊ້ອນຂອງໂຄງສ້າງ ແລະ ໄວຍາກອນຂອງ ພາສາອອກໄປ. ໃນສ່ວນຂອງການປ່ຽນຊຸດຄຳສັ່ງທີ່ເຮົາຂຽນເປັນພາສາເຄື່ອງ Python ມີການ ເຮັດວຽກແບບ Interpreter ຄື ເປັນການແປຊຸດຄຳສັ່ງເທື່ອລະແຖວເພື່ອປ້ອນຂໍ້ມູນເຂົ້າສູ່ຫນ່ວຍ ປະມວນຜົນໃຫ້ຄອມພິວເຕີເຮັດວຽກຕາມທີ່ເຮົາຕ້ອງການ. ນອກຈາກນັ້ນ Python ຍັງສາມາດນຳ ໄປໃຊ້ໃນການຂຽນໂປຣແກຣມໄດ້ຫຼາກຫຼາຍປະເພດ ໂດຍບໍ່ຈຳກັດວຽກງານສະເພາະດ້ານໃດ ດ້ານຫນຶ່ງເທົ່ານັ້ນ. ດັ່ງນັ້ນ, ຈຶ່ງເຮັດໃຫ້ອົງກອນຂະໜາດໃຫຍ່ລະດັບໂລກນຳໄປໃຊ້ຢ່າງແຜ່ຫຼາຍ ເຊັ່ນ Google, YouTube, Instagram, Dropbox ແລະ NASA ເປັນຕົ້ນ. (9experttraining.com, 2022).

2) ຄວາມຮູ້ກ່ຽວກັບ FastAPI

FastAPI ແມ່ນ Framework ຫນຶ່ງທີ່ນິຍົມໃຊ້ກັບພາສາ Python ເຊິ່ງຖືກອອກແບບມາ ໃຫ້ໃຊ້ງານງ່າຍຕໍ່ການພັດທະນາ ແລະ ສາມາດສ້າງ API ຂຶ້ນມາໄດ້ຢ່າງວ່ອງໄວ, ເຊິ່ງ ປະສິດທິພາບໃນການເຮັດວຽກນັ້ນໄວທຽບເທົ່າກັບພາສາ NodeJS ແລະ Go. ເຊິ່ງ FastAPI ນັ້ນ ຮອງຮັບການເຮັດວຽກແບບ Asynchronous ກໍຄືເປັນການເຮັດວຽກຜ່ອມກັນຫຼາຍໆຄຳສັ່ງ ໂດຍ ບໍ່ຕ້ອງລໍຖ້າໃຫ້ຄຳສັ່ງກ່ອນຫນ້ານີ້ເຮັດວຽກແລ້ວກ່ອນ. ນອກຈາກນີ້, FastAPI ຍັງມີ Uvicorn ເຊິ່ງເປັນຕົວ Run ຝ່າຍ Python ຢູ່ໃນ Server ອີກດ້ວຍ. (mindphp.com, 2022).

3) ຄວາມຮູ້ກ່ຽວກັບພາສາ Dart

Chaivanichanan (2020) ໄດ້ຂຽນໄວ້ວ່າ: Dart ເປັນພາສາ Open Source ທີ່ ພັດທະນາຂຶ້ນ ໂດຍ Google ແລະ ຖືກເປີດຕົວຄັ້ງທຳອິດໃນປີ 2011, ເຊິ່ງໂຄງສ້າງຂອງພາສາ Dart ຈະຄ້າຍຄືກັບ C/C++ ແລະ Java, ໂດຍຈະເປັນພາສາແບບ Structure Programming ຫຼື ເປັນພາສາແບບມີໂຄງສ້າງ. ແຕ່ກໍຍັງມີຄວາມສາມາດແບບພາສາປະເພດ Object Oriented Programming ນາ, ນັ້ນກໍຄືມີ Class ແລະ Inheritance ໃຫ້ໃຊ້ງານນຳ. ນອກຈາກນີ້, BorntoDev (2020) ຍັງໄດ້ຂຽນກ່ຽວກັບພາສາ Dart ໄວ້ວ່າ: Dart ເປັນພາສາໂປຣແກຣມທີ່ ເອົາ ໄວ້ສຳລັບສ້າງ Application ເທິງ Platform ທີ່ຫຼາກຫຼາຍ, ໂດຍໄດ້ທັງ Mobile, Desktop.

Server ແລະ Web. ເຊິ່ງສິ່ງທີ່ເປັນທີ່ນິຍົມທີ່ສຸດ ທີ່ເຮັດໃຫ້ຄົນສົນໃຈມາຮຽນພາສາ Dart ກໍເພື່ອທີ່ຈະເອົາໄປໃຊ້ຮ່ວມກັບ Flutter ທີ່ເປັນເຄື່ອງມືຊ່ວຍສ້າງ UI ຂອງ Google ເຊິ່ງໃຊ້ໄດ້ທັງກັບ

Android ແລະ iOS ຫຼື ຈະເປັນໃນ Desktop ກັບ Web ກໍໄດ້. ພາສາ Dart ເປັນ Open Source ທີ່ທຸກຄົນສາມາດນຳໄປໃຊ້ງານໄດ້ຝຣີ ແລະ ເປັນພາສາທີ່ຖືກອອກແບບມາໃຫ້ໃຊ້ງານໄດ້ງ່າຍ ແລະ ມີປະສິດທິພາບ. ດັ່ງນັ້ນ, ຈຶ່ງເຫມາະສົມກັບພວກນັກງານໃນການພັດທະນາໂຄງການໃນຄັ້ງນີ້ຫຼາຍ.

4) ຄວາມຮູ້ກ່ຽວກັບ Flutter

Flutter ແມ່ນ Cross-Platform Framework ທີ່ໃຊ້ໃນການພັດທະນາ Native Mobile Application (Android/iOS) ທີ່ພັດທະນາໂດຍ Google Inc. ໂດຍໃຊ້ພາສາ Dart ໃນການ ພັດທະນາທີ່

ມີຄວາມຄ້າຍຄືກັບພາສາ C# ແລະ Java ຈຸດເດັ່ນຂອງ Flutter ແມ່ນການປັບແຕ່ງ UI (User Interface) ທີ່ມີຄວາມຍືດຍຸ່ນ, ແຍກການອອກແບບເພື່ອເນັ້ນໄປທີ່ປະສົບການຂອງຜູ້ໃຊ້

ງານ UX (User Experience) ໂດຍ UI ຈະໃກ້ຄຽງກັບ Native ແລະ ກົງກັບ Design Guideline ທີ່ຖືກຕ້ອງ ແລະ ມີຄວາມສາມາດໃນການເຮັດ Hot Reload ທີ່ເຮັດໃຫ້ການແກ້ໄຂ Code ສາມາດສະແດງຜິດພາດໄດ້ທັນທີ ໃນລະຫວ່າງທີ່ Run Application ແລະ ຍັງລວມເຖິງມີ Widget ທີ່ພ້ອມໃຫ້ເລືອກໃຊ້ຫຼາກຫຼາຍ ເຮັດໃຫ້ການພັດທະນາແອັບເຮັດໄດ້ໄວເໝາະສໍາລັບອົງກອນທີ່ຕ້ອງການແອັບທີ່ສວຍງາມ, ມີປະສິດທິພາບ ແລະ ທີ່ສໍາຄັນຍັງເປັນ Open Source ທີ່ ສາມາດໃຊ້ງານໄດ້ແບບບໍ່ຈ່າຍເງິນອີກດ້ວຍ.

5) ຄວາມຮູ້ກ່ຽວກັບ Android Studio

Android Studio UIIDE Tool (Integrate Development Environment) ພັດທະນາໂດຍ Google. Android Studio ເປັນເຄື່ອງມືເພື່ອພັດທະນາໂປຣແກຣມ Android ໂດຍສະເພາະ, ມີການພັດທະນາຈາກແນວຄິດຜື້ນຖານມາຈາກ Inteli IDEA ຄ້າຍຄືກັບການ ເຮັດວຽກຂອງ Eclipse ແລະ Android ADT Plugin. ໂດຍຈຸດປະສົງຂອງ Android Studio ແມ່ນຕ້ອງການ ພັດທະນາເຄື່ອງມື IDE ທີ່ສາມາດພັດທະນາແອັບພລິເຄຊັນເທິງ Android ໃຫ້ ມີປະສິດທິພາບຫຼາຍຂຶ້ນ ທັງດ້ານການອອກແບບ GUI ທີ່ຊ່ວຍໃຫ້ສາມາດ Preview ຕົວ App ໃນມຸມມອງທີ່ແຕກຕ່າງກັນເທິງ Smart Phone ແຕ່ລະລຸ້ນ, ສາມາດສະແດງຜິດພາດບາງຢ່າງໄດ້ທັນທີ ໂດຍບໍ່ຕ້ອງເຮັດການ Run App ເທິງ Emulator ລວມ ທັງຍັງແກ້ໄຂປັບປຸງໃນເລື່ອງຂອງຄວາມ ໄວຂອງ Emulator ທີ່ຍັງພົບບັນຫາຢູ່ໃນປັດຈຸບັນ. (thaicreate.com, 2017).

- Android SDK: Android Software Development Kit (Android SDK)

ປຽບເຫມືອນ Library ທີ່ໃຊ້ໃນການພັດທະນາ Application ສໍາລັບ Android ເນື່ອງຈາກ Android ມີ ຫຼາຍເວີຊັນ ແລະ ແຕ່ລະເວີຊັນມີ Feature, GUI ທີ່ບໍ່ຄືກັນ ເຮັດໃຫ້ເກີດ Android SDK ອອກມາຫຼາຍເວີຊັນໃຫ້ເລືອກໃຊ້ງານ.

- API Level: API Level ຫມາຍເຖິງເວີຊັນຂອງ API ທີ່ໃຫ້ນັກພັດທະນານຳມາ ໃຊ້ ງານໃນ SDK ນັ້ນໆ ເຊັ່ນ: ມີຖືຂອງຜູ້ໃຊ້ Android 8 ກໍຈະສາມາດໃຊ້ງານ API Level 26 ເຊິ່ງ ອາດຈະມີ Feature ໃຫມ່ໆ ເພີ່ມຂຶ້ນມາ ເຮັດໃຫ້ມີຖືທີ່ໃຊ້ Android ເວີຊັນເກົ່າກວ່ານີ້ຈະ ບໍ່ສາມາດໃຊ້ງານ API Level ນີ້ໄດ້.

6) ຄວາມຮູ້ກ່ຽວກັບ Visual Studio Code

ສໍາລັບການພັດທະນາບົດໂຄງການຂອງພວກນ້ອງ, ໄດ້ເລືອກ IDE ຄື Visual Studio Code (VS Code). ໂປຣແກຣມດັ່ງກ່າວເປັນເຄື່ອງມືແກ້ໄຂໂຄດ (Code Editor) ທີ່ມີ ມີປະສິດທິພາບສູງ. Visual Studio Code ເປັນຊອຟແວເປີດກວ້າງ (Open Source) ທີ່ສາມາດນຳໃຊ້ໄດ້ໂດຍບໍ່ເສຍຄ່າໃຊ້ຈ່າຍ, ເໝາະສໍາລັບນັກພັດທະນາຊອຟແວທີ່ມີຄວາມຕ້ອງການປະຕິບັດການໃນຫຼາຍແຟລັດຟອມ. ເຄື່ອງມືດັ່ງກ່າວສະໜັບສະໜູນລະບົບປະຕິບັດການຫຼາຍຊະນິດ ລວມທັງ Windows, macOS ແລະ Linux. Visual Studio Code ຮອງຮັບຫຼາຍພາສາໂປຣແກຣມມິງໂດຍກົງ ເຊັ່ນ: JavaScript, TypeScript ແລະ Node.js, ພ້ອມທັງມີຄວາມສາມາດໃນການເຊື່ອມຕໍ່ກັບລະບົບຄວບຄຸມເວີຊັນ Git ຢ່າງມີປະສິດທິພາບ. ສິ່ງທີ່ເປັນຈຸດເດັ່ນອີກປະການໜຶ່ງແມ່ນ ສ່ວນຕິດຕໍ່ຜູ້ໃຊ້ທີ່ເຂົ້າໃຈງ່າຍ ແລະ ບໍ່ຊັບຊ້ອນ. ນອກຈາກນີ້, Visual Studio Code ຍັງມີລະບົບສ່ວນຂະຫຍາຍ (Extensions) ທີ່ຫຼາກຫຼາຍໃຫ້ເລືອກໃຊ້, ສະໜັບສະໜູນພາສາໂປຣ

ແກຣມມິງເພີ່ມເຕີມ ເຊັ່ນ: C++, C#, Java, Python, PHP ແລະ Go. ຄຸນສົມບັດທີ່ສໍາຄັນອື່ນໆປະກອບມີ ຄວາມສາມາດໃນການປັບແຕ່ງຮູບແບບ (Themes), ການມີເຄື່ອງມືແກ້ໄຂຂໍ້ຜິດພາດ (Debugger) ແລະ ຊຸດຄໍາສັ່ງ (Commands) ທີ່ຊ່ວຍເພີ່ມປະສິດທິພາບໃນການພັດທະນາຊອຟແວ.

7) ຄວາມຮູ້ກ່ຽວກັບ StarUML

StarUML ແມ່ນໂປຣແກຣມທີ່ໃຊ້ເພື່ອອອກແບບ ແບບຈໍາລອງຂອງລະບົບ (System Modeling) ພ້ອມທັງເປັນແຜນພາບ (Diagram) ທີ່ເປັນຕົວແທນແນວຄິດທັງໝົດທີ່ເຮົາ ມີຕໍ່ລະບົບ ເຊິ່ງ ຊ່ວຍໃຫ້ການຕິດຕໍ່ສື່ສານລະຫວ່າງກຸ່ມຄົນທີ່ກ່ຽວຂ້ອງໃຫ້ສາມາດມະໂນພາບ ແລະ ຮູ້ຈັກຄວາມຫມາຍກ່ຽວ ກັບລະບົບທີ່ຊັບຊ້ອນໃຫ້ເລື່ອໃຫ້ເຂົ້າໃຈງ່າຍຂຶ້ນ. ໃນການອອກແບບ

ແບບຈໍາລອງຂອງລະບົບ ຫຼື ແຜນພາບຈະປະກອບມີທັງໝົດ 9 Diagrams, ແຕ່ລະ Diagram ປະກອບດ້ວຍສັນຍາລັກທີ່ໃຊ້ຊີ້ຄວາມຫມາຍໂດຍສະເພາະໃນ Diagram ນັ້ນໆ. ເຊິ່ງການທີ່ເຮັດ ໃຫ້ເຮົາໃຊ້ ພາສາ UML ເປັນໄປຢ່າງປະສິດຜົນສໍາເລັດນັ້ນແມ່ນຜູ້ອອກແບບແລະພັດທະນາ ຈໍາເປັນຕ້ອງຮຽນຮູ້ຂະບວນ ການໃນການເລືອກໃຊ້ diagram ຕາມຄວາມເໝາະສົມ ແລະ ສອດຄ່ອງກັບຂະບວນການພັດທະນາຊອຟ ແວ. ສະນັ້ນ, ໃນການພັດທະນາລະບົບໂດຍທົ່ວໄປ

ແລ້ວຜູ້ພັດທະນາບໍ່ຈໍາເປັນຕ້ອງສ້າງແຜນພາບໃຫ້ຄົບທຸກແຜນພາບສະເໝີໄປ ຜູ້ພັດທະນາ ສາມາດ ປັບປຸງການໃຊ້ງານແຜນພາບໄດ້ຕາມຄວາມເໝາະສົມຂອງແຕ່ລະໄລຍະການ ພັດທະນາ. (ສົມມິດ ທຸມມາ ລີ ແລະ ພູທອນ ວົງປະສິດ, 2021).

2.2. ບົດຄົ້ນຄວ້າທີ່ກ່ຽວຂ້ອງ

Deep Neural Network for Musical Instrument Recognition Using MFCCs ໂດຍ (Sharma et al., 2021) ນໍາສະເໜີການນໍາໃຊ້ແບບຈໍາລອງເຄືອຂ່າຍປະສາດທຽມ (ANN) ສໍາລັບການຈໍາແນກເຄື່ອງດົນຕີ 20 ປະເພດທີ່ແຕກຕ່າງກັນ ໂດຍການໃຊ້ຄຸນລັກສະນະ mel-frequency cepstral coefficients (MFCCs) ຂອງຂໍ້ມູນສຽງ. ການສຶກສາໄດ້ນໍາໃຊ້ຊຸດຂໍ້ມູນ London philharmonic orchestra ເຊິ່ງປະກອບດ້ວຍເຄື່ອງ ດົນຕີ 20 ປະເພດຈາກ 4 ຕະກຸນຄື: ເຄື່ອງເປົ້າໄມ້, ເຄື່ອງເປົ້າທອງເຫຼືອງ, ເຄື່ອງຕີ, ແລະ ເຄື່ອງສາຍ ລວມແລ້ວມີ ຫຼາຍກວ່າ 13679 ຕົວຢ່າງ ເຊິ່ງໃນບົດຄົ້ນຄວ້າໄດ້ທໍາການແບ່ງຂໍ້ມູນທີ່ໃຊ້ໃນການຝຶກແບບຈໍາລອງ 80% ແລະ ຂໍ້ມູນທີ່ໃຊ້ໃນການທົດສອບແບບຈໍາລອງ 20% , ຂໍ້ມູນທີ່ໃຊ້ໃນການຝຶກແບບຈໍາລອງມີ 10943 ຕົວຢ່າງ ສ່ວນ ຂໍ້ມູນທີ່ໃຊ້ທົດສອບມີ 2736 ຕົວຢ່າງ. ຜົນການທົດລອງສະແດງໃຫ້ເຫັນວ່າແບບຈໍາລອງທີ່ນໍາສະເໜີສາມາດ ບັນລຸຄວາມຖືກຕ້ອງໃນການຈໍາແນກເຄື່ອງດົນຕີຫຼາຍປະເພດ ເຊິ່ງແບບຈໍາລອງທີ່ເຮັດອອກມານັ້ນໄດ້ຜົນຄ່າ ຄວາມຖືກຕ້ອງຂອງແບບຈໍາລອງ 97.26% .

Musical Instrument Recognition Using Their Distinctive Characteristics in Artificial Neural Networks ໂດຍ Toghiani-Rizi ແລະ Windmark (2017) ໄດ້ສຶກສາການຈໍາແນກເຄື່ອງດົນຕີ ໂດຍນໍາໃຊ້ເຄືອຂ່າຍປະສາດທຽມ (ANN) ທີ່ວິເຄາະຄຸນລັກສະນະສະເພາະຂອງສຽງດົນຕີ. ໃນການສະກັດຄຸນ ລັກສະນະ (feature extraction), ພວກເຂົາໄດ້ແປງສັນຍານສຽງຈາກ time domain ເປັນ frequency domain ໂດຍໃຊ້ Fast Fourier Transform (FFT), ຈາກນັ້ນຈຶ່ງທໍາການຕັດຄວາມຖີ່ທີ່ເກີນ 1000 Hz ອອກ , ປັບຄວາມຖີ່ໃຫ້ທຸກສັນຍານມີລັກສະນະຄ້າຍຄືກັນ (frequency shift), ແບ່ງ spectrum ອອກເປັນ 50 ສ່ວນ

ເພື່ອຈັດການຂໍ້ມູນ, ແລະ ປັບຄ່າໃຫ້ເປັນມາດຕະຖານ (normalization). ແບບຈຳລອງທີ່ໃຊ້ໃນການຝຶກແມ່ນ ເຄືອຂ່າຍປະສາດທຽມແບບ Multilayer Perceptron (MLP) ທີ່ມີ 50 ໂນດຂາເຂົ້າ, 30 ໂນດຊັ້ນຮັບ, ແລະ 8 ໂນດຂາອອກ, ໃຊ້ວິທີການຮຽນຮູ້ແບບ Resilient Back Propagation (Rprop) ພ້ອມກັບເຕັກນິກ Early Stopping. ຂໍ້ມູນທີ່ໃຊ້ແມ່ນມາຈາກຊຸດຂໍ້ມູນ London Philharmonic Orchestra ທີ່ມີຕົວຢ່າງສຽງຈາກ ເຄື່ອງດົນຕີ 8 ຊະນິດລວມທັງໝົດ 1,244 ຕົວຢ່າງ ເຊິ່ງຖືກແບ່ງເປັນຂໍ້ມູນຝຶກ 60%, ຂໍ້ມູນກວດສອບ 20% ແລະ ຂໍ້ມູນທົດສອບ 20%. ຜົນທີ່ໄດ້ຮັບສະແດງໃຫ້ເຫັນວ່າການໃຊ້ຂໍ້ມູນສຽງທັງໝົດໃຫ້ຄວາມແມ່ນຍຳ 93.5%, ໃນຂະນະທີ່ການໃຊ້ສະເພາະສ່ວນ attack ຂອງສຽງໃຫ້ຄວາມແມ່ນຍຳ 80.2%, ແລະ ການໃຊ້ສະເພາະ ຄວາມຖີ່ 100 Hz ທຳອິດໃຫ້ຄວາມແມ່ນຍຳພຽງ 64.2%, ເຊິ່ງສະແດງໃຫ້ເຫັນເຖິງຄວາມສຳຄັນຂອງສ່ວນຕ່າງໆ ຂອງສຽງໃນການຈຳແນກເຄື່ອງດົນຕີ.


ບົດຄົ້ນຄວ້າ Deep Convolutional Neural Networks for Predominant Instrument Recognition in Polyphonic Music (Han et al., 2016) ໄດ້ນຳສະເໜີການຈຳແນກເຄື່ອງດົນຕີຫຼັກໃນເພງດົນຕີແບບຫຼາຍ ສຽງໂດຍໃຊ້ CNN, ເຊິ່ງໃນການສະກັດຄຸນລັກສະນະ (feature extraction) ພວກເຂົາໄດ້ນຳໃຊ້ Log-Mel spectrogram ແບບ multi-resolution ທີ່ມີ 96 mel bins ແລະ ແບ່ງເປັນຄ່າ logarithmic ເພື່ອໃຫ້ເໝາະກັບ ການຮັບຮູ້ຂອງມະນຸດ, ຈາກນັ້ນຈຶ່ງວາງລຽງເປັນ 3 ແຖວທີ່ມີຄວາມລະອຽດແຕກຕ່າງກັນ. ແບບຈຳລອງທີ່ໃຊ້ຝຶກ ແມ່ນ CNN ທີ່ມີການສ້າງດ້ວຍ 5 ຊັ້ນ convolutional ທີ່ມີຕົວກອງ (filter) ຂະໜາດຕ່າງກັນ, ຕາມດ້ວຍ 2 ຊັ້ນ fully-connected ແລະ 1 ຊັ້ນ softmax ສຳລັບການຈຳແນກ. ຊຸດຂໍ້ມູນທີ່ໃຊ້ໃນການທົດລອງແມ່ນ MedleyDB ເຊິ່ງປະກອບດ້ວຍສ່ວນສຽງດົນຕີຈາກ 11 ປະເພດເຄື່ອງດົນຕີ, ມີການແບ່ງຂໍ້ມູນສຳລັບການຝຶກ 70% (1,437 ຕົວຢ່າງ), ກວດສອບ 10% (205 ຕົວຢ່າງ) ແລະ ທົດສອບ 20% (411 ຕົວຢ່າງ), ນອກຈາກນີ້ພວກເຂົາຍັງນຳໃຊ້ ເຕັກນິກ data augmentation ເພື່ອເພີ່ມຈຳນວນຕົວຢ່າງທີ່ໃຊ້ໃນການຝຶກ. ຜົນການທົດລອງສະແດງໃຫ້ເຫັນວ່າ ແບບຈຳລອງສາມາດບັນລຸຄວາມແມ່ນຍຳ (accuracy) ສູງເຖິງ 89.8% ໃນຊຸດທົດສອບ, ແລະ ເມື່ອທົດສອບກັບ ເພງຈິງທີ່ມີຫຼາຍເຄື່ອງດົນຕີຫຼິ້ນພ້ອມກັນ ແບບຈຳລອງຍັງສາມາດຈຳແນກເຄື່ອງດົນຕີຫຼັກໄດ້ຢ່າງຖືກຕ້ອງ, ຝຶກ ໃຫ້ເຫັນວ່າເຕັກນິກ CNN ມີປະສິດທິພາບສູງໃນການຈຳແນກເຄື່ອງດົນຕີຈາກສຽງ ແມ້ແຕ່ໃນສະພາບແວດລ້ອມ ທີ່ມີສຽງຊ້ອນກັນຫຼາຍແຫຼ່ງ.

ບົດທີ 3

ວິທີດຳເນີນການຄົ້ນຄວ້າ

3.1. ວິທີການສຶກສາ ແລະ ຄົ້ນຄວ້າ

ໃນຂະບວນການພັດທະນາ ການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງນັ້ນຈະທຳການນຳໃຊ້ເທັກນິກຫຼາຍຢ່າງໂດຍສະເພາະແມ່ນຢູ່ໃນຮູບແບບຂອງການວິເຄາະແບບນຳໃຊ້ Deep Learning ເປັນຫຼັກເຊິ່ງເປັນຂະບວນການໃນການພັດທະນາແບບຈຳລອງດັ່ງກ່າວ ນີ້ ໄດ້ອີງໃສ່ຂະບວນການ CRISP-DM (Cross-industry standard process for data mining) ເຂົ້າມາຊ່ວຍເພື່ອເຫັນເຖິງຄວາມເປັນໄປໄດ້ໃນການສ້າງແບບຈຳລອງທີ່ມີປະສິດທິພາບໂດຍອີງຕາມຂະບວນການດັ່ງກ່າວນີ້ເປັນໄປຕາມຂັ້ນຕອນ



ຮູບທີ 3.1 CRISP-DM (Cross-industry standard process for data mining)
ມາດຕະຖານການປະມວນຜົນເພື່ອສ້າງແບບຈຳລອງໃນຮູບແບບຂອງການຊຸດຄົ້ນຂໍ້ມູນ

3.1.1. ຄວາມເຂົ້າໃຈຕໍ່ກັບບັນຫາ (Business Understanding)

ໃນປັດຈຸບັນເຄື່ອງດົນຕີຜື້ນເມືອງລາວເປັນມໍລະດົກທາງວັດທະນະທຳທີ່ສຳຄັນຂອງຊາດ ເຊິ່ງສະແດງເຖິງເອກະລັກ ແລະ ຄວາມເປັນມາອັນຍາວນານຂອງປະເທດລາວ, ແຕ່ໃນຍຸກປັດຈຸບັນທີ່ເຕັກໂນໂລຊີມີການພັດທະນາຢ່າງວ່ອງໄວ ເຮັດໃຫ້ຄົນລຸ້ນໃໝ່ມີຄວາມສົນໃຈໃນດົນຕີຜື້ນເມືອງໜ້ອຍລົງ, ການຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີຜື້ນເມືອງກໍ່ເປັນໄປໄດ້ຍາກຢູ່ຂຶ້ນ ເນື່ອງຈາກຂາດເຄື່ອງມືທີ່ທັນສະໄໝໃນການສຶກສາ ແລະ ເຂົ້າເຖິງຂໍ້ມູນ. ດັ່ງນັ້ນ, ການພັດທະນາລະບົບຈຳແນກເຄື່ອງດົນຕີຜື້ນເມືອງລາວດ້ວຍສຽງໂດຍນຳໃຊ້ເຕັກນິກ Deep Learning ຈຶ່ງເປັນການນຳເອົາເຕັກໂນໂລຊີສະໄໝໃໝ່ມາປະຍຸກໃຊ້ໃນການອະນຸລັກວັດທະນະທຳໃນດ້ານການໃຫ້ຂໍ້ມູນປະຫວັດຄວາມເປັນມາຂອງເຄື່ອງດົນຕີທັງ 6 ປະເພດ, ອີກທັງຍັງເປັນການສົ່ງເສີມການອະນຸລັກ ແລະ ສືບທອດມໍລະດົກທາງວັດທະນະທຳອັນລ້ຳຄ່ານີ້ໃຫ້ຄົງຢູ່ຄູ່ກັບຊາດລາວຕໍ່ໄປ. ນອກຈາກນັ້ນ, ການສຶກສານີ້ຍັງເປັນການພັດທະນາອົງຄວາມຮູ້ທາງດ້ານ Deep Learning ໃນການຈຳແນກສຽງເຄື່ອງດົນຕີອີກດ້ວຍ

ໂດຍສະຫຼຸບແລ້ວສິ່ງທີ່ຈະສາມາດແກ້ໄຂບັນຫາດັ່ງກ່າວນີ້ໄດ້ຈະມີຢູ່ສອງພາກສ່ວນໃນການພັດທະນາຂອງພວກຂ້າພະເຈົ້າຄື:

- ການຈຳແນກປະເພດເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດໂດຍການວິເຄາະຜ່ານສຽງຂອງເຄື່ອງດົນຕີດັ່ງກ່າວ
- ໃຫ້ຂໍ້ມູນກ່ຽວກັບເຄື່ອງດົນຕີປະເພດດັ່ງກ່າວພາຍຫຼັງການຈຳແນກສຳເລັດຜົນ ເພື່ອສົ່ງເສີມການອະນຸລັກ ແລະ ໃຫ້ຄວາມຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີຜື້ນເມືອງລາວທັງ 6 ປະເພດເຊັ່ນ: ແຄນ (Khean) , ຊໍອູ້ (Saw U), ລະນາດ (Ra nad), ຄໍອງວົງ (Khong vong), ຊິ່ງ (Sing), ຝິນ (Pin) ແລະ ເພີ່ມ class unknown ເພື່ອຈັດການກັບສຽງອື່ນທີ່ບໍ່ແມ່ນສຽງຂອງເຄື່ອງດົນຕີທັງ 6.

3.1.2. ຄວາມເຂົ້າໃຈຕໍ່ກັບຂໍ້ມູນ (Data Understanding)

1) ຂໍ້ມູນສຽງ

ກ່ອນອື່ນໝົດເຮົາຕ້ອງເຂົ້າໃຈກ່ອນວ່າ ສຽງທີ່ຄົນເຮົາໄດ້ຍິນ ແລະ ການກຳເນີດຂອງສຽງທີ່ເກີດຂຶ້ນມັນມາຈາກປັດໄຈຜື້ນຖານຫຼັກກໍ່ຄືຄືຄວາມຖີ່ເຊິ່ງມັນເກີດຈາກການສັ່ນສະເທືອນຂອງວັດຖຸໃດຫນຶ່ງ (sound wave) ແລ້ວມັນເຄື່ອນທີ່ຜ່ານຕົວກາງເຊັ່ນ: ອາກາດ, ນ້ຳ, ຫຼື ແມ້ແຕ່ວັດຖຸຂອງແຂງຜ່ານເຂົ້າມາຫາຊັ້ນໃນຫູຂອງມະນຸດເຊິ່ງຈະມີຂົນນ້ອຍໆ (hair cells) ຈຸລັງເຫຼົ່ານີ້ຈະປ່ຽນແຮງສັ່ນສະເທືອນໃຫ້ກາຍເປັນສັນຍານໄຟຟ້າແລ້ວມັນຈະຖືກສົ່ງຜ່ານເສັ້ນປະສານຫູ (auditory nerve) ໄປຫາສະໝອງສ່ວນປະມວນຜົນການໄດ້ຍິນຂອງມະນຸດ (auditory cortex) ແລະມັນກໍ່ແມ່ນການຮັບຮູ້ການເກີດຂຶ້ນຂອງສຽງໃນມະນຸດ. ການທີ່ເຮົາຈະຮູ້ຈັກກັບວິທີການແປງຄື້ນສັ່ນສະເທືອນໃຫ້ກັບຄອມພິວເຕີຮັບຮູ້ໄດ້ນັ້ນຕ້ອງຮູ້ຈັກກັບຄຸນລັກສະນະທີ່ສຳຄັນຂອງສຽງກັນກ່ອນ.

ສຽງມີຄຸນລັກສະນະທີ່ສຳຄັນຫຼາຍປະການທີ່ເຮັດໃຫ້ເຮົາສາມາດແຍກແຍະຄວາມແຕກຕ່າງໄດ້:

ກ. ຄວາມຖີ່ (Frequency) ມີຫົວໜ່ວຍແມ່ນ (Hz) ແມ່ນຈຳນວນຮອບຂອງການສັ່ນສະເທືອນຕໍ່ວິນາທີ ສຽງທີ່ມີຄວາມຖີ່ສູງຈະໃຫ້ໂທນສຽງທີ່ສູງ (ສຽງແຫຼມ) ສ່ວນສຽງທີ່ມີຄວາມຖີ່ຕໍ່າຈະໃຫ້ໂທນສຽງຕໍ່າ (ສຽງທຸ້ນ) ເຊິ່ງມະນຸດສາມາດໄດ້ຍິນສຽງໃນຊ່ວງຄວາມຖີ່ປະມານ 20Hz ຫາ 20000Hz ແລະຈະຫຼຸດລົງຕາມອາຍຸ.

ຂ. ຄວາມດັງ (Amplitude) ມີຫົວໜ່ວຍແມ່ນ (dB) ສະແດງໃຫ້ເຫັນເຖິງຄວາມເຂັ້ມຂອງສຽງຫຼື ພະລັງງານຂອງຄື້ນສຽງຍິ່ງມີຄວາມດັງທີ່ຫຼາຍຄື້ນສຽງຈະມີ ຄ່າ ເດຊິເບວ (dB) ທີ່ສູງຂຶ້ນ.

ຄ. ຄຸນນະພາບສຽງ (Timbre) ລັກສະນະສະເພາະຂອງສຽງທີ່ເຮັດໃຫ້ເຮົາສາມາດແຍກແຍະສຽງທີ່ມີຄວາມຖີ່ ແລະ ຄວາມດັງເທົ່າກັນແຕ່ມາຈາກຕົ້ນກຳເນີດທີ່ແຕກຕ່າງກັນຕົວຢ່າງ: ສຽງໄວໂອລິນ ກັບ ສຽງຊຸ່ຍທີ່ຫຼິ້ນໂນດດຽວກັນດ້ວຍຄວາມດັງເທົ່າກັນແຕ່ຝັງແລ້ວຮູ້ສຶກເປັນຄົນລະເຄື່ອງດົນຕີຄຸນນະພາບສຽງເກີດຈາກຄວາມຊັບຊ້ອນຂອງຄຸ້ນສຽງເຊິ່ງປະກອບໄປດ້ວຍຄວາມຖີ່ຫຼັກ (fundamental frequency) ແລະ ຄວາມຖີ່ຮ່າໂມນີ (harmonic frequency).

ງ. ໄລຍະເວລາ (Duration) ຊ່ວງໄລຍະທີ່ມີສຽງເກີດຂຶ້ນນັບແຕ່ຕົ້ນຈົນສຽງໝົດໄປ.

Envelope ຮູບແບບການປ່ຽນແປງຕາມຄວາມດັງຂອງສຽງຕາມເວລາຈະປະກອບມີ:

- Attack: ຊ່ວງເລີ່ມຕົ້ນຂອງສຽງ
- Decay: ຊ່ວງຫຼຸດຄວາມດັງລົງຫຼັງຈາກ Attack
- Sustain: ຊ່ວງຄົງຄວາມດັງໄວ້ລະດັບໜຶ່ງ
- Release: ຊ່ວງຄ່ອຍໆງຽບລົງ

ຄຸນສົມບັດເຫຼົ່ານີ້ເຮັດໃຫ້ເຄື່ອງດົນຕີແຕ່ລະຊະນິດມີເອກະລັກສະເພາະ ແລະ ເປັນພື້ນຖານສຳຄັນທີ່ເຮັດໃຫ້ເຮົາສາມາດໃຊ້ເຕັກນິກ deep learning ໃນການຈຳແນກປະເພດຂອງເຄື່ອງດົນຕີໄດ້

2) ການປ່ຽນແປງສຽງເປັນຂໍ້ມູນດິຈິຕໍ້

ການນຳສຽງມາປະມວນຜົນດ້ວຍຄອມພິວເຕີຈຳເປັນຈະຕ້ອງປ່ຽນຂໍ້ມູນຄຸ້ນສຽງອະນາລັອກ analog (ສຽງທີ່ບໍ່ໄດ້ຜ່ານຂະບວນການທາງເຕັກໂນໂລຊີ) ໃຫ້ເປັນຂໍ້ມູນສຽງແບບດິຈິຕໍ້ digital ເຊິ່ງປະກອບດ້ວຍຂະບວນການດັ່ງຕໍ່ໄປນີ້:

ກ. ການສຸ່ມຕົວຢ່າງ (Sampling) ແມ່ນຂະບວນການວັດ ຄວາມດັງ (amplitude) ຂອງຄຸ້ນສຽງ analog ຊ່ວງເວລາຕ່າງໆ, ຄວາມຖີ່ໃນການສຸ່ມຕົວຢ່າງ (Sampling Rate) ຄືຈຳນວນຄັ້ງຕໍ່ວິນາທີທີ່ເລີ່ມການວັດມີຫົວໜ່ວຍເປັນ Hertz (Hz) ຫຼື Sample per second ຕາມທົດສະດີຂອງ Nyquist-Shannon sampling theorem ອັດຕາການສຸ່ມຕົວຢ່າງຕ້ອງຫຼາຍກວ່າສອງເທົ່າຂອງຄວາມຖີ່ສູງສຸດໃນສັນຍານສຽງທີ່ຕ້ອງການບັນທຶກເພື່ອໃຫ້ສາມາດບັນທຶກແລະສ້າງສຽງທີ່ກັບມາໄດ້ຢ່າງສົມບູນແບບຕົວຢ່າງ:

- ສຽງໂທລະສັບ: ຢູ່ທີ່ 8,000 Hz ສາມາດບັນທຶກຄວາມຖີ່ໄດ້ເຖິງ 4,000 Hz
- ສຽງ CD ຄຸນນະພາບ: 44,100 Hz ສາມາດບັນທຶກຄວາມຖີ່ໄດ້ເຖິງ 20,050 Hz ເຊິ່ງເປັນຄວາມຖີ່ທີ່ຄອບຄຸມໄລຍະການໄດ້ຍິນຂອງມະນຸດ
- ສຽງລະດັບສະຕູດີໂອ: 48,000 Hz 96,000 Hz ຫຼືອາກຈະສູງກວ່າ

ສັນຍານສຽງທີ່ຈະໃຊ້ບັນທຶກເພື່ອເກັບຂໍ້ມູນແມ່ນຈະຢູ່ທີ່ 44,100 Hz (sampling rate) ເຫດຜົນຫຼັກໆ ທີ່ພວກຂ້າພະເຈົ້າໄດ້ເລືອກເອົາອັດຕາການສຸ່ມຕົວຢ່າງ (sampling rate) ຢູ່ທີ່ 44,100 Hz ເນື່ອງຈາກເປັນມາດຕະຖານທີ່ໃຊ້ໃນການບັນທຶກສຽງດົນຕີທີ່ໜ້າໄປ ສາມາດຄອບຄຸມໄລຍະຄວາມຖີ່ທີ່ມະນຸດໄດ້ຍິນ (20 - 20,000 Hz) ແລະເປັນອັດຕາທີ່ໃຊ້ໃນວົງການສຽງດິຈິຕອນຢ່າງແຜ່ຫຼາຍ ແລະ ຍັງໃຫ້ຄວາມລະອຽດຂອງສຽງໄດ້ຊັດເຈນ, ການໃຊ້ອັດຕາ (sampling rate) ທີ່ສູງກວ່ານີ້ຈະເຮັດໃຫ້ຂະໜາດ file ໃຫຍ່ຂຶ້ນໂດຍບໍ່ຈຳເປັນ ແລະ ເພີ່ມພາລະໃຫ້ກັບການປະມວນຜົນອີກດ້ວຍ.

ຂ. Quantization ເປັນຂະບວນການແປງຄ່າ Amplitude ທີ່ວັດໄດ້ໃຫ້ເປັນຄ່າດິຈິຕອນທີ່ມີຄວາມລະອຽດທີ່ແນ່ນອນມັກວັດໃນຫົວໜ່ວຍ (bit) ແຮງມີຈຳນວນບິດຫຼາຍການແທນຄ່າລະດັບຄວາມດັງຈະລະອຽດຫຼາຍຂຶ້ນຫຼັກໆຈະມີຢູ່ 3 ຄ່າ:

- 8 bit: 256 ລະດັບແມ່ນຖືກໃຊ້ໃນ file ສຽງຄຸນນະພາບຕ່ຳ
- 16 bit: 66,536 ລະດັບແມ່ນຄ່າລະດັບມາດຕະຖານທີ່ຄວບຄູ່ໄປກັບ ສຽງ CD ຄຸນນະພາບ: 44,100 Hz (ເປັນຄ່າທີ່ພວກຂ້າພະເຈົ້າເລືອກໃຊ້ໃນໂຄງການນີ້)
- 24 bit: 16,777,216 ລະດັບແມ່ນຖືກໃຊ້ໃນການບັນທຶກລະດັບສະຖິຕິໂອຂະໜາດໃຫຍ່.

ຄ. ການບີບອັດຂໍ້ມູນ (Compression) ເປັນເຕັກນິກໃນການຫຼຸດຂະໜາດຂອງ file ສຽງດິຈິຕອນໂດຍແບ່ງເປັນສອງຢ່າງຫຼັກໆຄື:

- ການບີບອັດແບບບໍ່ສຸນເສຍ (lossless compression) ຂໍ້ມູນທັງໝົດຂອງສຽງຈະຖືກເກັບໄວ້ຢູ່ໃນນາມສະກຸນ File ຈຳພວກ WAV, FLAC ແລະ ALAC ເປັນຕົ້ນ
- ການບີບອັດແບບສຸນເສຍ (Lossy Compression) ຈະເປັນການບີບອັດຄວາມລະອຽດຂອງສຽງໃຫ້ມີຂະໜາດທີ່ນ້ອຍລົງຕັດສຽງຂອງສ່ວນທີ່ມະນຸດບໍ່ໄດ້ຍິນອອກເຊັ່ນຈຳພວກ MP3, MP4, AAC

ໃນໂຄງການນີ້ພວກຂ້າພະເຈົ້າໄດ້ເລືອກໃຊ້ File ສຽງໃນຮູບແບບຂອງ WAV (Waveform Audio File Format) ເຊິ່ງເປັນຮູບແບບ File ດິຈິຕອນທີ່ບໍ່ໄດ້ມີການບີບອັດເພື່ອຮັກສາຄຸນນະພາບຂອງສຽງໃຫ້ໄດ້ດີທີ່ສຸດສຳລັບການວິເຄາະແລະປ້ອງກັນຄວາມຜິດພາດທີ່ອາດຈະເກີດຂຶ້ນໃນລະຫວ່າງການທຳຄວາມສະອາດຂໍ້ມູນ (Data Cleaning)

3) ການປະມວນຜົນສັນຍານສຽງດິຈິຕອນ (Digital Signal Processing for Audio)


ພວກຂ້າພະເຈົ້າໄດ້ເລືອກໃຊ້ເຕັກນິກ HPSS (Harmonic-Percussive Source Separation) ແລະ Multi-Channel Feature Extraction ເປັນຫຼັກໃນການສະກັດຄຸນລັກສະນະຂອງສຽງເຄື່ອງດົນຕີທັງ 6 ປະເພດ. HPSS ຊ່ວຍແຍກສຽງອອກເປັນສອງອົງປະກອບຄື: ສຽງ Harmonic ເຊິ່ງເປັນສຽງທີ່ມີຄວາມຖີ່ທີ່ສະໜ້າສະເໝີແລະຕໍ່ເນື່ອງ ເຊັ່ນ: ສຽງຂອງ ແຄນ ແລະ ຊໍ, ແລະ ສຽງ Percussive ເຊິ່ງເປັນສຽງທີ່ມີຈັງຫວະແລະມີການປ່ຽນແປງແບບກະທັນຫັນ ເຊັ່ນ: ສຽງຂອງ ຄໍ້ອງວົງ ແລະ ລະນາດ. ການແຍກນີ້ຊ່ວຍໃຫ້ລະບົບສາມາດວິເຄາະຄຸນລັກສະນະສະເພາະຂອງແຕ່ລະປະເພດສຽງໄດ້ດີຂຶ້ນ, ໂດຍສະເພາະແມ່ນຊ່ວງການເລີ່ມຕົ້ນຂອງສຽງ (Attack), ການຄົງຢູ່ (Sustain) ແລະ ການຫາຍໄປຂອງສຽງ (Decay). ນອກຈາກນັ້ນ, ການນຳໃຊ້ຮູບແບບຂໍ້ມູນແບບຫຼາຍຊ່ອງທາງ (Multi-Channel) ໂດຍລວມມີ Mel Spectrogram, MFCCs, ແລະ Delta, Delta Delta ຍັງຊ່ວຍໃຫ້ໂຄງຂ່າຍປະສາດທຽມແບບຄອນໂວລູຊັນ (CNN) ສາມາດຮຽນຮູ້ຮູບແບບຄຸນລັກສະນະທີ່ຊັບຊ້ອນຂອງແຕ່ລະເຄື່ອງດົນຕີໄດ້ຢ່າງມີປະສິດທິພາບສູງ ເນື່ອງຈາກຮູບແບບຂໍ້ມູນທັງໝົດນີ້ແມ່ນຂໍ້ມູນສອງມິຕິທີ່ເໝາະສົມກັບສະຖາປັດຕະຍະກຳ CNN.

4) ການເກັບລວບລວມຂໍ້ມູນ

ໃນການພັດທະນາລະບົບຈຳແນກເຄື່ອງດົນຕີຜື້ນເມືອງລາວ, ການທຳຄວາມເຂົ້າໃຈກັບຂໍ້ມູນແມ່ນມີຄວາມສຳຄັນຫຼາຍ. ຂໍ້ມູນທີ່ໃຊ້ໃນການພັດທະນາລະບົບປະກອບດ້ວຍສຽງຂອງເຄື່ອງດົນຕີຜື້ນເມືອງລາວທັງ 6 ປະເພດ ເຊິ່ງມີລາຍລະອຽດດັ່ງນີ້:

ກ. ການຄັດເລືອກປະຊາກອນ


ຂໍ້ມູນໃນການສຶກສາຄັ້ງນີ້ແມ່ນໄດ້ກຳນົດເອົາການບັນທຶກສຽງຈາກເຄື່ອງດົນຕີແຕ່ລະອັນທັງ 6 ປະເພດ ໃຫ້ມີຂະໜາດຂອງຂໍ້ມູນຕໍ່ file ຫນຶ່ງຢູ່ປະມານ 6-10 ວິນາທີ ເປັນການບັນທຶກຜ່ານເຄື່ອງດົນຕີຂອງໃຜ ມັນແບບດ່ຽວໂດຍກົງທີ່ມີຢູ່ 4 ຢ່າງເຊັ່ນ: ຊໍອູ້, ແຄນ, ຊິ່ງ, ຝິນ ແລະ ຍັງໄດ້ບັນທຶກສຽງໃນອິນເຕີເນັດຜ່ານ ແຟດຟອມ youtube.com ແລະ ແຟດຟອມ facebook.com ສິ່ງສຳຄັນຫຼັກໆທີ່ຂໍ້ມູນຄວນທີ່ຈະມີແມ່ນຄວາມ ຊັດເຈນຂອງສຽງເຄື່ອງດົນຕີປະເພດດ່ຽວເພື່ອໃຫ້ແບບຈຳລອງມີການຈຳແນກສຽງເຄື່ອງດົນຕີຂອງແຕ່ລະ 6 ປະເພດໄດ້ຢ່າງຊັດເຈນ.




ຮູບທີ 3.2 ຮູບພາບເຄື່ອງດົນຕີທີ່ພວກຂ້າພະເຈົ້າມີ

ຈາກໃນຮູບພາບສັງເກດເຫັນໄດ້ວ່າຍັງເຫຼືອອີກສອງເຄື່ອງດົນຕີພວກຂ້າພະເຈົ້າບໍ່ມີເຊັ່ນ ຊໍອູ້ ແລະ ຄ້ອງວົງ ທີ່ບໍ່ໄດ້ເກັບກັບເຄື່ອງໂຕຈົງແຕ່ບໍ່ໄດ້ເປັນບັນຫາເພາະເຄື່ອງດົນຕີແຕ່ລະໂຕກໍຕ້ອງໄດ້ບັນທຶກເພີ່ມຂໍ້ມູນທີ່ຫຼາກ ຫລາຍຜ່ານແຟດຟອນທີ່ໄດ້ກ່າວໄປ.


ຕົວຢ່າງລັກສະນະຂອງຂໍ້ມູນທີ່ຜ່ານການປະມວນຜົນສັນຍານສຽງດິຈິຕອນໃຫ້ຢູ່ໃນຮູບແບບຂອງ Mel Spectrogram ທັງ 6 ປະເພດ:




ຮູບທີ 3.3 ສຽງແຄນໃນຮູບແບບຂອງພາບ Mel Spectrogram




ຮູບທີ 3.4 ສຽງຄ້ອງໃນຮູບແບບຂອງພາບ Mel Spectrogram




ຮູບທີ 3.5 ສຽງຟິນໃນຮູບແບບຂອງພາບ Mel Spectrogram



ຮູບທີ 3.6 ສຽງລະນາດໃນຮູບແບບຂອງພາບ Mel Spectrogram



ຮູບທີ 3.7 ສຽງຊໍ່ໃນຮູບແບບຂອງພາບ Mel Spectrogram



ຮູບທີ 3.8 ສຽງຊິງໃນຮູບແບບຂອງພາບ Mel Spectrogram

ຂ. ການກຳນົດຕົວຢ່າງຈຳນວນປະຊາກອນ

ຈຳນວນຂໍ້ມູນປະຊາກອນຊຸດຂໍ້ມູນ (Dataset) ແມ່ນການກຳນົດເອົາການບັນທຶກສຽງອອກເປັນ 7 ພາກສ່ວນຕໍ່ໜຶ່ງເຄື່ອງດົນຕີ ຫຼືກໍຄືການແບ່ງ 7 Folders ຕໍ່ເຄື່ອງດົນຕີ ແລະແຕ່ລະພາກສ່ວນຈະມີວິທີການບັນທຶກສຽງເຄື່ອງດົນຕີແຕ່ລະຢ່າງແຕກຕ່າງກັນເພື່ອໃຫ້ໄດ້ຂໍ້ມູນທີ່ມີຄວາມຫຼາກຫຼາຍທີ່ພຽງພໍເຊັ່ນ:

- ພາກສ່ວນທີ 1 (session 1): ບັນທຶກສະເພາະສຽງເຄື່ອງດົນຕີບໍ່ມີສຽງເພງຫລືສຽງລົບກວນອື່ນລັກສະນະຄືກັບບັນທຶກໂນດ (ບັນທຶກຈາກເຄື່ອງດົນຕີແທ້ຖ້າມີ)
- ພາກສ່ວນທີ 2 (session 2): ບັນທຶກສຽງເຄື່ອງດົນຕີທີ່ມີລະດັບຄວາມດັງຂອງສຽງ (ສຽງແຮງ - ສຽງຄ່ອຍ) ທີ່ແຕກຕ່າງກັນ
- ພາກສ່ວນທີ 3 (session 3): ບັນທຶກສຽງຮູບແບບການຫລິ້ນເຄື່ອງດົນຕີໃຫ້ໄດ້ຫຼາຍແບບ
- ພາກສ່ວນທີ 4 (session 4): ປ່ຽນໄລຍະຫ່າງໃນການບັນທຶກສຽງສາມໄລຍະໃກ້ສຸດ, ຫ່າງ 1 ແມັດ, ຫ່າງ 2 ແມັດ ຈາກຕົວກະຈາຍສຽງ
- ພາກສ່ວນທີ 5 (session 5): ບັນທຶກສຽງເຄື່ອງດົນຕີໂດຍມີການຫຼິ້ນສຽງລົບກວນຟື້ນຫຼັງ
- ພາກສ່ວນທີ 6 (session 6): ພາກສ່ວນສຳຮອງໃນການເພີ່ມຂໍ້ມູນສຽງຂອງເຄື່ອງດົນຕີທຸກຮູບແບບ
- ພາກສ່ວນທີ 7 (session 7): ພາກສ່ວນສຳຮອງຊຸດທີ່ສອງໃນການເພີ່ມຂໍ້ມູນສຽງຂອງເຄື່ອງດົນຕີທຸກຮູບແບບຂຶ້ນເປັນສອງເທົ່າ

ພາຍຫຼັງທີ່ໄດ້ບັນທຶກມາແລ້ວສາມາດສະຫຼຸບຈຳນວນຂອງຂໍ້ມູນສຽງແຕ່ລະເຄື່ອງດົນຕີໄດ້ດັ່ງນີ້ຕາມຕາຕະລາງທີ 3.1 ດັ່ງນີ້:

ຕາຕະລາງທີ 3.1 ສະແດງການກະຈາຍຕົວຂອງຂໍ້ມູນຂອງແຕ່ລະໝວດໝູ່

ເຄື່ອງດົນຕີ	ພາກສ່ວນ ທີ 1	ພາກສ່ວນ ທີ 2	ພາກສ່ວນ ທີ 3	ພາກສ່ວນ ທີ 4	ພາກສ່ວນ ທີ 5	ພາກສ່ວນ ທີ 6	ພາກສ່ວນ ທີ 7	ລວມ
ແຄນ	20	20	20	20	20	41	154	295
ຄ້ອງວົງ	24	20	45	20	20	31	154	314
ລະນາດ	20	21	20	20	20	45	156	302
ຊໍອູ້	20	21	20	20	20	41	146	314
ຊິງ	20	20	20	20	20	43	152	295
ຟິນ	20	20	20	20	20	39	146	285
unknown	ສຽງອື່ນເຊັ່ນສະພາບແວດລ້ອມພາຍໃນ ແລະ ນອກ, ສຽງເວົ້າ, ສຽງອື່ນໆອີກທີ່ບໍ່ກ່ຽວກັບສຽງ ເຄື່ອງດົນຕີ							308
ລວມ								2,113

ພາຍຫຼັງທີ່ໄດ້ບັນທຶກຂໍ້ມູນສຽງເຄື່ອງດົນຕີທັງປະເພດແລ້ວຂໍ້ມູນທັງໝົດລວມມີ 2,113 ຟາຍ.

ຄ. ວິທີສຸມຕົວຢ່າງປະຊາກອນ

ຈາກຂໍ້ມູນຈົງທັງໝົດ 2,113 ຟາຍແມ່ນຈຳນວນທີ່ຕ້ອງໄດ້ເອົາໄປເຮັດການເພີ່ມຂໍ້ມູນ (data augmentation) ດ້ວຍການປັບປ່ຽນຄຸນລັກສະນະທາງສຽງ ເຊັ່ນ: SpecAugment (ການປົດບັງຄວາມຖີ່ ແລະ ເວລາໃນ spectrogram ໂດຍການປົດບັງຄວາມຖີ່ສູງສຸດ 27 ຊ່ອງ ແລະ ປົດບັງເວລາສູງສຸດ 100 steps), Mixup (ການປະສົມຂໍ້ມູນສອງຕົວຢ່າງເຂົ້າດ້ວຍກັນດ້ວຍຄ່າ α 0.4). ຂໍ້ມູນຈະຖືກແບ່ງອອກເປັນ 2 ຊຸດ ຫຼັກ: ຊຸດຂໍ້ມູນຝຶກສອນ (Training set) ຈຳນວນ 80% ແລະ ຊຸດຂໍ້ມູນທົດສອບ (Test set) ຈຳນວນ 20% ຂອງຂໍ້ມູນທັງໝົດ. ພາຍຫຼັງທີ່ໄດ້ທຳການປະມວນຜົນສຽງເພື່ອປ່ຽນຮູບແບບຂອງຟາຍສຽງໄປຢູ່ໃນຮູບແບບທີ່ແບບຈຳລອງສາມາດຮຽນຮູ້ໄດ້ຂໍ້ມູນຕົວຢ່າງ, ລວມທັງໝົດທີ່ຈະໄດ້ນຳໄປໃຊ້ຝຶກແບບຈຳລອງນັ້ນແມ່ນທັງໝົດມີຈຳນວນ 2,114 ຕົວຢ່າງ ແລະ ສຳລັບຊຸດຂໍ້ມູນຝຶກສອນນັ້ນຈະນຳໃຊ້ເທັກນິກ K-Fold Cross Validation ເພື່ອແບ່ງເປັນຊຸດຝຶກ ແລະ ຊຸດກວດສອບ (Validation) ໃນແຕ່ລະຮອບການຝຶກ. ເຊິ່ງໄດ້ນຳໃຊ້ເທັກນິກການຮຽນຮູ້ຂອງຄອມພິວເຕີ (Machine Learning) ດັ່ງນີ້:

$$D = D_{\text{Train}} + D_{\text{Test}} \quad D = D_{\text{Train}} + D_{\text{Test}} \quad (3.1)$$

D ແມ່ນຊຸດຂໍ້ມູນທັງໝົດ

DTrain ແມ່ນຊຸດຂໍ້ມູນຝຶກສອນແບບຈຳລອງ


DTest ແມ່ນຊຸດຂໍ້ມູນທົດສອບແບບຈຳລອງ

ງ. ແຫຼ່ງທີ່ມາຂໍ້ມູນ

ໃນການຄົ້ນຄວ້າຄັ້ງນີ້ໄດ້ທຳການເກັບຂໍ້ມູນສຽງຜ່ານເຄື່ອງດົນຕີຕົວຈິງ 4 ຢ່າງຄື: ລະນາດ, ແຄນ, ຊິງ, ພິນ ສ່ວນສຳລັບອີກສອງເຄື່ອງດົນຕີທີ່ບໍ່ມີຕົວຈິງເຊັ່ນ: ຄ້ອງວົງ, ຊໍອູ້ ແລະ ລວມໄປເຖິງຂໍ້ມູນສຽງອື່ນໆ ແມ່ນໄດ້ນຳວິທີການບັນທຶກຜ່ານ youtube ແລະ facebook ແລະ ຍັງໄດ້ບັນທຶກສຽງເຄື່ອງດົນຕີແຕ່ລະປະເພດໃນອິນເຕີເນັດຜ່ານແຟດຟອມ youtube.com ແລະ ແຟດຟອມ facebook.com ເພື່ອໃຫ້ໄດ້ຂໍ້ມູນທີ່ມີຄວາມຫຼາກຫຼາຍຢູ່ຂຶ້ນ.

ຈ. ວິທີການເກັບຂໍ້ມູນ


ພວກຂ້າພະເຈົ້າໄດ້ທຳການເກັບຂໍ້ມູນສຽງຂອງເຄື່ອງຫຼິ້ນດົນຕີ ແລະ ສຽງລົບກວນອື່ນ ທັງ 7 ປະເພດຜ່ານການບັນທຶກສຽງໂດຍນຳໃຊ້ແອັບພິເຄຊັນບັນທຶກສຽງ (Voice Recorder) ທີ່ສາມາດປັບຄວາມລະອຽດການບັນທຶກສຽງສູງສຸດໄດ້ຢູ່ທີ່ 44100 Hz sample rate ເພື່ອໃຫ້ໄດ້ຄວາມລະອຽດຂອງສຽງທີ່ຊັດເຈນທີ່ສຸດ



ຮູບທີ 3.9 ແອັບ Voice Recorder ທີ່ໃຊ້ເກັບຂໍ້ມູນສຽງປັບຄວາມລະອຽດໄດ້ສູງສຸດ 44Khz

ໃນການເກັບຂໍ້ມູນພວກຂ້າພະເຈົ້າໄດ້ມີການວາງແຜນເກັບຂໍ້ມູນສຽງໃຫ້ມີຄວາມຫຼາກຫຼາຍທີ່ສຸດໂດຍການແບ່ງການບັນທຶກສຽງອອກເປັນ 7 folders (7 sessions) ຕໍ່ໜຶ່ງເຄື່ອງດົນຕີໂດຍແຕ່ລະ folder ຈະມີຮູບແບບບັນທຶກສຽງທີ່ແຕກຕ່າງກັນ.

ການຈັດການກັບຟາຍສຽງຂອງເຄື່ອງດົນຕີແຕ່ລະປະເພດໃຫ້ຢູ່ໃນ folder ຂອງແຕ່ລະພາກສ່ວນແມ່ນພວກຂ້າພະເຈົ້າໄດ້ນຳໃຊ້ແອັບພິເຄຊັນ ZArchiver ເພື່ອເປັນໂຕຈັດການກັບຟາຍ ແລະ ຈັດເກັບໄວ້ໃນ folder ທີ່ຖືກຕ້ອງຕາມແຕ່ລະພາກສ່ວນ.



ຮູບທີ 3.10 ແອັບ ZArchiver ທີ່ໃຊ້ຈັດການຟາຍໃຫ້ຢູ່ໃນແຕ່ລະພາກສ່ວນ

3.1.3. ການກະກຽມຂໍ້ມູນ (Data Preparation)


ການກະກຽມຂໍ້ມູນເປັນຂັ້ນຕອນທີ່ສໍາຄັນໃນການພັດທະນາລະບົບຈຳແນກສຽງເຄື່ອງດົນຕີລາວ. ຂັ້ນຕອນນີ້ປະກອບດ້ວຍຫຼາຍຂະບວນການເພື່ອຮັບປະກັນວ່າຂໍ້ມູນມີຄຸນນະພາບສູງ ແລະ ເໝາະສົມສໍາລັບການນຳໃຊ້ໃນການຝຶກແບບຈຳລອງ Deep Learning. ໃນພາກສ່ວນນີ້, ພວກຂ້າພະເຈົ້າຈະນຳສະເໜີຂະບວນການກະກຽມຂໍ້ມູນຢ່າງລະອຽດ.

1) ການທຳຄວາມສະອາດຂໍ້ມູນ (Data Cleaning)

ຂໍ້ມູນສຽງຂອງເຄື່ອງດົນຕີລາວທີ່ເກັບກຳມາມີຄວາມຫຼາກຫຼາຍທາງດ້ານຄຸນນະພາບແລະຄວາມຍາວ. ພວກຂ້າພະເຈົ້າຈຶ່ງໄດ້ດຳເນີນການທຳຄວາມສະອາດຂໍ້ມູນດັ່ງລຸ່ມນີ້:

ກ. ການກັ່ນກອງຟາຍສຽງທີ່ສັ່ນເກີນໄປ:

ຟາຍສຽງທີ່ມີຄວາມຍາວນ້ອຍກວ່າ 0.5 ວິນາທີຈະຖືກຂ້າມໄປເນື່ອງຈາກບໍ່ມີຂໍ້ມູນພຽງພໍສໍາລັບການວິເຄາະ. ການກັ່ນກອງນີ້ຊ່ວຍກຳຈັດຂໍ້ມູນທີ່ບໍ່ເໝາະສົມສໍາລັບການຮຽນຮູ້ຂອງແບບຈຳລອງອອກໄປ.



ຮູບທີ 3.11 ສະແດງການກະຈາຍຂອງຄວາມຍາວຟາຍສຽງໂດຍໃຊ້ histogram

ຄຳສະແດງ:

- ການກະຈາຍຄວາມຍາວຟາຍທັງໝົດມີຢູ່ 2,113 ຟາຍ
- ເສັ້ນສີແດງສະແດງຈຸດຕັດ (threshold) ທີ່ 0.5 ວິນາທີ
- ເສັ້ນສີຂຽວສະແດງຄ່າກາງ (median) ມີຄ່າຢູ່ທີ່ 7.00 ວິນາທີ
- ເສັ້ນສີສົ້ມສະແດງຄ່າສະເລ່ຍ (mean) ມີຄ່າຢູ່ທີ່ 7.09 ວິນາທີ

ຈະສັງເກດເຫັນໄດ້ເລີຍວ່າບໍ່ມີຟາຍສຽງໃດທີ່ຢູ່ຕໍ່າກ່ອນເກນທີ່ກຳນົດໄວ້ ແລະ ຄ່າສະເລ່ຍຂອງຟາຍສຽງໂດຍສ່ວນໃຫຍ່ຈະຢູ່ທີ່ 7 ວິນາທີເຊິ່ງມັນຈະເປັນຄ່າສູງສຸດໃນການເລືອກ duration segment ໃຫ້ກັບຮູບແບບຂອງສຽງບໍ່ເກີນ 7 ວິນາທີ.

ຂ. ການຄັດເລືອກຊ່ວງສຽງທີ່ດີທີ່ສຸດ (Segment Selection)

ການຄັດເລືອກຊ່ວງສຽງທີ່ດີທີ່ສຸດຈາກແຕ່ລະຟາຍແມ່ນຂັ້ນຕອນທີ່ສຳຄັນຫຼາຍໃນການປັບປຸງຄຸນນະພາບຂອງຊຸດຂໍ້ມູນການຝຶກສອນ (training dataset). ເນື່ອງຈາກການບັນທຶກສຽງເຄື່ອງດົນຕີມັກຈະມີຄຸນນະພາບທີ່ບໍ່ສະໝໍ່າສະເໝີຕະຫຼອດທັງຟາຍ ແລະ ບາງຊ່ວງອາດມີສຽງລົບກວນ, ບາງຊ່ວງອາດມີຄວາມງຽບ, ແລະ ບາງຊ່ວງ ມີການຫຼິ້ນເຄື່ອງດົນຕີທີ່ຊັດເຈນ ແລະ ເປັນຕົວແທນທີ່ດີຂອງເຄື່ອງດົນຕີນັ້ນໆ. ໂດຍຂະບວນການຄັດເລືອກຊ່ວງສຽງໃນລະບົບມີດັ່ງນີ້:

- **ການແບ່ງຟາຍ:** ລະບົບຈະແບ່ງແຕ່ລະຟາຍສຽງອອກເປັນຊ່ວງຍ່ອຍຂະໜາດ 6 ວິນາທີທີ່ຊ້ອນທັບກັນ 75% ເຊິ່ງໝາຍຄວາມວ່າມີການເລື່ອນໄປຂ້າງໜ້າຟຽງ 1/4 ຂອງຊ່ວງສຽງໃນແຕ່ລະຄັ້ງ:
 - ຊ່ວງທີ 0: ວິນາທີ 0.0-6.0
 - ຊ່ວງທີ 1: ວິນາທີ 1.5-7.5
 - ຊ່ວງທີ 2: ວິນາທີ 3.0-9.0

ແລະ ອື່ນໆ

- **ການຄຳນວນຄະແນນ:** ແຕ່ລະຊ່ວງຈະຖືກຄຳນວນຄະແນນຄຸນນະພາບໂດຍໃຊ້ເກນປະເມີນຫຼາຍມິຕິ (Multi-criteria Assessment) ທີ່ພັດທະນາຂຶ້ນພິເສດສຳລັບການຈຳແນກເຄື່ອງດົນຕີລາວ.
- **ການຄັດເລືອກ:** ສຳລັບການຝຶກອົບຮົມ, ລະບົບຈະເລືອກຊ່ວງທີ່ມີຄະແນນສູງສຸດສອງຊ່ວງຈາກແຕ່ລະຟາຍເພື່ອນຳໄປຝຶກອົບຮົມແບບຈຳລອງ AI. ສຳລັບການທົດສອບ, ຈະໃຊ້ຝຣຽງຊ່ວງທີ່ດີທີ່ສຸດໜຶ່ງຊ່ວງເທົ່ານັ້ນ.

ສູດການຄຳນວນຄະແນນຄຸນນະພາບແມ່ນໃຊ້ສູດທີ່ປະສົມປະສານຄຸນລັກສະນະສຽງ 6 ປະເພດ:

$$\begin{aligned} \text{Score} = & (RMS \times 0.30) + (\text{SpectralCentroid}/4000 \times 0.25) + \\ & (\text{SpectralBandwidth}/4000 \times 0.15) + (\text{SpectralContrast} \times 0.10) + \\ & (\text{OnsetDensity} \times 0.15) + (\text{SpectralFlux}/1000 \times 0.05) \end{aligned} \quad (3.2)$$

ແຕ່ລະອົງປະກອບຂອງສູດມີຄວາມໝາຍສະເພາະຕໍ່ຄຸນນະພາບຂອງສຽງດັ່ງນີ້:

ຜະລິງງານສຽງ (RMS - Root Mean Square, 30%): ວັດແທກຄວາມແຮງຂອງສຽງໃນຊ່ວງນັ້ນ, ຊ່ວງທີ່ມີສຽງຊັດເຈນແລະມີຄວາມດັງພໍດີຈະໄດ້ຄະແນນສູງກວ່າ, ສຳຄັນຫຼາຍສຳລັບເຄື່ອງດົນຕີທີ່ມີສຽງຄ່ອຍເຊັ່ນ: ຟິນ.


ຄວາມຖີ່ກາງ (Spectral Centroid, 25%): ວັດແທກ "ຄວາມໂປ່ງໃສ" ຂອງສຽງ (ຄວາມຖີ່ສະເລ່ຍຂອງສະເປັກຕຣຳ), ຊ່ວຍຈຳແນກເຄື່ອງດົນຕີທີ່ມີສຽງສູງ (ເຊັ່ນ: ລະນາດ) ຈາກເຄື່ອງທີ່ມີສຽງຕ່ຳ (ເຊັ່ນ: ຊໍ), ຄ່າຖືກຫານດ້ວຍ 4000 ເພື່ອປັບໃຫ້ຢູ່ໃນຊ່ວງ 0-1.

ແບນວິດສະເປັກຕຣຳ (Spectral Bandwidth, 15%): ວັດແທກການກະຈາຍຂອງຄວາມຖີ່ສຽງ, ຊ່ວຍຈຳແນກສຽງທີ່ມີຄວາມຊັບຊ້ອນຫຼາຍ (ເຊັ່ນ: ແຄນ) ຈາກສຽງທີ່ງ່າຍກວ່າ, ຄ່າຖືກຫານດ້ວຍ 4000 ເພື່ອປັບໃຫ້ຢູ່ໃນຊ່ວງ 0-1.


ຄວາມຄົມຊັດຂອງສະເປັກຕຣຳ (Spectral Contrast, 10%): ວັດແທກຄວາມແຕກຕ່າງລະຫວ່າງສຽງສັນຍານແລະສຽງລົບກວນ, ຊ່ວຍກຳຈັດຊ່ວງທີ່ມີສຽງລົບກວນຫຼາຍ, ສຳຄັນສຳລັບການຈຳແນກເຄື່ອງດົນຕີທີ່ມີສຽງຄ້າຍຄືກັນ (ເຊັ່ນ: ແຄນ ແລະ ຟິນ).

ຄວາມໜາແໜ້ນຂອງ Onset (Onset Density, 15%): ວັດແທກຄວາມຖີ່ຂອງການເລີ່ມຕົ້ນຂອງໂນດໃໝ່ໃນຊ່ວງສຽງ, ຊ່ວຍຈຳແນກລະຫວ່າງຊ່ວງທີ່ມີການຫຼິ້ນດົນຕີຢ່າງຕໍ່ເນື່ອງຈາກຊ່ວງທີ່ມີການຝັກ, ສຳຄັນສຳລັບເຄື່ອງດົນຕີປະເພດເຄາະ (ເຊັ່ນ: ຄ້ອງວົງ ແລະ ລະນາດ).

ການປ່ຽນແປງຂອງສະເປັກຕຣຳ (Spectral Flux, 5%): ວັດແທກອັດຕາການປ່ຽນແປງຂອງຄວາມຖີ່ໃນແຕ່ລະຊ່ວງເວລາ, ຊ່ວຍຈຳແນກລະຫວ່າງຊ່ວງທີ່ມີການປ່ຽນແປງຄຸນລັກສະນະສຽງຢ່າງຫຼວງຫຼາຍແລະຊ່ວງທີ່ມີສຽງຄົງທີ່, ຄ່າຖືກຫານດ້ວຍ 1,000 ເພື່ອປັບໃຫ້ຢູ່ໃນຊ່ວງ 0-1



ຮູບທີ 3.12 ສະແດງຕົວຢ່າງການຄັດເລືອກຊ່ວງສຽງ ທີ່ມີຄວາມຍາວ 8.10 ວິນາທີ



ຮູບທີ 3.13 ສະແດງຕົວຢ່າງການຄັດເລືອກຊ່ວງສຽງທີ່ມີຄວາມຍາວ 6.80 ວິນາທີ

ຮູບທີ 3.11 ແລະ 3.12 ສະແດງສອງກໍລະນີທີ່ແຕກຕ່າງກັນດັ່ງນີ້:

ຝາຍທີ່ມີຄວາມຍາວພຽງພໍສໍາລັບສອງຊ່ວງ (ຮູບທີ 3.11, Recording_164):

- ຝາຍນີ້ມີຄວາມຍາວ 8.10 ວິນາທີ, ເຊິ່ງສາມາດແບ່ງອອກເປັນສອງຊ່ວງ 6 ວິນາທີທີ່ຊ້ອນທັບກັນ
- ຊ່ວງທີ 0 (ເລີ່ມຕົ້ນທີ່ 0.0 ວິນາທີ) ມີຄະແນນ 2.211
- ຊ່ວງທີ 1 (ເລີ່ມຕົ້ນທີ່ 1.5 ວິນາທີ) ມີຄະແນນ 2.207
- ທັງສອງຊ່ວງໄດ້ຮັບການຄັດເລືອກສໍາລັບການຝຶກອົບຮົມເນື່ອງຈາກເປັນຝາຍທີ່ມີຄຸນນະພາບດີ ແລະມີພຽງສອງຊ່ວງເທົ່ານັ້ນ

ຝາຍທີ່ມີຄວາມຍາວພໍດີສໍາລັບໜຶ່ງຊ່ວງ (ຮູບທີ 3.12, Recording_165):

- ຝາຍນີ້ມີຄວາມຍາວ 6.80 ວິນາທີ, ເຊິ່ງພໍດີສໍາລັບໜຶ່ງຊ່ວງ 6 ວິນາທີ
- ມີພຽງຊ່ວງດຽວ (ເລີ່ມຕົ້ນທີ່ 0.0 ວິນາທີ) ທີ່ມີຄະແນນ 2.492
- ຊ່ວງນີ້ຈະຖືກເລືອກສໍາລັບທັງການຝຶກອົບຮົມແລະການທົດສອບ


ສັງເກດວ່າ ໃນຮູບພາບທັງສອງ, ແທ່ງສີແດງແມ່ນຊ່ວງສຽງທີ່ຖືກເລືອກ ໂດຍມີປ້າຍ "Selected" ສະແດງໄວ້. ໃນກໍລະນີຂອງ Recording_164, ເນື່ອງຈາກມີພຽງສອງຊ່ວງ ແລະ ຕ້ອງການສອງຊ່ວງສໍາລັບການຝຶກສອນ, ທັງສອງຊ່ວງຈຶ່ງຖືກເລືອກ. ສ່ວນໃນກໍລະນີຂອງ Recording_165, ມີພຽງຊ່ວງດຽວທີ່ມີຢູ່ ແລະຖືກເລືອກ. ເຊິ່ງວ່າການຄັດເລືອກຊ່ວງສຽງນີ້ມີຜົນກະທົບໂດຍກົງຕໍ່ຂະໜາດຂອງຊຸດຂໍ້ມູນການຝຶກສອນ ກໍຄືການເພີ່ມຂຶ້ນຂອງຕົວຢ່າງຈາກຝາຍສຽງຈຳນວນ 1,690 ຝາຍ, ພວກຂ້າພະເຈົ້າໄດ້ຕົວຢ່າງການຝຶກອົບຮົມ ທັງໝົດ 2,114 ຕົວຢ່າງ. ສາເຫດນີ້ເກີດຂຶ້ນຍ້ອນວ່າຝາຍຈຳນວນໜຶ່ງມີຄວາມຍາວພຽງພໍສໍາລັບສອງຊ່ວງ, ເຮັດໃຫ້ສາມາດເລືອກສອງຕົວຢ່າງຈາກໜຶ່ງຝາຍໄດ້ ແລະ ຝາຍສັ້ນກວ່າຈະໃຫ້ພຽງໜຶ່ງຕົວຢ່າງເທົ່ານັ້ນ.

ຄ. ຈັດການກັບຂໍ້ຜິດພາດ (Error Handling)

ນໍາໃຊ້ກົນໄກການຈັດການກັບຂໍ້ຜິດພາດທີ່ຄົບຖ້ວນເພື່ອຮັບປະກັນວ່າໂປຣແກຣມຈະດໍາເນີນຕໍ່ໄປ ໄດ້ແມ່ນໃນກໍລະນີທີ່ມີບັນຫາກັບຝາຍບາງຝາຍ:

ປະເພດຂໍ້ຜິດພາດທີ່ຈັດການໄດ້ຈະມີຝາຍເສຍຫາຍ ຫຼື ບໍ່ສາມາດອ່ານໄດ້, ການ encoding ທີ່ບໍ່ຖືກຕ້ອງ, Sample rate ທີ່ບໍ່ຖືກຕ້ອງ, ຝາຍຫວ່າງເປົ່າ, ຂໍ້ຜິດພາດໃນການປະມວນຜົນສຽງໂດຍໃຊ້ librosa. ຈາກຂໍ້ມູນສະຖິຕິການປະມວນຜົນຂອງຊຸດຂໍ້ມູນທັງໝົດ 2,113 ຝາຍ:

- ປະມວນຜົນສໍາເລັດ: 2,113 ຝາຍ (100.00%)
- ຖືກກັ່ນກອງ (ສັ້ນເກີນໄປ): 0 ຝາຍ (0.00%)
- ເກີດຂໍ້ຜິດພາດ: 0 ຝາຍ (0.00%)



ຮູບທີ 3.14 ສະແດງສະຖິຕິການປະມວນຜົນແບບ bar chart ແລະ pie chart

2) ການຈັດໝວດໝູ່ເຄື່ອງດົນຕີ (Labeling Class)


ເນື່ອງຈາກຊື່ຂອງເຄື່ອງດົນຕີລາວສາມາດຂຽນໄດ້ຫຼາກຫຼາຍແບບ ທັງໃນພາສາລາວ ແລະ ການຖອດຄວາມເປັນພາສາອັງກິດເພື່ອປ້ອງກັນການດຶງ folder ຂອງເຄື່ອງດົນຕີທີ່ບໍ່ໃຫ້ເກີດຂໍ້ຜິດພາດ, ພວກຂ້າພະເຈົ້າຈຶ່ງໄດ້ສ້າງວິທີການຈັດໝວດໝູ່ທີ່ເປັນມາດຕະຖານເພື່ອຮັບປະກັນຄວາມສອດຄ່ອງໃນການເອີ້ນຊື່ຂອງແຕ່ລະ class

ຕາຕະລາງທີ 3.2: ການຈັດໝວດໝູ່ເຄື່ອງດົນຕີລາວ

ຊື່ມາດຕະຖານ	ຊື່ທີ່ນຳໃຊ້ໃນຂໍ້ມູນທີ່ຖືກແປງອອກເປັນ folder	ຈຳນວນ ຝາຍ	ປະເພດເຄື່ອງ ດົນຕີ
Khean	khean-ss1, khean-ss2, khean-ss3, khean-ss4, khean-ss5, khean-ss6, khean-ss7	295	ເຄື່ອງເປົ່າ
Khong_Vong	khong-vong-ss1, khong-vong-ss2, khong-vong-ss3, khong-vong-ss4, khong-vong-ss5, khong-vong-ss6, khong-vong-ss7	314	ເຄື່ອງຕີ
Pin	pin-ss1, pin-ss2, pin-ss3, pin-ss4, pin-ss5, pin-ss6, pin-ss7	285	ເຄື່ອງດົດ
Ranad	ranad-ss1, ranad-ss2, ranad-ss3, ranad-ss4, ranad-ss5, ranad-ss6, ranad-ss7	302	ເຄື່ອງຕີ
Saw	saw-ss1, saw-ss2, saw-ss3, saw-ss4, saw-ss5, saw-ss6, saw-ss7	314	ເຄື່ອງສີ
Sing	sing-ss1, sing-ss2, sing-ss3, sing-ss4, sing-ss5, sing-ss6, sing-ss7	295	ເຄື່ອງເຄາະ
Unknown	unknown-env_indoor, unknown-env_outdoor, unknown-human_speech, unknown-non_speech, unknown-non-instru, unknown-processed_sound, unknown-silence, unknown-unique	308	ສຽງອື່ນໆ

ກຸ່ມເພງແປງອອກເປັນ 6 ປະເພດເຄື່ອງດົນຕີລາວ ແລະ ອີກ class ຫນຶ່ງແມ່ນກຸ່ມທີ່ເອົາຈັດການກັບສຽງທີ່ບໍ່ແມ່ນເຄື່ອງດົນຕີລາວຄື:

- ແຄນ (Khean) - ເຄື່ອງດົນຕີປະເພດເປົ່າທີ່ເຮັດຈາກໄມ້ ແລະ ລຳໄມ້ປ່ອງ
- ຄ້ອງວົງ (Khong Vong) - ເຄື່ອງດົນຕີປະເພດຕີທີ່ປະກອບດ້ວຍຄ້ອງໂລຫະຫຼາຍອັນ
- ຝິນ (Pin) - ເຄື່ອງດົນຕີປະເພດດົດທີ່ມີສາຍໂລຫະ
- ລະນາດ (Ranad) - ເຄື່ອງດົນຕີປະເພດຕີຄ້າຍຄືກັບຣະນາດໄທ
- ຊໍອູ້ (Saw) - ເຄື່ອງດົນຕີປະເພດສີທີ່ມີຮູບຮ່າງຄ້າຍກັບຊໍໄທ
- ຊິ່ງ (Sing) - ເຄື່ອງດົນຕີປະເພດເຄາະທີ່ເປັນແຜ່ນໂລຫະຄູ່
- ສຽງອື່ນ (Unkown) - ບັນດາສຽງລົບກວນພາຍນອກສະຖານທີ່ ແລະ ພາຍໃນ, ສຽງເວົ້າຂອງຄົນ, ສຽງສັດ ແລະ ສຽງອື່ນໆທີ່ບໍ່ກ່ຽວຂ້ອງ ແລະ ບໍ່ຄ້າຍຄືກັບສຽງຂອງທັງ 6 ເຄື່ອງດົນຕີ



ຮູບທີ 3.15 ສະແດງການກະຈາຍຂອງຂໍ້ມູນແຕ່ລະປະເພດເຄື່ອງດົນຕີ

3) ການແປງສັນຍານສຽງເປັນ Multi-Channel Features Extraction

ໃນການພັດທະນາແບບຈຳລອງທີ່ມີປະສິດທິພາບສູງ, ພວກຂ້າພະເຈົ້າໄດ້ພັດທະນາລະບົບການສະກັດຄຸນລັກສະນະແບບຫຼາຍຊ່ອງສັນຍານ (Multi-channel Feature Extraction) ທີ່ສາມາດຈັບຄຸນລັກສະນະທີ່ຫຼາກຫຼາຍແລະລະອຽດຂອງສຽງເຄື່ອງດົນຕີລາວແຕ່ລະປະເພດ. ລະບົບນີ້ປະກອບມີເທັກນິກທີ່ຊ່ວຍໃຫ້ແບບຈຳລອງສາມາດຈຳແນກເຄື່ອງດົນຕີທີ່ມີລັກສະນະຄ້າຍຄືກັນໄດ້ຢ່າງແມ່ນຍຳ ເຊັ່ນ ແຄນ, ຝົນ, ແລະ ຊໍອູ້. ເຊິ່ງໃນການພັດທະນາ Feature Extraction Pipeline ຈະປະກອບມີ:

ກ. Harmonic-Percussive Source Separation (HPSS)

ແມ່ນເທັກນິກທີ່ແຍກສຽງອອກເປັນສອງສ່ວນຫຼັກດັ່ງນີ້:

ສ່ວນ Harmonic (ສຽງເພງ):

- ຄຸນລັກສະນະ: ສຽງທີ່ມີຄວາມຖີ່ສະໜ້າສະເໝີ, ຄົງທີ່ຕາມເວລາ
- ສຳຄັນສຳລັບ: ແຄນ (drone sound), ຊໍອູ້ (bowing), ຝົນ (sustained notes)
- Parameters: harmonic_margin = 1.0

ສ່ວນ Percussive (ສຽງຈັງຫວະ):

- ຄຸນລັກສະນະ: ສຽງທີ່ມີການປ່ຽນແປງໄວ, transient sounds
- ສຳຄັນສຳລັບ: ຄ້ອງວົງ, ລະນາດ, ຊິ່ງ, ການຕີ/ກະທົບ
- Parameters: percussive_margin = 5.0

ຂ. Multi-Channel Feature Architecture (6 ຊ່ອງສັນຍານ)

ແມ່ນລະບົບສ້າງ 6 ຊ່ອງສັນຍານ ທີ່ແຕກຕ່າງກັນເພື່ອຈັບຄຸນລັກສະນະທີ່ຫຼາກຫຼາຍ:

Channel 1: Original Mel-Spectrogram

- ຈຸດປະສົງ: ຄຸນລັກສະນະພື້ນຖານຂອງສຽງໂດຍລວມ
- Parameters: n_mels=128, n_fft=2048, hop_length=512, fmax=8,000 Hz

Channel 2: Harmonic Mel-Spectrogram

- ຈຸດປະສົງ: ຈັບຄຸນລັກສະນະສຽງເພງ/ດິນຕີ
- ປະໂຫຍດ: ແຍກແຄນ, ຊໍ້ອູ້ ທີ່ມີ harmonic content ສູງ

Channel 3: Percussive Mel-Spectrogram

- ຈຸດປະສົງ: ຈັບຄຸນລັກສະນະສຽງຕີ/ຈັງຫວະ
- ປະໂຫຍດ: ແຍກຄໍ່ອງວົງ, ລະນາດ, ຊຶ່ງ ທີ່ມີ percussive content ສູງ

Channel 4: MFCCs (Mel-Frequency Cepstral Coefficients)


- ຈຸດປະສົງ: ຄຸນລັກສະນະສະເພາະຂອງ timbre
- Parameters: n_mfcc=20 (ຂະຫຍາຍເປັນ 128 dimensions)
- ປະໂຫຍດ: ຈັບຄຸນລັກສະນະສຽງເສິ່ງທີ່ເປັນເອກະລັກ

Channel 5: Delta Features (MFCC Derivatives)

- ຈຸດປະສົງ: ອັດຕາການປ່ຽນແປງຂອງ MFCCs
- ສູດ: $\Delta\text{mfcc}(t) = \text{mfcc}(t+1) - \text{mfcc}(t-1)$
- ປະໂຫຍດ: ຈັບການປ່ຽນແປງທາງດ້ານ timbre ຕາມເວລາ

Channel 6: Delta-Delta Features (MFCC Second Derivatives)

- ຈຸດປະສົງ: ການເລັ່ງ/ຊ້າລົງຂອງການປ່ຽນແປງ MFCCs
- ສູດ: $\Delta\Delta\text{mfcc}(t) = \Delta\text{mfcc}(t+1) - \Delta\text{mfcc}(t-1)$
- ປະໂຫຍດ: ຈັບລັກສະນະການປ່ຽນແປງທີ່ຊັບຊ້ອນ



ຮູບທີ 3.16 ສະແດງ ຂະບວນການສະກັດ feature ແບບ 6-channel


ຈາກຮູບທີ 3.16 ເປັນການສະແດງໃຫ້ເຫັນເຖິງຮູບແບບຂອງການສະກັດຄຸນລັກສະນະຂອງຕົວຢ່າງຝາຍສຽງແຄນເພື່ອໃຫ້ເຫັນເຖິງຄວາມແຕກຕ່າງລະຫວ່າງທັງ 6 ລັກສະນະນັ້ນເອງ. (ຄຸນລັກສະນະທັງ 6 ແບບນີ້ ພວກຂ້າພະເຈົ້າຈະນຳໄປໃຊ້ໃນການຝຶກແບບຈຳລອງໂດຍນຳໃຊ້ CNN)

ເຄື່ອງດົນຕີລາວແຕ່ລະປະເພດມີລັກສະນະສຽງທີ່ເປັນເອກະລັກ ເຊິ່ງລະບົບ Enhanced Features ສາມາດຈັບຄຸນລັກສະນະເຫຼົ່ານີ້ໄດ້ຢ່າງລະອຽດ:

- **ການວິເຄາະດ້ວຍ HPSS (Harmonic-Percussive Separation):** ແຄນມີລັກສະນະສຽງ drone ທີ່ມີ harmonic content ສູງ, ສຽງຄົງທີ່ ແລະ ເປັນຈັງຫວະ. ພົນມີທັງ harmonic content ຈາກການສັ່ນຂອງສາຍ ແລະ percussive content ຈາກການຕີດ. ຊໍອູ້ມີ harmonic content ສູງຈາກການສີ ແລະ ສຽງທີ່ມີຄອມຕໍ່ເນື່ອງ. ຄ້ອງວົງມີ percussive content ສູງ ຈາກການຕີໂລຫະ, ສຽງກົງ ແລະ ມີການສະທ້ອນ. ລະນາດມີ percussive content ຈາກການຕີໄມ້, ສຽງແຫ້ງ ແລະ ສັ່ນ. ຊິ່ງມີ percussive content ສູງ ຈາກການເຄາະໂລຫະ, ສຽງແຫຼມ ແລະ ສັ່ນ.

- **ການວິເຄາະດ້ວຍ MFCCs (Timbre Characteristics):** ແຄນມີລັກສະນະ reed instrument ທີ່ມີ formant ສະເພາະຈາກການສັ່ນຂອງທໍ່ໄມ້. ພົນມີລັກສະນະ plucked string ທີ່ມີ harmonic series ຈາກການສັ່ນຂອງສາຍ. ຊໍອູ້ມີລັກສະນະ bowed string (ການຂີດຕົວຂອງສາຍ) ທີ່ມີຄວາມຕໍ່ເນື່ອງ ແລະ ການປ່ຽນແປງຂອງ bow pressure

- **ການວິເຄາະດ້ວຍ Delta Features (Attack Patterns):** ແຄນຈະເລີ່ມຕົ້ນຄ່ອຍໆ (gradual onset), ສຽງຄົງທີ່ (sustained). ພົນຈະເລີ່ມຕົ້ນແຫຼມ (sharp attack), ການຫຼຸດລົງແບບ exponential decay. ຊໍອູ້ຈະມີການເລີ່ມຕົ້ນທີ່ (smooth onset), ການຄວບຄຸມການຄົງຢູ່ ໃຫ້ສຽງມີຄວາມນຸ້ມລະມຸນ (controlled sustain)



ຮູບທີ 3.17 ສະແດງອົງປະກອບຂອງ HPSS ຈາກເຄື່ອງດົນຕີທັງ 6 ປະເພດ

ຈາກຮູບທີ 3.17 ສະແດງທັງ 6 ຊ່ອງສັນຍານເພື່ອໃຫ້ເຫັນຄວາມແຕກຕ່າງລະຫວ່າງ harmonic ແລະ percussive content ຂອງແຕ່ລະເຄື່ອງດົນຕີ.

4) ການກະກຽມຂໍ້ມູນສໍາລັບແບບຈຳລອງ

ກ. ການເພີ່ມຂໍ້ມູນ (Data Augmentation)

ພວກຂ້າພະເຈົ້າໄດ້ນຳໃຊ້ເທັກນິກ On-the-fly Augmentation ທີ່ເພີ່ມຄວາມຫລາກຫລາຍໃຫ້ກັບຂໍ້ມູນໃນລະຫວ່າງການຝຶກແບບຈຳລອງໂດຍນຳໃຊ້ເທັກນິກດັ່ງນີ້:

SpecAugment ເທັກນິກການປັດບັງຂໍ້ມູນໃນ spectrogram ເພື່ອເພີ່ມຄວາມທົນທານ:

- Frequency Masking: ປັດບັງ frequency bands ສູງສຸດ 27 bands, 2 ຄັ້ງຕໍ່ sample
- Time Masking: ປັດບັງ time steps ສູງສຸດ 100 steps, 2 ຄັ້ງຕໍ່ sample

Mixup Augmentation ການຜະສົມຜະສານລະຫວ່າງ samples:

- Alpha parameter: 0.4
- ການສຸ່ມເລືອກ 2 samples ແລະ ປະສົມດ້ວຍອັດຕາສ່ວນທີ່ສຸ່ມໄດ້
- ຊ່ວຍໃຫ້ແບບຈຳລອງຮຽນຮູ້ຈາກຂໍ້ມູນທີ່ປະສົມປະສານ

ການເພີ່ມຂໍ້ມູນຈາກການຄັດເລືອກ Segments:

- ສໍາລັບການຝຶກ: ເລືອກ 2 segments ທີ່ດີທີ່ສຸດຕໍ່ຝາຍ
- ສໍາລັບການທົດສອບ: ເລືອກ 1 segment ທີ່ດີທີ່ສຸດຕໍ່ຝາຍ

ຂ. ການແປງຊຸດຂໍ້ມູນສໍາລັບການຝຶກແລະທົດສອບ

```
1. PROCESSING DATASET WITH ENHANCED FEATURES...
Processing dataset with enhanced features...
Total files found: 2113
Classes: ['khean', 'khong_vong', 'pin', 'ranad', 'saw', 'sing', 'unknown']
Train files: 1690, Test files: 423
Extracting enhanced features for training set...
100%|
Extracting enhanced features for test set...
100%|

Final dataset shape:
X_train: (2114, 128, 517, 6)
X_test: (422, 128, 517, 6)
Number of channels: 6
✓ Dataset processed in 0:17:49.773789

Class distribution in training set:
khean: 368 samples
khong_vong: 292 samples
pin: 247 samples
ranad: 274 samples
saw: 285 samples
sing: 321 samples
unknown: 327 samples
```

ຮູບທີ 3.18 ລາຍລະອຽດຂໍ້ມູນທີ່ມີການແປງໄວ້ສໍາລັບການຝຶກສອນແບບຈຳລອງ ແລະ ການທົດສອບ

ຂໍ້ມູນຂອງພວກຂ້າພະເຈົ້າມີທັງໝົດ 2,113 ຝາຍ ແລ້ວທຳການແປງຊຸດຂໍ້ມູນອອກເປັນ 80% ສໍາລັບການຝຶກ ໄດ້ 1,690 ຝາຍ ແລະ 20% ສໍາລັບການທົດສອບ ໄດ້ 423 ຝາຍ ໂດຍໃຊ້ເທັກນິກ

stratified sampling ເພື່ອຮັບປະກັນວ່າແຕ່ລະຊຸດຂໍ້ມູນມີການກະຈາຍຂອງປະເພດເຄື່ອງດົນຕີທີ່ສົມດຸນ, ຫຼັງຈາກການປະມວນຜົນເບື້ອງຕົ້ນ: ເນື່ອງຈາກແຕ່ລະຝາຍສຽງຈະຖືກແຍກເອົາສ່ວນທີ່ດີທີ່ສຸດ 6 ວິນາທີ ໂດຍຝາຍທີ່ຍາວກວ່າ 8 ວິນາທີສາມາດແຍກໄດ້ 2 ສ່ວນ ສິ່ງຜິດໃຫ້ຊຸດຂໍ້ມູນການຝຶກມີທັງໝົດ 2,114 ຕົວຢ່າງ ແລະຊຸດຂໍ້ມູນທົດສອບມີ 422 ຕົວຢ່າງ ແລະ ແຕ່ລະຕົວຢ່າງຈະຖືກແປງເປັນຟີເຈີ 6 ຊ່ອງທາງ (mel-spectrogram ດັ່ງເດີມ, ສ່ວນ harmonic, ສ່ວນ percussive, MFCCs, ແລະ delta ,delta delta) ສ້າງເປັນ tensor ຂະໜາດ (128×517×6) ສໍາລັບການປ້ອນເຂົ້າແບບຈໍາລອງ CNN.

ຄ. ການຄຳນວນນ້ຳໜັກຂອງແຕ່ລະກຸ່ມ (Class Weights)

ເພື່ອຈັດການກັບຄວາມບໍ່ສົມດຸນລະຫວ່າງກຸ່ມຂໍ້ມູນ ແລະ ແກ້ໄຂບັນຫາການແຍກແຍະເຄື່ອງດົນຕີທີ່ມີຄຸນລັກສະນະຄ້າຍຄືກັນ, ພວກຂ້າພະເຈົ້າໄດ້ພັດທະນາລະບົບ class weights ແບບປັບປຸງທີ່ປະກອບດ້ວຍສອງຂັ້ນຕອນ:

ຂັ້ນຕອນທີ 1: ການຄຳນວນ Base Balanced Weights ໃຊ້ສູດ sklearn's balanced weighting:

$$weight = total_samples / (num_classes \times samples_in_class) \quad (3.3)$$

ຂັ້ນຕອນທີ 2: Enhanced Weighting ສໍາລັບເຄື່ອງດົນຕີທີ່ຫຍຸ້ງຍາກ ຈາກການວິເຄາະຜົນການຝຶກເບື້ອງຕົ້ນ, ພົບວ່າເຄື່ອງດົນຕີສາມຊະນິດ (ແຄນ, ຝົນ, ຊໍອູ້) ມີຄວາມຫຍຸ້ງຍາກໃນການແຍກແຍະເນື່ອງຈາກ:

- ແຄນ - ຝົນ: ທັງສອງມີ harmonic components ທີ່ຄ້າຍຄືກັນ
- ແຄນ - ຊໍອູ້: ທັງສອງເປັນ sustained tones
- ຝົນ - ຊໍອູ້: ມີ spectral characteristics ທີ່ປະສົມປະສານ

ເພື່ອແກ້ໄຂບັນຫານີ້, ພວກຂ້າພະເຈົ້າໄດ້ນຳໃຊ້ Enhanced Class Weights ທີ່ເພີ່ມນ້ຳໜັກໃຫ້ກັບເຄື່ອງດົນຕີທີ່ຫຍຸ້ງຍາກເຫຼົ່ານີ້ໂດຍການເພີ່ມນ້ຳໜັກໃຫ້ປະມານ 50% ຫຼື 1.5 ເພາະເຫດຜົນໃນການເລືອກ 1.5× boost ເພື່ອຫຼີກຫຼ່ຽງການເກີດ overfitting ກໍຄືການເພີ່ມສູງເກີນໄປ (ຄຸນຫຼາຍກ່ອນ 2.0) ອາດເຮັດໃຫ້ແບບຈໍາລອງ overfocus ໃສ່ classes ເຫຼົ່ານີ້ ແລະ ຍັງຊ່ວຍໃຫ້ຄວາມສົມດຸນລະຫວ່າງ accuracy ແລະ robustness ຢູ່ທີ່ 50% ເປັນການປັບປຸງທີ່ເໝາະສົມທີ່ສຸດ.


```

1. PROCESSING DATASET WITH ENHANCED FEATURES...
Processing dataset with enhanced features...
Total files found: 2113
Classes: ['khean', 'khong_vong', 'pin', 'ranad', 'saw', 'sing', 'unknown']
Train files: 1690, Test files: 423
Extracting enhanced features for training set...
100%|
Extracting enhanced features for test set...
100%|

Final dataset shape:
X_train: (2114, 128, 517, 6)
X_test: (422, 128, 517, 6)
Number of channels: 6
✓ Dataset processed in 0:17:49.773789

Class distribution in training set:
khean: 368 samples
khong_vong: 292 samples
pin: 247 samples
ranad: 274 samples
saw: 285 samples
sing: 321 samples
unknown: 327 samples

2. TRAINING ENHANCED MODEL...

Training enhanced model...


Class weights:
khean: 1.231
khong_vong: 1.034
pin: 1.834
ranad: 1.102
saw: 1.589
sing: 0.941
unknown: 0.924

```

ຮູບທີ 3.19 ສະແດງ class weights ຂອງແຕ່ລະເຄື່ອງດົນຕີ.

ດັ່ງຮູບທີ 3.19 ເຄື່ອງດົນຕີທີ່ມີຄ່າສູງແມ່ນ ແຄນ, ຝົນ, ຊໍຮູ້ ເປັນກຸ່ມທີ່ໄດ້ຮັບການ enhanced weighting ເພື່ອແກ້ໄຂບັນຫາການສັບສົນລະຫວ່າງກັນ.

5) ສະແດງການໄຫຼຂອງຂໍ້ມູນສໍາລັບ CNN



ຮູບທີ 3.20 ສະແດງຂະບວນການກະກຽມຂໍ້ມູນທັງໝົດທີ່ສະແດງການໄຫຼຂອງຂໍ້ມູນ

ຂະບວນການກະກຽມຂໍ້ມູນທັງໝົດດັ່ງຮູບທີ 3.20 ສະແດງໃຫ້ເຫັນເຖິງການໄຫຼຂອງຂໍ້ມູນນໍາຕັ້ງແຕ່ raw data → data cleaning (feature extraction) → augmentation → Label processing .→ CNN model Input ຂະບວນການນີ້ຮັບປະກັນວ່າຂໍ້ມູນທີ່ຈະຖືກນໍາໃຊ້ໃນການຝຶກແບບຈໍາລອງ deep learning ມີຄຸນນະພາບສູງ, ມີຄວາມຫຼາກຫຼາຍພຽງພໍ, ແລະ ເໝາະສົມສໍາລັບການຮຽນຮູ້ລັກສະນະສະເພາະຂອງສຽງເຄື່ອງດົນຕີພື້ນເມືອງລາວແຕ່ລະປະເພດ. ຂໍ້ມູນທີ່ໄດ້ຮັບການກະກຽມຢ່າງດີນີ້ຈະຊ່ວຍໃຫ້ແບບຈໍາລອງ CNN ສາມາດຈໍາແນກປະເພດເຄື່ອງດົນຕີລາວຈາກສຽງໄດ້ຢ່າງແນ່ນອນຍໍາສູງ.

3.1.4. ການສ້າງແບບຈໍາລອງ (Modeling)

ການສ້າງແບບຈໍາລອງເປັນຂັ້ນຕອນສໍາຄັນໃນການພັດທະນາລະບົບຈໍາແນກສຽງເຄື່ອງດົນຕີລາວ. ແບບຈໍາລອງໃຊ້ເຕັກນິກ Deep Learning ເພື່ອຮຽນຮູ້ລັກສະນະສະເພາະຂອງສຽງແຕ່ລະປະເພດເຄື່ອງດົນຕີ. ໃນພາກສ່ວນນີ້, ພວກຂ້າພະເຈົ້າຈະອະທິບາຍກ່ຽວກັບໂຄງສ້າງຂອງແບບຈໍາລອງ, ຂະບວນການຝຶກສອນ, ແລະ ການປະເມີນຜົນ.

1) ຂະບວນການຝຶກແບບຈໍາລອງແບບ K-Fold Cross Validation

ໃນການຝຶກແບບຈໍາລອງ, ພວກຂ້າພະເຈົ້າໄດ້ນໍາໃຊ້ເຕັກນິກ K-Fold Cross Validation ເພື່ອໃຫ້ໄດ້ຜົນການປະເມີນແບບຈໍາລອງທີ່ໜ້າເຊື່ອຖືຫຼາຍຂຶ້ນ. ວິທີການນີ້ຈະແບ່ງຂໍ້ມູນອອກເປັນ K ສ່ວນເທົ່າໆ

ກັນ, ແລ້ວຝຶກແບບຈຳລອງ K ຄັ້ງ, ໂດຍແຕ່ລະຄັ້ງຈະໃຊ້ສ່ວນໜຶ່ງເປັນຂໍ້ມູນທົດສອບ ແລະ ສ່ວນທີ່ເຫຼືອເປັນຂໍ້ມູນຝຶກສອນ.

ໃນກໍລະນີຂອງພວກຂ້າພະເຈົ້າໃຊ້ 3-Fold Cross Validation (K=3) ສຳລັບຂໍ້ມູນທີ່ເອົາໄວ້ຝຶກສອນທັງໝົດ 80% ແລະມີການສະຫຼັບຕຳແໜ່ງ ຂໍ້ມູນທຸກ k fold.

2) ເທັກນິກການຫຼຸດຄວາມ Overfitting (Regularization Techniques)

ເພື່ອປ້ອງກັນບໍ່ໃຫ້ແບບຈຳລອງຈື່ຈຳຂໍ້ມູນຝຶກສອນຫລາຍຈົນເກີນໄປ (overfitting) ແລະ ເພື່ອໃຫ້ສາມາດຈຳແນກຂໍ້ມູນໃໝ່ໄດ້ດີ, ພວກຂ້າພະເຈົ້າໄດ້ນຳໃຊ້ເຕັກນິກຫຼຸດຄວາມ overfitting ຫຼາຍວິທີຮ່ວມກັນ:

- **Dropout ແບບຄ່ອຍໆເພີ່ມຂຶ້ນ:** ນຳໃຊ້ອັດຕາ dropout ທີ່ເພີ່ມຂຶ້ນຕາມລຳດັບຊັ້ນຂອງໂຄງຂ່າຍ (25% → 30% → 35% → 40% → 50%) ໂດຍສ່ວນ dense layers ໃຊ້ 50% ເພື່ອເພີ່ມຄວາມສາມາດໃນການ generalize ຂອງແບບຈຳລອງ.
- **L2 Regularization:** ນຳໃຊ້ L2 regularization ຄ່າ 0.01 ໃນ dense layers ເພື່ອຄວບຄຸມຂະໜາດຂອງຄ່ານ້ຳໜັກໃນແບບຈຳລອງ, ເຮັດໃຫ້ແບບຈຳລອງບໍ່ເນັ້ນຄຸນລັກສະນະໃດໜຶ່ງຫຼາຍເກີນໄປ.
- **Batch Normalization:** ນຳໃຊ້ batch normalization ຫຼັງແຕ່ລະຊັ້ນ convolutional ແລະ dense layers ເພື່ອຄວບຄຸມການກະຈາຍຂອງຄ່າ ແລະ ເຮັດໃຫ້ການຮຽນຮູ້ມີສະຖຽນລະພາບ.
- **Focal Loss:** ນຳໃຊ້ Focal Loss ກັບຄ່າ $\gamma=2.0$ ແລະ $\alpha=0.25$ ແທນ categorical cross entropy ເພື່ອແກ້ໄຂບັນຫາ class imbalance ແລະໃຫ້ຄວາມສຳຄັນກັບຕົວຢ່າງທີ່ຈຳແນກຍາກ.
- **Enhanced Class Weights:** ນຳໃຊ້ນ້ຳໜັກຜິເສດສຳລັບເຄື່ອງດົນຕີທີ່ຈຳແນກຍາກ (ແຄນ, ຝົນ, ຊໍ) ດ້ວຍການເພີ່ມນ້ຳໜັກ 1.5 ເທົ່າຈາກນ້ຳໜັກຜື້ນຖານ.
- **Early Stopping:** ຢຸດການຝຶກສອນແບບຈຳລອງເມື່ອຄ່າຄວາມແມ່ນຍຳຂອງຊຸດຂໍ້ມູນກວດສອບບໍ່ມີການປັບປຸງພາຍໃນ 20 ຮອບ ເພື່ອຫຼີກເວັ້ນການຝຶກສອນເກີນຄວາມຈຳເປັນ.
- **Learning Rate Reduction:** ນຳໃຊ້ການຫຼຸດ learning rate ລົງເຄິ່ງໜຶ່ງເມື່ອ validation loss ບໍ່ປັບປຸງພາຍໃນ 10 epochs ເພື່ອຊ່ວຍໃຫ້ການຝຶກສອນມີຄວາມລະອຽດຫຼາຍຂຶ້ນ.

3) ໂຄງສ້າງຂອງແບບຈຳລອງ CNN (CNN Architecture)

ພວກຂ້າພະເຈົ້າໄດ້ນຳໃຊ້ແບບຈຳລອງ Enhanced Convolutional Neural Network (CNN) ທີ່ມີການປັບປຸງສະເພາະສຳລັບການຈຳແນກສຽງເຄື່ອງດົນຕີລາວດ້ວຍເຕັກນິກການແຍກສັນຍານໃໝ່ (HPSS) ແລະ ລັກສະນະຫຼາຍຊ່ອງສັນຍານ. ໂຄງສ້າງຂອງແບບຈຳລອງ Enhanced CNN ທີ່ໃຊ້ມີດັ່ງນີ້:

ຊັ້ນ Input: ຮັບຂໍ້ມູນ multi-channel features ທີ່ມີຂະໜາດ (128, ໄລຍະເວລາ, 6)

- 128: ຈຳນວນ mel bands
- ໄລຍະເວລາ: ຂຶ້ນກັບຄວາມຍາວຂອງສຽງ (6 ວິນາທີ)
- 6: ຈຳນວນຊ່ອງສັນຍານ (Mel + Harmonic + Percussive + MFCC + Delta + Delta2)

ຊັ້ນ Convolutional ທີ 1:

- 64 filters ຂະໜາດ 3×3

- Padding: 'same'
- Activation: ReLU
- ຕາມດ້ວຍ BatchNormalization
- MaxPooling ຂະໜາດ 2×2
- Dropout 25%

ຊັ້ນ Convolutional ທີ 2:

- 128 filters ຂະໜາດ 3×3
- Padding: 'same'
- Activation: ReLU
- ຕາມດ້ວຍ BatchNormalization
- MaxPooling ຂະໜາດ 2×2
- Dropout 30%

ຊັ້ນ Convolutional ທີ 3:

- 256 filters ຂະໜາດ 3×3
- Padding: 'same'
- Activation: ReLU
- ຕາມດ້ວຍ BatchNormalization
- MaxPooling ຂະໜາດ 2×2
- Dropout 35%

ຊັ້ນ Convolutional ທີ 4:

- 512 filters ຂະໜາດ 3×3
- Padding: 'same'
- Activation: ReLU
- ຕາມດ້ວຍ BatchNormalization
- MaxPooling ຂະໜາດ 2×2
- Dropout 40%

ຊັ້ນ Global Average Pooling: ຫຼຸດຄວາມຊັບຊ້ອນຂອງຂໍ້ມູນໂດຍການເຮັດຄ່າສະເລ່ຍຂອງແຕ່ລະ feature map

ຊັ້ນ Attention Mechanism: ຊ່ວຍໃຫ້ແບບຈຳລອງສົ່ງຄວາມສົນໃຈໄປທີ່ຄວາມຖີ່ທີ່ສຳຄັນສຳລັບການຈຳແນກແຕ່ລະເຄື່ອງດົນຕີ

ຊັ້ນ Dense ທີ 1:

- 512 neurons
- Activation: ReLU
- L2 Regularization (0.01)
- ຕາມດ້ວຍ BatchNormalization
- Dropout 50%

ຊັ້ນ Dense ທີ 2:

- 256 neurons

- Activation: ReLU
- L2 Regularization (0.01)
- ຕາມດ້ວຍ BatchNormalization
- Dropout 50%

ຊັ້ນ Output:

- 7 neurons (ລວມທັງ 'unknown' class)
- Activation: Softmax

Model: "model"		
Layer (type)	Output Shape	Param #
input_1 (InputLayer)	[(None, 128, 517, 6)]	0
conv2d (Conv2D)	(None, 128, 517, 64)	3520
batch_normalization (BatchNormalization)	(None, 128, 517, 64)	256
activation (Activation)	(None, 128, 517, 64)	0
conv2d_1 (Conv2D)	(None, 128, 517, 64)	36928
batch_normalization_1 (BatchNormalization)	(None, 128, 517, 64)	256
activation_1 (Activation)	(None, 128, 517, 64)	0
max_pooling2d (MaxPooling2D)	(None, 64, 258, 64)	0
dropout (Dropout)	(None, 64, 258, 64)	0
conv2d_2 (Conv2D)	(None, 64, 258, 128)	73856
batch_normalization_2 (BatchNormalization)	(None, 64, 258, 128)	512
activation_2 (Activation)	(None, 64, 258, 128)	0
conv2d_3 (Conv2D)	(None, 64, 258, 128)	147584
batch_normalization_3 (BatchNormalization)	(None, 64, 258, 128)	512
activation_3 (Activation)	(None, 64, 258, 128)	0
max_pooling2d_1 (MaxPooling2D)	(None, 32, 129, 128)	0
dropout_1 (Dropout)	(None, 32, 129, 128)	0
conv2d_4 (Conv2D)	(None, 32, 129, 256)	295168
batch_normalization_4 (BatchNormalization)	(None, 32, 129, 256)	1024
activation_4 (Activation)	(None, 32, 129, 256)	0
conv2d_5 (Conv2D)	(None, 32, 129, 256)	590880
batch_normalization_5 (BatchNormalization)	(None, 32, 129, 256)	1024
activation_5 (Activation)	(None, 32, 129, 256)	0
max_pooling2d_2 (MaxPooling2D)	(None, 16, 64, 256)	0
dropout_2 (Dropout)	(None, 16, 64, 256)	0
conv2d_6 (Conv2D)	(None, 16, 64, 512)	1180160
batch_normalization_6 (BatchNormalization)	(None, 16, 64, 512)	2048
activation_6 (Activation)	(None, 16, 64, 512)	0
conv2d_7 (Conv2D)	(None, 16, 64, 512)	2359808
batch_normalization_7 (BatchNormalization)	(None, 16, 64, 512)	2048
activation_7 (Activation)	(None, 16, 64, 512)	0
max_pooling2d_3 (MaxPooling2D)	(None, 8, 32, 512)	0
dropout_3 (Dropout)	(None, 8, 32, 512)	0
global_average_pooling2d (GlobalAveragePooling2D)	(None, 512)	0
reshape (Reshape)	(None, 512, 1)	0
attention_layer (AttentionLayer)	(None, 512, 1)	2
flatten (Flatten)	(None, 512)	0
dense (Dense)	(None, 512)	262656
batch_normalization_8 (BatchNormalization)	(None, 512)	2048
dropout_4 (Dropout)	(None, 512)	0
dense_1 (Dense)	(None, 256)	131328
batch_normalization_9 (BatchNormalization)	(None, 256)	1024
dropout_5 (Dropout)	(None, 256)	0
dense_2 (Dense)	(None, 7)	1799
=====		
Total params: 5,093,641		
Trainable params: 5,088,265		
Non-trainable params: 5,376		
=====		

ຮູບທີ 3.21 ລາຍລະອຽດການສະແດງຜົນ Compile ຂອງແບບຈຳລອງທີ່ດີທີ່ສຸດໃນທັງ 3 k

ຈາກຮູບທີ 3.21 ສະແດງຜົນ output ຂອງແບບຈຳລອງແຕ່ລະຊັ້ນເຊັ່ນ:

Input Layer:

- input_1 (InputLayer): Output (None, 128, 517, 6) - Param: 0

Convolutional Block 1:

- conv2d (Conv2D): Output (None, 128, 517, 64) - Param: 3,520
- batch_normalization: Output (None, 128, 517, 64) - Param: 256
- activation (Activation): Output (None, 128, 517, 64) - Param: 0
- conv2d_1 (Conv2D): Output (None, 128, 517, 64) - Param: 36,928
- batch_normalization_1: Output (None, 128, 517, 64) - Param: 256
- activation_1 (Activation): Output (None, 128, 517, 64) - Param: 0
- max_pooling2d (MaxPooling2D): Output (None, 64, 258, 64) - Param: 0
- dropout (Dropout): Output (None, 64, 258, 64) - Param: 0

Convolutional Block 2:

- conv2d_2 (Conv2D): Output (None, 64, 258, 128) - Param: 73,856
- batch_normalization_2: Output (None, 64, 258, 128) - Param: 512
- activation_2 (Activation): Output (None, 64, 258, 128) - Param: 0
- conv2d_3 (Conv2D): Output (None, 64, 258, 128) - Param: 147,584
- batch_normalization_3: Output (None, 64, 258, 128) - Param: 512
- activation_3 (Activation): Output (None, 64, 258, 128) - Param: 0
- max_pooling2d_1 (MaxPooling2D): Output (None, 32, 129, 128) - Param: 0
- dropout_1 (Dropout): Output (None, 32, 129, 128) - Param: 0

Convolutional Block 3:

- conv2d_4 (Conv2D): Output (None, 32, 129, 256) - Param: 295,168
- batch_normalization_4: Output (None, 32, 129, 256) - Param: 1,024
- activation_4 (Activation): Output (None, 32, 129, 256) - Param: 0
- conv2d_5 (Conv2D): Output (None, 32, 129, 256) - Param: 590,080
- batch_normalization_5: Output (None, 32, 129, 256) - Param: 1,024
- activation_5 (Activation): Output (None, 32, 129, 256) - Param: 0
- max_pooling2d_2 (MaxPooling2D): Output (None, 16, 64, 256) - Param: 0
- dropout_2 (Dropout): Output (None, 16, 64, 256) - Param: 0

Convolutional Block 4:

- conv2d_6 (Conv2D): Output (None, 16, 64, 512) - Param: 1,180,160
- batch_normalization_6: Output (None, 16, 64, 512) - Param: 2,048
- activation_6 (Activation): Output (None, 16, 64, 512) - Param: 0

- conv2d_7 (Conv2D): Output (None, 16, 64, 512) - Param: 2,359,808
- batch_normalization_7: Output (None, 16, 64, 512) - Param: 2,048
- activation_7 (Activation): Output (None, 16, 64, 512) - Param: 0
- max_pooling2d_3 (MaxPooling2D): Output (None, 8, 32, 512) - Param: 0
- dropout_3 (Dropout): Output (None, 8, 32, 512) - Param: 0

Feature Processing:

- global_average_pooling2d: Output (None, 512) - Param: 0
- reshape (Reshape): Output (None, 512, 1) - Param: 0
- attention_layer (AttentionLayer): Output (None, 512, 1) - Param: 2
- flatten (Flatten): Output (None, 512) - Param: 0

Dense Layers:

- dense (Dense): Output (None, 512) - Param: 262,656
- batch_normalization_8: Output (None, 512) - Param: 2,048
- dropout_4 (Dropout): Output (None, 512) - Param: 0
- dense_1 (Dense): Output (None, 256) - Param: 131,328
- batch_normalization_9: Output (None, 256) - Param: 1,024
- dropout_5 (Dropout): Output (None, 256) - Param: 0
- dense_2 (Dense): Output (None, 7) - Param: 1,799

ສະຫຼຸບພາລາມີຕີ:

- Total params: 5,093,641
- Trainable params: 5,088,205
- Non-trainable params: 5,376

"None" ໃນ Output shape ແມ່ນຫມາຍເຖິງຈຳນວນ batch size ທີ່ສາມາດປ່ຽນແປງໄດ້ ຫຼື ເວົ້າງ່າຍໆແມ່ນຈຳນວນຂໍ້ມູນທີ່ນຳມາຝຶກສອນ ແລະ Parameters (Params) ແມ່ນຄ່າ weights ແລະ biases ທີ່ແບບຈຳລອງຮຽນຮູ້ໃນລະຫວ່າງການຝຶກ, ເປັນຕົວເລກທີ່ໄດ້ຮັບການປັບປຸງຜ່ານ backpropagation ເພື່ອໃຫ້ແບບຈຳລອງສາມາດທຳນາຍໄດ້ແມ່ນຍຳ, ຍິ່ງມີ params ຫຼາຍ, ແບບຈຳລອງກໍ່ຊັບຊ້ອນ ແລະ ມີຄວາມສາມາດໃນການຮຽນຮູ້ຫຼາຍ.

ສາເຫດທີ່ບາງຊັ້ນມີ Params = 0 ແມ່ນຍ້ອນວ່າຊັ້ນນັ້ນບໍ່ມີຄ່າທີ່ຕ້ອງຮຽນຮູ້ ແຕ່ເປັນພຽງການປຸງແຕ່ງຫຼືປ່ຽນແປງຂໍ້ມູນຕາມກົດເກນທີ່ກຳໜົດໄວ້ແລ້ວ.

ໂຄງສ້າງແບບຈຳລອງນີ້ໄດ້ຮັບການອອກແບບໃຫ້ສາມາດຈັບລັກສະນະສຳຄັນຂອງສຽງເຄື່ອງດົນຕີລາວໃນທຸກລະດັບ ແລະ ອອກແບບສະເພາະເພື່ອແກ້ໄຂບັນຫາການສັບສົນລະຫວ່າງແຄນ, ຝິນ, ແລະ ຊໍ. ຊັ້ນ convolutional ຕົ້ນຈະຈັບລັກສະນະພື້ນຖານຂອງທັງ 6 features, ໃນຂະນະທີ່ຊັ້ນລຸ່ມລົງໄປຈະຈັບລັກສະນະທີ່ຊັບຊ້ອນຂຶ້ນ.

ສັງເກດວ່າ ອັດຕາການ dropout ຈະເພີ່ມຂຶ້ນຕາມລຳດັບຊັ້ນຂອງໂຄງຂ່າຍ (ຈາກ 25% ໃນຊັ້ນທຳອິດ ຫາ 50% ໃນຊັ້ນສຸດທ້າຍ), ເຊິ່ງເປັນການອອກແບບທີ່ຊ່ວຍເພີ່ມປະສິດທິພາບໃນການປ້ອງກັນການ overfitting.

3.1.5. ການປະເມີນຜົນ (Evaluation)

ວິທີການປະເມີນຜົນແບບຈຳລອງຈະໃຊ້ຂະບວນການ confusion Matrix ເພື່ອທົດສອບແບບຈຳລອງທັງສອງແບບເຊັ່ນ: ຂໍ້ມູນທີ່ແບບໄວ້ເພື່ອທົດສອບແບບຈຳລອງ 20% ແລະ ທົດສອບແບບຈຳລອງກັບຂໍ້ມູນທີ່ໃຊ້ຝຶກສອນ 80%, ເຊິ່ງຈະປະເມີນໂດຍກັນວັດຄວາມຖືກຕ້ອງ (Accuracy Score) ໂດຍລວມຂອງແບບຈຳລອງ.

3.1.6. ການນຳໄປໃຊ້ (Deployment)

ເພື່ອໃຫ້ແບບຈຳລອງສາມາດນຳໄປໃຊ້ໃນແອັບພລິເຄຊັນສຳລັບມືຖືໄດ້, ພວກຂ້າພະເຈົ້າໄດ້ແປງແບບຈຳລອງຈາກຮູບແບບ TensorFlow ເປັນຮູບແບບ ONNX (Open Neural Network Exchange) ຊຶ່ງເປັນຮູບແບບມາດຕະຖານທີ່ສາມາດໃຊ້ໄດ້ກັບຫຼາຍແພລດຟອມ.

ການແປງແບບຈຳລອງເປັນຮູບແບບ ONNX ມີຂໍ້ດີດັ່ງນີ້:

- ຄວາມເຂົ້າກັນໄດ້ສູງ: ONNX ສາມາດໃຊ້ໄດ້ກັບຫຼາຍແພລດຟອມແລະຫຼາຍພາສາໂປຣແກຣມ
- ປະສິດທິພາບສູງ: ONNX Runtime ມີການປັບປຸງປະສິດທິພາບສຳລັບອຸປະກອນມືຖື
- ຂະໜາດນ້ອຍ: ຮູບແບບ ONNX ມີຂະໜາດນ້ອຍກວ່າຮູບແບບ TensorFlow ດັ່ງເດີມ
- ເໝາະສົມສຳລັບການນຳໃຊ້ໃນ Streamlit: ສາມາດນຳໃຊ້ກັບ web applications ແລະ real-time inference ໄດ້ຢ່າງງ່າຍດາຍ

ແບບຈຳລອງທີ່ໄດ້ຖືກແປງເປັນຮູບແບບ ONNX ແລ້ວມີຂະໜາດປະມານ 19 MB (ເນື່ອງຈາກໃຊ້ multi-channel features), ເຊິ່ງຍັງເໝາະສົມສຳລັບການນຳໃຊ້ໃນແອັບພລິເຄຊັນທີ່ຕ້ອງການປະສິດທິພາບສູງ.

ພວກຂ້າພະເຈົ້າໄດ້ບັນທຶກຂໍ້ມູນ metadata ທີ່ຈຳເປັນສຳລັບການນຳໃຊ້ແບບຈຳລອງໃນອະນາຄົດ, ເຊິ່ງລວມມີ:

ຂໍ້ມູນພື້ນຖານ:

- ຊື່ກຸ່ມເຄື່ອງດົນຕີ: khean, khong_vong, pin, ranad, saw, sing, unknown (7 ປະເພດ)
- ປະເພດຂອງຄຸນລັກສະນະ: Multi-channel features (6 channels)
- Feature Channels: mel, harmonic, percussive, mfcc, delta, delta2
- ຮູບແບບ Input: [128, time_frames, 6] (mel_bands, time, channels)

ການຕັ້ງຄ່າສຳລັບ Feature Extraction:

- ອັດຕາການຊັກຕົວຢ່າງ: 44,100 Hz
- ຄວາມຍາວຂອງສຽງ: 6.0 ວິນາທີ
- Mel-spectrogram Parameters: n_mels = 128, hop_length = 512, n_fft = 2048, fmax = 8,000
- HPSS Parameters: margin = (1.0, 5.0)
- MFCC Parameters: n_mfcc = 20

ການຕັ້ງຄ່າສໍາລັບ Training:

- Focal Loss: $\gamma = 2.0$, $\alpha = 0.25$
- Enhanced Class Weights: $\text{boost} = 1.5x$ ສໍາລັບ difficult instruments
- SpecAugment: $\text{freq_mask} = 27$, $\text{time_mask} = 100$
- Mixup: $\alpha = 0.4$
- L2 Regularization: 0.01
- Dropout Rate: 0.5
- Learning Rate: 0.0001

ຂໍ້ມູນ metadata ເຫຼົ່ານີ້ຈະຊ່ວຍໃຫ້ສາມາດນໍາແບບຈໍາລອງໄປໃຊ້ໄດ້ຢ່າງຖືກຕ້ອງ, ໂດຍຮູ້ວ່າຄວນຕັ້ງຄ່າ parameter ຕ່າງໆແນວໃດເພື່ອໃຫ້ໄດ້ຜົນລັບທີ່ດີທີ່ສຸດ ແລະ ເຂົ້າໃຈວ່າເປັນຫຍັງແບບຈໍາລອງຈຶ່ງສາມາດແກ້ໄຂບັນຫາການສັບສິນລະຫວ່າງແຄນ, ຝິນ, ແລະ ຊໍ ໄດ້ສໍາເລັດ.

3.2. ເຄື່ອງມືທີ່ໃຊ້ໃນການຄົ້ນຄວ້າ

3.2.1. Hardware

ຄອມພິວເຕີທີ່ໃຊ້ສໍາລັບຂຽນ Code ໃນການສ້າງ Application , ສ້າງ Model ໃນການວິເຄາະຂໍ້ມູນ ແລະ ທົດສອບລະບົບມີຄຸນລັກສະນະດັ່ງນີ້:

- 1) Notebook Asus TUF Gaming Dash F15 FX516PM-HN086T
 - CPU: Intel Core i5-11300H (4C/8T & 2.60 – 4.40GHz)
 - RAM: 16GB DDR4 Bus 3200 MHz
 - GPU: Intel Iris Xe Graphics + NVIDIA GeForce RTX 3060 (6GB GDDR6)
- 2) Notebook Acer Nitro 5 AN515-775P
 - CPU: Intel Core i7-11800H (8C/16T: 2.30 – 4.60 GHz)
 - RAM: 16GB DDR4 3200 MHz (8GB x 2)
 - GPU: Intel UHD + NVIDIA GeForce RTX 3050 (4GB GDDR6)
- 3) Desktop PC
 - CPU: Intel Core i5-14600KF (14C/20T: 5.3 GHz)
 - RAM: 32GB DDR4 3200 MHz (16GB x 2)
 - GPU: RTX 5070 (12GB GDDR7)


3.2.2. Software

1. Operating System (OS) Windows 11 Home.
2. Microsoft Tools: Office Professional 2019.
3. IDE Tools: VS Code, Draw.io, Figma.
4. Programming Languages: Dart, Python.
- 2) Python Libraries: TensorFlow, Librosa, Seaborn, ONNX, Sklearn, Matplotlib, NumPy, FastAPI, Uvicorn.
1. Frameworks: Flutter.
2. Browsers: Google Chrome, Microsoft Edge.

3.3. ການວິເຄາະລະບົບ

3.3.1.ແຜນວາດລວມຂອງລະບົບ

ລະບົບຈຳແນກເຄື່ອງດົນຕີພື້ນເມືອງລາວປະກອບດ້ວຍ 4 ສ່ວນຫຼັກ ຄື: ສ່ວນສຳຜັນກັບຜູ້ໃຊ້ (Frontend), ສ່ວນປະມວນຜົນ (Backend), ສ່ວນຈັດເກັບຂໍ້ມູນ (Database) ແລະ ສ່ວນ Deep Learning Model ດັ່ງທີ່ສະແດງໃນຮູບພາບດ້ານລຸ່ມ:



ຮູບທີ 3.22 ແຜນວາດລວມຂອງລະບົບ

ຄຳອະທິບາຍສ່ວນປະກອບຂອງລະບົບ:

- 1) ຜູ້ໃຊ້ສິ່ງຄຳຮ້ອງຂໍຜ່ານ Flutter App
- 2) Flutter App ສົ່ງຂໍ້ມູນໄປຫາ FastAPI Backend ຜ່ານ HTTP/HTTPS
- 3) Backend ປະມວນຜົນຂໍ້ມູນແລະສົ່ງໄປຫາ Deep Learning Model
- 4) Deep Learning Model ວິເຄາະສຽງແລະສົ່ງຜົນກັບ
- 5) ສົ່ງຜົນລັບໄປຫາ Flutter App ໃນຮູບແບບ JSON

3.3.2. ແຜນວາດ Use Case Diagram

1) ຄົ້ນຫາ Actor

ຫຼັງຈາກໄດ້ຮັບຮູ້ລາຍລະອຽດ ແລະ ຂະບວນການເຮັດວຽກແລ້ວ ຈຶ່ງມາພິຈາລະນາຫາ Actor ແລະ ສາມາດພິຈາລະນາຫາໄດ້ 1 Actor ແມ່ນ ຜູ້ໃຊ້ງານ (User).


2) ຄົ້ນຫາ Use Cases ທີ່ໂຕ້ຕອບກັບ Actor ໂດຍກົງ

ສາມາດຄົ້ນຫາ Use Case ທີ່ໂຕ້ຕອບກັບ Actor ໂດຍກົງໄດ້ດັ່ງນີ້:

- ບັນທຶກສຽງ (Record Audio)
- ນຳເຂົ້າຟາຍສຽງ (Import Audio File)
- ຈຳແນກເຄື່ອງດົນຕີ (Classify Instrument)
- ເບິ່ງລາຍລະອຽດ (View Details)

3) Use Case Diagram

Use Case Diagram ສະແດງໃຫ້ເຫັນການໂຕ້ຕອບລະຫວ່າງຜູ້ໃຊ້ (Actor) ກັບລະບົບ ຜ່ານ Use Cases ຕ່າງໆ ທີ່ລະບົບສາມາດໃຫ້ບໍລິການໄດ້. ແຜນວາດນີ້ຊ່ວຍໃຫ້ເຂົ້າໃຈຟັງຊັນການເຮັດວຽກຫຼັກຂອງລະບົບ ແລະ ຄວາມຕ້ອງການຂອງຜູ້ໃຊ້.



ຮູບທີ 3.23 Use Case Diagram ສະແດງໃຫ້ເຫັນການໂຕ້ຕອບລະຫວ່າງຜູ້ໃຊ້ກັບລະບົບ

ຕາຕະລາງທີ 3.3: ລາຍລະອຽດ Use Case - ບັນທຶກສຽງ

ລາຍການ	ລາຍລະອຽດ
Use Case ID	1
Use Case Title	ບັນທຶກສຽງ (Record Audio)
Primary Actor	ຜູ້ໃຊ້ (User)

Description	ຜູ້ໃຊ້ສາມາດບັນທຶກສຽງເຄື່ອງດົນຕີໂດຍກົງຜ່ານໄມໂຄຣໂຟນຂອງອຸປະກອນ
Main Flow	1. ຜູ້ໃຊ້ກົດປຸ່ມ "ບັນທຶກສຽງ" 2. ລະບົບຂໍອະນຸຍາດເຂົ້າເຖິງໄມໂຄຣໂຟນ 3. ຜູ້ໃຊ້ອະນຸຍາດການເຂົ້າເຖິງ 4. ລະບົບເລີ່ມບັນທຶກສຽງ 5. ສະແດງສະຖານະ "ກຳລັງບັນທຶກ" ເປັນເວລາ 8 ວິນາທີ 6. ລະບົບຢຸດບັນທຶກ ແລະ ບັນທຶກຟາຍ
Exception Flow	1. ໄມໂຄຣໂຟນບໍ່ວຽກ: ແຈ້ງເຕືອນກວດສອບອຸປະກອນ 2. ພື້ນທີ່ເກັບຂໍ້ມູນເຕັມ: ແຈ້ງໃຫ້ລຶບຟາຍເກົ່າ
Postconditions	ໄດ້ຟາຍສຽງທີ່ຜ່ອມສຳລັບການຈຳແນກ

ຕາຕະລາງທີ 3.4: ລາຍລະອຽດ Use Case - ນຳເຂົ້າຟາຍສຽງ

ລາຍການ	ລາຍລະອຽດ
Use Case ID	2
Use Case Title	ນຳເຂົ້າຟາຍສຽງ (Import Audio File)
Primary Actor	ຜູ້ໃຊ້ (User)
Description	ຜູ້ໃຊ້ສາມາດເລືອກຟາຍສຽງທີ່ມີຢູ່ໃນອຸປະກອນເພື່ອນຳມາຈຳແນກ
Preconditions	- ມີຟາຍສຽງຢູ່ໃນອຸປະກອນ - ຟາຍເປັນຮູບແບບທີ່ຮອງຮັບ (.wav, .mp3)
Main Flow	1. ຜູ້ໃຊ້ກົດປຸ່ມ “ນຳເຂົ້າຟາຍ” 2. ລະບົບເປີດ File Browser 3. ຜູ້ໃຊ້ເລືອກຟາຍສຽງ 4. ລະບົບກວດສອບຟາຍ 5. ລະບົບໂຫຼດຟາຍເຂົ້າແອັບ 6. ສະແດງຂໍ້ມູນຟາຍ (ຊື່, ຂະໜາດ, ໄລຍະເວລາ)
Alternative Flow	• ຟາຍບໍ່ຮອງຮັບ: - ສະແດງລາຍການຮູບແບບທີ່ຮອງຮັບ - ກັບໄປຂັ້ນຕອນທີ 2 • ຟາຍໃຫຍ່ເກີນ (10MB): - ແຈ້ງເຕືອນຂະໜາດສູງສຸດ - ກັບໄປຂັ້ນຕອນທີ 2
Exception Flow	• ຟາຍເສຍຫາຍ: ແຈ້ງເຕືອນແລະຂໍໃຫ້ເລືອກຟາຍໃໝ່ • ບໍ່ມີສິດເຂົ້າເຖິງຟາຍ: ແຈ້ງໃຫ້ຕັ້ງຄ່າສິດ

Postconditions	ໄດ້ຟາຍສຽງທີ່ຝອມສໍາລັບການຈຳແນກ
-----------------------	-------------------------------

ຕາຕະລາງທີ 3.5: ລາຍລະອຽດ Use Case - ຈຳແນກເຄື່ອງດົນຕີ

ລາຍການ	ລາຍລະອຽດ
Use Case ID	3
Use Case Title	ຈຳແນກເຄື່ອງດົນຕີ (Classify Instrument)
Primary Actor	ລະບົບ (System)
Description	ລະບົບວິເຄາະຟາຍສຽງ ແລະ ຈຳແນກປະເພດເຄື່ອງດົນຕີ
Preconditions	- ມີຟາຍສຽງທີ່ຖືກຕ້ອງ - Deep Learning Model ພ້ອມໃຊ້ງານ - ມີການເຊື່ອມຕໍ່ອິນເຕີເນັດ
Main Flow	1. ລະບົບຮັບຟາຍສຽງຈາກຜູ້ໃຊ້ 2. ປະມວນຜົນສຽງ (HPSS & Multi-Channel Features Extraction) 3. ສົ່ງ Features ໄປຫາ Deep Learning Model 4. Deep Learning Model ວິເຄາະ ແລະ ຄຳນວນ Probability 5. ເລືອກເຄື່ອງດົນຕີທີ່ມີ Probability ສູງສຸດ 6. ສົ່ງຜົນການຈຳແນກກັບຜູ້ໃຊ້
Alternative Flow	ຟາຍສຽງບໍ່ຊັດເຈນ: - ແຈ້ງເຕືອນຄຸນນະພາບຕ່ຳ - ສະເໜີການປັບປຸງສຽງ
Exception Flow	• Deep Learning Model ຂັດຂ້ອງ: ແຈ້ງເຕືອນລອງໃໝ່ພາຍຫຼັງ • ບໍ່ມີອິນເຕີເນັດ: ແຈ້ງກວດສອບການເຊື່ອມຕໍ່
Postconditions	ໄດ້ຜົນການຈຳແນກເຄື່ອງດົນຕີພ້ອມຄ່າຄວາມໝັ້ນໃຈ

ຕາຕະລາງທີ 3.6: ລາຍລະອຽດ Use Case - ເບິ່ງຜົນລັບ

ລາຍການ	ລາຍລະອຽດ
Use Case ID	4
Use Case Title	ເບິ່ງຜົນລັບ (View Results)
Primary Actor	ຜູ້ໃຊ້ (User)
Description	ຜູ້ໃຊ້ສາມາດເບິ່ງຜົນການຈຳແນກເຄື່ອງດົນຕີຫຼັງຈາກລະບົບວິເຄາະສຽງສໍາເລັດແລ້ວ
Preconditions	- ການວິເຄາະສຽງສໍາເລັດແລ້ວ - ມີຜົນການຈຳແນກເຄື່ອງດົນຕີ

Main Flow	1. ລະບົບສະແດງໜ້າຜິວລັບ 2. ສະແດງລາຍລະອຽດເຄື່ອງດົນຕີທີ່ກວດພົບ 3. ສະແດງເປີເຊັນຄວາມໝັ້ນໃຈ (Confidence Score) ຂອງແຕ່ລະເຄື່ອງດົນຕີ
Exception Flow	- ຂໍ້ມູນຜິວລັບເສຍຫາຍ: ແຈ້ງເຕືອນຂໍ້ຜິດພາດ ແລະ ລອງໃໝ່ອີກຄັ້ງ.
Postconditions	ຜູ້ໃຊ້ເຫັນລາຍລະອຽດການຈຳແນກເຄື່ອງດົນຕີຜ່ານຂໍ້ມູນ.


Use Cases ຫຼັກ:

- ບັນທຶກສຽງ (Record Audio): ຜູ້ໃຊ້ສາມາດບັນທຶກສຽງເຄື່ອງດົນຕີໂດຍກົງຜ່ານໄມໂຄຣໂຟນຂອງອຸປະກອນມືຖື ເພື່ອນຳໄປວິເຄາະຕໍ່ໄປ.
- ນຳເຂົ້າຟາຍລສຽງ (Import Audio File): ຜູ້ໃຊ້ສາມາດເລືອກຟາຍລສຽງທີ່ມີຢູ່ແລ້ວໃນອຸປະກອນ (.wav, .mp3) ເພື່ອນຳມາວິເຄາະ.
- ຈຳແນກເຄື່ອງດົນຕີ (Classify Instrument): ລະບົບວິເຄາະສຽງດ້ວຍ Deep Learning Model ແລະ ຈຳແນກປະເພດເຄື່ອງດົນຕີ 6 ປະເພດ (ແຄນ, ຊໍອູ້, ຊິງ, ຟິນ, ຄໍ່ອງວົງ, ລະນາດ).
- ເບິ່ງລາຍລະອຽດ (View Details): ຜູ້ໃຊ້ສາມາດເບິ່ງຂໍ້ມູນປະຫວັດຄວາມເປັນມາ, ຮູບພາບ ແລະ ລາຍລະອຽດຂອງເຄື່ອງດົນຕີທີ່ຖືກຈຳແນກ.

3.3.3.ແຜນວາດ Sequence Diagram

1) Sequence Diagram - ການບັນທຶກສຽງ

ການບັນທຶກສຽງສະແດງໃຫ້ເຫັນລຳດັບການໂຕ້ຕອບລະຫວ່າງອົງປະກອບຕ່າງໆ ໃນຂະບວນການບັນທຶກສຽງເຄື່ອງດົນຕີ ແລະ ການວິເຄາະຜິວ. ການໂຕ້ຕອບເລີ່ມຈາກຜູ້ໃຊ້ກົດປຸ່ມບັນທຶກ ຈົນເຖິງການສະແດງຜິວການຈຳແນກ.




ຮູບທີ 3.24 Sequence Diagram ບັນທຶກສຽງເຄື່ອງດົນຕີ ແລະ ການວິເຄາະຜົນລັບ

ຂະບວນການເຮັດວຽກ:

1. ຜູ້ໃຊ້ກົດປຸ່ມ "ບັນທຶກສຽງ" ໃນ Flutter App
2. Flutter App ຂໍອະນຸຍາດເຂົ້າເຖິງໄມໂຄຣໂຟນຈາກລະບົບ
3. ເລີ່ມບັນທຶກສຽງເປັນເວລາ 8 ວິນາທີ
4. ສົ່ງຟາຍສຽງໄປ Backend API ຜ່ານ HTTP POST
5. Backend ປະມວນຜົນ ແລະ ສົ່ງຂໍ້ມູນໄປ Model
6. Model ວິເຄາະ ແລະ ສົ່ງຜົນການຈຳແນກກັບຄືນ
7. ສົ່ງຜົນລັບໄປ Flutter App ແລະ ສະແດງໃຫ້ຜູ້ໃຊ້
 - ຖ້າ $\geq 70\%$: ສົ່ງຊື່ເຄື່ອງດົນຕີ + confidence
 - ຖ້າ $< 70\%$: ສົ່ງ "unknown" + confidence

2) Sequence Diagram - ການນຳເຂົ້າຟາຍ

Sequence Diagram ການນຳເຂົ້າຟາຍສະແດງຂະບວນການທີ່ຜູ້ໃຊ້ເລືອກຟາຍສຽງທີ່ມີຢູ່ແລ້ວໃນອຸປະກອນ ແລະ ນຳມາວິເຄາະ. ຂະບວນການນີ້ແຕກຕ່າງຈາກການບັນທຶກສຽງໃນການໂຕ້ຕອບກັບ File System ຂອງອຸປະກອນ.



ຮູບທີ 3.25 Sequence Diagram ການນຳເຂົ້າຟາຍສຽງ ແລະ ການວິເຄາະຜົນລັບ

ຂະບວນການເຮັດວຽກ:

1. ຜູ້ໃຊ້ກົດປຸ່ມ "ນຳເຂົ້າຟາຍ" ໃນ Flutter App
2. Flutter App ເປີດ File Browser ຂອງອຸປະກອນ
3. ຜູ້ໃຊ້ເລືອກຟາຍສຽງ (.wav ຫຼື .mp3) ລະບົບກວດສອບຮູບແບບ ແລະ ຂະໜາດຟາຍ
4. Flutter ກວດສອບ:
 - ຮູບແບບຟາຍ (WAV/MP3 ເທົ່ານັ້ນ)
 - ຂະໜາດຟາຍ (ສູງສຸດ 10MB)
 - ໄລຍະເວລາ (ແນະນຳ ≤ 10 ວິນາທີ)
5. ຖ້າຟາຍຖືກຕ້ອງ: ສົ່ງໄປ Backend API ຜ່ານ HTTP POST /predict

6. ຖ້າຝາຍບໍ່ຖືກ: ສະແດງຂໍ້ຜິດພາດ ແລະ ໃຫ້ເລືອກໃໝ່

7. ຂະບວນການວິເຄາະຄືກັນການບັນທຶກສຽງ


8. Flutter ດຶງຂໍ້ມູນຈາກ local list ຕາມຜືນທີ່ໄດ້

ສະແດງຜົນການຈຳແນກແລະລາຍລະອຽດເຄື່ອງດົນຕີຄວາມແຕກຕ່າງຈາກການບັນທຶກສຽງ: ບໍ່ຕ້ອງ
ຂໍອະນຸຍາດໄມໂຄຣໂຟນ ແຕ່ຕ້ອງມີການກວດສອບຝາຍທີ່ເລືອກວ່າຖືກຕ້ອງ ຫຼື ບໍ່.

3.3.4.ແຜນວາດ Activity Diagram

Activity Diagram ການບັນທຶກສຽງສະແດງ Flow ຂອງກິດຈະກຳ (Activity Flow) ແລະ
ການຕັດສິນໃຈ (Decision Points) ໃນຂະບວນການບັນທຶກສຽງເຄື່ອງດົນຕີ. ແຜນວາດນີ້ເລີ່ມຈາກ Initial
State (●) ໄປຫາ Final State (◎) ຜ່ານກິດຈະກຳຕ່າງໆ

1) Activity Diagram - ການວິເຄາະເຄື່ອງດົນຕີລາວ.




ຮູບທີ 3.26: Activity Diagram ການວິເຄາະເຄື່ອງດົນຕີລາວ.

ຂັ້ນຕອນຫຼັກ:

- ຖ້າເລືອກຟາຍ: ກວດສອບຮູບແບບ (.wav/.mp3) ແລະ ຂະໜາດ ($\leq 10\text{MB}$)
- App ກວດສອບຄຸນນະພາບຟາຍ
- ຖ້າຟາຍຜິດພາດຈະສະແດງການແຈ້ງເຕືອນແລະສິ້ນສຸດຂະບວນການ
- ຖ້າຟາຍຖືກຕ້ອງຈະສົ່ງຟາຍໄປຫາ Backend (POST /predict)
- Backend Extract Enhanced Features (HPSS + multi-channel) ຈາກຟາຍສຽງ
- ແບ່ງເປັນຫຼາຍ segments ສໍາລັບການວິເຄາະ
- ສົ່ງ Features ໄປຫາ CNN Model
- CNN Model ເຮັດ Ensemble prediction ທຸກ segment
- CNN Model ວິເຄາະແລະຄຳນວນ Probability + Confidence Score
- ສົ່ງຜົນການຈຳແນກກັບຄືນມາ Backend
- Backend ກວດສອບ confidence score (threshold 70%)
- ຖ້າ $\geq 70\%$: ກຳນົດເຄື່ອງດົນຕີທີ່ກວດພົບ
- ຖ້າ $< 70\%$: ກຳນົດເປັນ "unknown"
- Backend ສົ່ງຜົນລັບໄປຫາ App ໃນຮູບແບບ JSON
- App ດຶງລາຍລະອຽດເຄື່ອງດົນຕີຈາກ local list ຕາມຜົນທີ່ໄດ້
- App ສະແດງຜົນການຈຳແນກ + confidence score
- ຖ້າເປັນ "unknown": ສະແດງຂໍ້ສະເໜີປັບປຸງການບັນທຶກ
- ຜູ້ໃຊ້ເບິ່ງຜົນລັບແລະຂໍ້ມູນເຄື່ອງດົນຕີ

2) Activity Diagram - ການຈັດການຂໍ້ຜິດພາດ

Activity Diagram ການຈັດການຂໍ້ຜິດພາດສະແດງການຈັດການ Exception Handling ທີ່ອາດເກີດຂຶ້ນໃນລະບົບ.



ຮູບທີ 3.27: Activity Diagram ການຈັດການຂໍ້ຜິດພາດ

ປະເພດຂໍ້ຜິດພາດທີ່ຈັດການ:

1. Network Error: ບໍ່ມີອິນເຕີເນັດ
2. File Error: ຮູບແບບບໍ່ຮອງຮັບ ຫຼື ຂະໜາດໃຫຍ່ເກີນ
3. Permission Error: ບໍ່ມີສິດເຂົ້າເຖິງ microphone
4. Hardware Error: ໄມໂຄຣໂຟນຂັດຂ້ອງ
5. Processing Error: Model/Backend ບໍ່ສາມາດປະມວນຜົນໄດ້
6. Confidence Error: ຜົນການວິເຄາະບໍ່ແນ່ນອນ ($<70\%$)

3) ຂໍ້ມູນທີ່ລະບົບຈັດການ

Activity Diagram ການນຳເຂົ້າຟາຍສະແດງຂະບວນການທີ່ຜູ້ໃຊ້ເລືອກຟາຍສຽງຈາກອຸປະກອນ ແລະ ການກວດສອບຟາຍກ່ອນນຳໄປວິເຄາະ.


ຕາຕະລາງທີ 3.7: ປະເພດຂໍ້ມູນທີ່ລະບົບຮອງຮັບ

ປະເພດຂໍ້ມູນ	ລາຍລະອຽດ	ຂໍ້ກຳນົດ
ຟາຍສຽງ Input	- ຮູບແບບ: .wav, .mp3 - Sample Rate: 44100Hz - Channels: Mono/Stereo	- ຂະໜາດສູງສຸດ: 10MB - ໄລຍະເວລາ: 6-10 ວິນາທີ (segments) - ຄຸນນະພາບຕໍ່າສຸດ: 44.1kHz
Extract Features	- Mel-Spectrogram: 128 mel bins - N_FFT: 2048 - Hop Length: 512 - FMAX: 8000Hz	- ຂະໜາດ Features: 128 × time_frames - Normalization: Z-score - Format: 2D array for CNN
ຜົນການ ຈຳແນກ	- ເຄື່ອງດົນຕີ: 6 ປະເພດ + Unknown - Confidence: 0-100%	- High: ≥70% - Low: <70% (Unknown)
ຂໍ້ມູນເຄື່ອງ ດົນຕີ	- ຊື່ - ປະຫວັດ	- ສຽງຕົວຢ່າງ: MP3 <10MB - Model: CNN with K-fold validation

3.4. ການອອກແບບ

3.4.1. ການອອກແບບຮ່າງສະແດງຜິນ

1) ແຖບນຳທາງຂອງແອັບ




ຮູບທີ 3.28 ໂຄງຜັງການນຳທາງຫຼັກຂອງແອັບຈຳແນກເຄື່ອງດົນຕີລາວ

2) ໜ້າຈຳຫຼັກ (Home Screen)




ຮູບທີ 3.29 ໜ້າຫຼັກສະແດງຂໍ້ມູນໂຄງການ ແລະ ປຸ່ມການດຳເນີນງານດ້ວນ

3) ໜ້າຈໍບັນທຶກສຽງເຄື່ອງດົນຕີ (Record Screen)



ຮູບທີ 3.30 ອອກແບບໜ້າບັນທຶກສຽງຜ່ອມຄຳແນະນຳ ແລະ ການສະແດງຜົນ

4) ໜ້າຳຜັນການວິເຄາະລະອຽດ (Detailed Results Screen)




ຮູບທີ 3.31 ອອກແບບຜົນການວິເຄາະລະອຽດຜ່ອມຄະແນນຄວາມເຊື່ອໝັ້ນ

5) ໜ້າຳຜົນການວິເຄາະລະອຽດ (Detailed Results Screen)



ຮູບທີ 3.32 ອອກແບບໜ້າຜົນການໃຊ້ງານ

6) ໜ້າຈໍຕັ້ງຄ່າ (Settings Screen)



ຮູບທີ 3.33 ອອກແບບໜ້າຕັ້ງຄ່າແອັບ

ບົດທີ 4


ຜົນຂອງການສຶກສາ ແລະ ອະທິບາຍຜົນ

4.1. ລາຍງານຜົນການສຶກສາ ແລະ ອະທິບາຍຜົນ

ໃນການລາຍງານ ແລະ ອະທິບາຍຜົນການພັດທະນາແບບຈຳລອງແບ່ງອອກເປັນ 3 ພາກສ່ວນຄື: ລາຍງານຜົນສະຖິຕິຂອງຂໍ້ມູນ, ລາຍງານຜົນການຝຶກສອນແບບຈຳລອງ ແລະ ລາຍງານຜົນການປະເມີນແບບຈຳລອງ.

4.1.1. ລາຍງານຜົນສະຖິຕິຂອງຂໍ້ມູນ

ຈາກການເກັບຂໍ້ມູນຂອງພວກຂ້າພະເຈົ້າໂດຍການອັດສຽງເຄື່ອງດົນຕີແຕ່ລະປະເພດ ແລະ ສຽງອື່ນໆ (unkown class) ຜ່ານແອັບພິເຄຊັນ Voice Recorder ເທິງໂທລະສັບມືຖືຂໍ້ມູນທີ່ໄດ້ທັງໝົດແມ່ນເປັນຟາຍ .wav ແລະ ມີການກະແຈກຕົວຂອງແຕ່ລະ class ຂໍ້ມູນດັ່ງໃນຮູບທີ 4.1 ສະແດງໃຫ້ເຫັນວ່າຟາຍທີ່ໄດ້ບັນທຶກທັງໝົດແມ່ນ 2,113 ຟາຍເຊິ່ງແຄນມີຢູ່ທີ່ 295 ຟາຍ ເທົ່າກັບ 13.96%, ຄ້ອງວົງມີ 314 ຟາຍ ເທົ່າກັບ 14.86%, ຝົນມີ 285 ຟາຍ ເທົ່າກັບ 13.49%, ລະນາດມີ 302 ຟາຍ ເທົ່າກັບ 14.29%, ຊໍ 314 ຟາຍ ເທົ່າກັບ 14.86%, ຊິ່ງ 295 ຟາຍ ເທົ່າກັບ 13.96% ແລະ ຂໍ້ມູນສຽງອື່ນ (unkown sound) ແມ່ນມີ 308 ຟາຍ ເທົ່າກັບ 14.58%.



ຮູບທີ 4.1 ການກະຈາຍຕົວຂອງຟາຍສຽງແຕ່ລະເຄື່ອງດົນຕີ ແລະ ສຽງອື່ນ

```

1. PROCESSING DATASET WITH ENHANCED FEATURES...
Processing dataset with enhanced features...
Total files found: 2113
Classes: ['khean', 'khong_vong', 'pin', 'ranad', 'saw', 'sing', 'unknown']
Train files: 1690, Test files: 423
Extracting enhanced features for training set...
100%|
Extracting enhanced features for test set...
100%|

Final dataset shape:
X_train: (2114, 128, 517, 6)
X_test: (422, 128, 517, 6)
Number of channels: 6
✓ Dataset processed in 0:17:49.773789

Class distribution in training set:
khean: 368 samples
khong_vong: 292 samples
pin: 247 samples
ranad: 274 samples
saw: 285 samples
sing: 321 samples
unknown: 327 samples


```

ຮູບທີ 4.2 ການກະຈາຍຕົວຂອງຂໍ້ມູນຕົວຢ່າງແຕ່ລະເຄື່ອງດົນຕີ ແລະ ສຽງອື່ນ ພາຍຫລັງການປະມວນຜົນສຽງ

ຫຼັງຈາກທຳການແບ່ງຂໍ້ມູນສຳລັບຝຶກສອນແບບຈຳລອງປະມານ 80% ຈະເຫຼືອ file ທັງໝົດຢູ່ທີ່ 1,690 ຟາຍ ພາຍຫລັງການສະກັດຄຸນລັກສະນະໃຫ້ກັບຟາຍສຽງຈະໄດ້ການກະຈາຍຕົວຂອງຕົວຢ່າງໃນຊຸດຝຶກສອນຂໍ້ມູນດັ່ງຮູບທີ 4.2 ແຄນຈະມີ 368 ຕົວຢ່າງ, ຄ້ອງວົງ 292 ຕົວຢ່າງ, ຟິນ 247 ຕົວຢ່າງ, ລະນາດ 274 ຕົວຢ່າງ, ຊໍຮໍ 285 ຕົວຢ່າງ, ຊິງ 321 ຕົວຢ່າງ ແລະ ສຽງອື່ນອີກ 327 ຕົວຢ່າງ.


4.1.2. ລາຍງານຜົນການຝຶກສອນແບບຈຳລອງ

ການສ້າງແບບຈຳລອງ “ການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍໃຊ້ເຕັກນິກການຮຽນຮູ້ຂັ້ນສູງ” ໄດ້ນຳໃຊ້ວິທີການຂອງ CNN ໃນການຝຶກສອນແລະໄດ້ມີການກວດສອບຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງດ້ວຍວິທີການ K-Fold Cross Validation ເຊິ່ງໄດ້ກຳນົດເອົາ $k = 3$ ແລະໄດ້ມີການວັດການກວດສອບປຽບທຽບກັບແຕ່ລະ Fold ແລ້ວກຳນົດເອົາ fold ທີ່ດີທີ່ສຸດມາເປັນໂຕນຳໃຊ້ ດັ່ງຮູບທີ 4.3.




ຮູບທີ 4.3 ສະແດງຄ່າການກວດຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງ ແລະ ຄ່າການກວດສອບການສູນເສຍຂອງແບບຈຳລອງທັງ 3 Fold

ຈາກຮູບທີ 4.3 ຈະເຫັນໄດ້ວ່າຄ່າການກວດສອບຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງໃນ fold ທີ່ 1 ມີຄ່າສູງສຸດຢູ່ທີ່ 0.994 ແລະ ຄ່າການກວດສອບການສູນເສຍຂອງແບບຈຳລອງຕໍ່າທີ່ສຸດໃນ fold ທັງໝົດຢູ່ທີ່ 0.039 ສະນັ້ນ fold ທີ່ 1 ຈະເປັນ fold ທີ່ຖືກເລືອກໄປເປັນ model ເພື່ອ deploy.



ຮູບທີ 4.4 ສະແດງຄ່າຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງ ແລະ ຄ່າການກວດສອບຄວາມຖືກຕ້ອງພ້ອມບອກຮອບຂອງການຝຶກທີ່ດີທີ່ສຸດ


ຈາກຮູບທີ 4.4 ທີ່ສະແດງຄ່າຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງທີ່ເພີ່ມຂຶ້ນໃນການຝຶກສອນຄັ້ງທຳອິດ ແມ່ນ 0.4329 ຄິດເປັນ 43.29% ແລະ ຮອບສຸດທ້າຍແມ່ນ 0.9673 ຄິດເປັນ 96.73% ແລະ ຄະແນນການກວດສອບໃນຄັ້ງທຳອິດແມ່ນ 0.1517 ຄິດເປັນ 15.17% ແລະ ຄັ້ງທີ່ດີທີ່ສຸດແມ່ນ 0.9943 ຄິດເປັນ 99.43% ຈະ ສັງເກດເຫັນວ່າແບບຈຳລອງຮອບທີ່ຝຶກສອນໄດ້ດີທີ່ສຸດແມ່ນຢູ່ທີ່ຮອບທີ 70 ເປັນຮອບທີ່ຖືກເລືອກ.



ຮູບທີ 4.5 ສະແດງຄ່າການສູນເສຍຂອງແບບຈຳລອງ ແລະ ຄ່າການກວດສອບການສູນເສຍຂອງແບບຈຳລອງ

ຈາກຮູບທີ 4.5 ທີ່ສະແດງສະແດງຄ່າການສູນເສຍຂອງແບບຈຳລອງ ທີ່ຫຼຸດລົງໃນການຝຶກ

ສອນຄັ້ງທຳອິດ 8.2812 ແລະ ຄັ້ງສຸດທ້າຍແມ່ນຢູ່ທີ່ 0.0535 ແລະ ຄ່າການສູນເສຍການກວດສອບ ໃນຄັ້ງທຳອິດແມ່ນ 7.6465 ແລະ ຄັ້ງທີ່ດີທີ່ສຸດແມ່ນ 0.0391.



ຮູບທີ 4.6 Confusion Matrix ຂອງການຝຶກສອນແບບຈຳລອງ


ຈາກຮູບທີ 4.6 ສະແດງຜົນການຝຶກສອນແບບຈຳລອງເຫັນວ່າ:

- ແຄນ (khean): ຈັດປະເພດຖືກຕ້ອງ 367 ຄັ້ງ, ຜິດພາດ 1 ຄັ້ງ (ສັບສົນກັບ saw)
- ຄ້ອງວົງ (khong_vong): ຈັດປະເພດຖືກຕ້ອງ 291 ຄັ້ງ, ຜິດພາດ 1 ຄັ້ງ (ສັບສົນກັບ unknown)
- ພິນ (pin): ຈັດປະເພດຖືກຕ້ອງ 247 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)
- ລະນາດ (ranad): ຈັດປະເພດຖືກຕ້ອງ 274 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)
- ຊື່ອູ້ (saw): ຈັດປະເພດຖືກຕ້ອງ 283 ຄັ້ງ, ຜິດພາດ 2 ຄັ້ງ (ສັບສົນກັບ unknown)
- ຊິງ (sing): ຈັດປະເພດຖືກຕ້ອງ 321 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)
- ບໍ່ຮູ້ຈັກ (unknown): ຈັດປະເພດຖືກຕ້ອງ 327 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)

ສາມາດຄິດໄລ່ຄວາມຖືກຕ້ອງໂດຍລວມຂອງແບບຈຳລອງ (Accuracy) ແມ່ນ 99.81% ແລະ ພະຍາກອນຜິດ 0.19%.

4.1.3. ລາຍງານການປະເມີນແບບຈຳລອງ

ໃນການປະເມີນແບບຈຳລອງ “ການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍໃຊ້ເຕັກນິກການຮຽນຮູ້ຂັ້ນສູງ” ແມ່ນໄດ້ນຳໃຊ້ຊຸດຂໍ້ມູນທີ່ແບ່ງໄວ້ເພື່ອທົດສອບ 422 ຕົວຢ່າງ ແລະ ສະແດງຜົນການທົດສອບດ້ວຍ Confusion Matrix ເຊິ່ງຜົນທີ່ຮັບໄດ້ດັ່ງນີ້:



ຮູບທີ 4.7 Confusion Matrix ຂອງການທົດສອບແບບຈຳລອງ

ຈາກຮູບທີ 4.7 ການວິເຄາະ Test Set - Confusion Matrix ຂອງແບບຈຳລອງການຈັດປະເພດເຄື່ອງດົນຕີລາວ ແລະ ຜົນການຈັດປະເພດແຕ່ລະເຄື່ອງດົນຕີໃນຊຸດທົດສອບ:

- ແຄນ (khean): ຈັດປະເພດຖືກຕ້ອງ 59 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)
- ຄ້ອງວົງ (khong_vong): ຈັດປະເພດຖືກຕ້ອງ 62 ຄັ້ງ, ຜິດພາດ 1 ຄັ້ງ (ສັບສົນກັບ pin)
- ຟິນ (pin): ຈັດປະເພດຖືກຕ້ອງ 56 ຄັ້ງ, ຜິດພາດ 1 ຄັ້ງ (ສັບສົນກັບ saw)
- ລະນາດ (ranad): ຈັດປະເພດຖືກຕ້ອງ 60 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)
- ຊໍ່ອູ້ (saw): ຈັດປະເພດຖືກຕ້ອງ 60 ຄັ້ງ, ຜິດພາດ 2 ຄັ້ງ (ສັບສົນກັບ unknown)
- ຊິ່ງ (sing): ຈັດປະເພດຖືກຕ້ອງ 59 ຄັ້ງ, ບໍ່ມີຄວາມຜິດພາດ (100% ຄວາມແມ່ນຍຳ)
- ບໍ່ຮູ້ຈັກ (unknown): ຈັດປະເພດຖືກຕ້ອງ 59 ຄັ້ງ, ຜິດພາດ 3 ຄັ້ງ (ສັບສົນກັບ ranad 1 ຄັ້ງ ແລະ saw 2 ຄັ້ງ)

ສາມາດຫາຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງໂດຍລວມ (Accuracy) ໄດ້ແມ່ນ 98.34% ແລະ ພະຍາກອນຜິດແມ່ນ 1.66%.

ຕາຕະລາງທີ 4.1: ຜົນການປະເມີນລະອຽດຂອງແຕ່ລະປະເພດເຄື່ອງດົນຕີຈາກ fold ທີ 1

ເຄື່ອງດົນຕີ	Precision	Recall	F1-Score	Support
ແຄນ (khean)	1.00	1.00	1.00	59
ຄ້ອງວົງ (khong_vong)	0.98	0.98	0.98	63
ຟິນ (pin)	0.98	0.98	0.98	57
ລະນາດ (ranad)	0.98	1.00	0.99	60
ຊໍຮູ້ (saw)	0.95	0.97	0.96	62
ຊິ່ງ (sing)	1.00	1.00	1.00	59
ບໍ່ຮູ້ຈັກ (unknown)	0.97	0.95	0.96	62

ໂດຍລວມແລ້ວ, ການນຳໃຊ້ HPSS ແລະ multi-channel features ໄດ້ຊ່ວຍປັບປຸງການຈຳແນກເຄື່ອງດົນຕີທີ່ມີຄວາມຄ້າຍຄືກັນ (ແຄນ, ຟິນ, ຊໍ) ໄດ້ຢ່າງມີປະສິດທິພາບ.

4.2. ລາຍງານ ແລະ ອະທິບາຍຜົນການສ້າງແອັບພິເຄຊັນ

4.2.1. ລາຍງານຜົນການສ້າງແອັບພິເຄຊັນ

ການພັດທະນາແອັບພິເຄຊັນຈຳແນກເຄື່ອງດົນຕີຟື້ນເມືອງລາວໂດຍໃຊ້ເຕັກນິກ Deep Learning ໄດ້ຜ່ານຂັ້ນຕອນການພັດທະນາຢ່າງເປັນລະບົບ ແລະ ສຳເລັດຜົນຕາມທີ່ຄາດຫວັງ. ແອັບພິເຄຊັນທີ່ພັດທະນາຂຶ້ນມານີ້ສາມາດຈຳແນກເຄື່ອງດົນຕີຟື້ນເມືອງລາວທັງ 6 ປະເພດໄດ້ແກ່: ແຄນ, ຊໍຮູ້, ຊິ່ງ, ຟິນ, ຄ້ອງວົງ ແລະ ລະນາດ ພ້ອມດ້ວຍຄວາມຖືກຕ້ອງສູງ ແລະ ການໃຊ້ງານທີ່ງ່າຍດາຍ.

ຜົນສຳເລັດຂອງການພັດທະນາແອັບພິເຄຊັນ:

1) ດ້ານການພັດທະນາ Mobile Application

ແອັບພິເຄຊັນໄດ້ຖືກພັດທະນາດ້ວຍ Framework Flutter ໂດຍໃຊ້ພາສາ Dart ເຊິ່ງເຮັດໃຫ້ແອັບພິເຄຊັນສາມາດເຮັດວຽກໄດ້ທັງໃນລະບົບ Android ແລະ iOS. ການໃຊ້ Visual Studio Code ເປັນເຄື່ອງມືພັດທະນາຫຼັກໄດ້ຊ່ວຍໃຫ້ການຂຽນໂຄ້ດ ແລະ ການແກ້ໄຂມີປະສິດທິພາບສູງ ດ້ວຍຄຸນສົມບັດ Hot Reload ທີ່ເຮັດໃຫ້ການພັດທະນາເປັນໄປຢ່າງວ່ອງໄວ.

2) ການເຊື່ອມຕໍ່ກັບລະບົບ AI

ແອັບພິເຄຊັນໄດ້ຮັບການພັດທະນາໃຫ້ເຊື່ອມຕໍ່ກັບລະບົບ Backend API ທີ່ພັດທະນາດ້ວຍ FastAPI ແລະ Python ເຊິ່ງເປັນຕົວກາງໃນການຮັບສິ່ງຂໍ້ມູນສຽງ ແລະ ຜົນການວິເຄາະຈາກໂມເດວ Deep

Learning. ການໃຊ້ ໂມເດວ Deep Learning ໄດ້ຊ່ວຍໃຫ້ການປະມວນຜົນ AI ເປັນໄປຢ່າງມີປະສິດທິພາບ.

3) ຄຸນສົມບັດການບັນທຶກ ແລະ ການວິເຄາະສຽງ


ແອັບພິເຄຊັນມີຄວາມສາມາດໃນການບັນທຶກສຽງເປັນເວລາ 8 ວິນາທີຢ່າງຕໍ່ເນື່ອງ ແລະ ສາມາດອັບໂຫຼດໄຟລ໌ສຽງທີ່ມີຢູ່ແລ້ວ. ລະບົບສາມາດປະມວນຜົນໄຟລ໌ສຽງໃນຮູບແບບ WAV ແລະ MP3 ໄດ້ ພ້ອມທັງມີການກຳນົດຂະໜາດສູງສຸດ 10MB ເພື່ອຮັບປະກັນປະສິດທິພາບການເຮັດວຽກ.

4) ການສະແດງຜົນ ແລະ ຂໍ້ມູນວັດທະນະທຳ

ແອັບພິເຄຊັນສາມາດສະແດງຜົນການວິເຄາະໃນຮູບແບບທີ່ເຂົ້າໃຈງ່າຍ ພ້ອມດ້ວຍລະດັບຄວາມໝັ້ນໃຈຂອງການຈຳແນກແຕ່ລະປະເພດ. ນອກຈາກນີ້ ຍັງມີການສະແດງຂໍ້ມູນປະຫວັດ, ຄວາມເປັນມາ, ແລະ ຄວາມສຳຄັນຂອງເຄື່ອງດົນຕີແຕ່ລະຊະນິດ ເຊິ່ງຊ່ວຍສົ່ງເສີມການອະນຸລັກວັດທະນະທຳລາວ.


4.2.2. ອະທິບາຍຜົນການສ້າງແອັບພິເຄຊັນ

1) ໜ້າຫຼັກ (Home Screen)



ຮູບທີ 4.8: ໜ້າຈໍຫຼັກຂອງ Application (Home Screen)

- 1) ຈາກຮູບທີ 4.8 ອະທິບາຍໄດ້ດັ່ງນີ້:
- 2) ສະແດງຫົວຂໍ້ມະຫາວິທະຍາໄລ ຂໍ້ມູນຄະນະ ພ້ອມດ້ວຍໂລໂກ້ຂອງຄະນະ ແລະ ຫົວຂໍ້ໂຄງການຫຼັກ
- 3) ສະແດງຂໍ້ມູນນັກສຶກສາມ ອາຈານທີ່ປຶກສາ ແລະ ອາຈານຜູ້ຊ່ວຍນຳພາ
- 4) ສະແດງລາຍການເຄື່ອງດົນຕີ 6 ປະເພດ - ແຄນ, ຊໍຊູ້, ຊິງ, ຟິນ, ຄ້ອງວົງ, ລະນາດ ພ້ອມສະແດງຮູບພາບ ແລະ ຄຳອະທິບາຍສັ້ນໆ ຂອງແຕ່ລະເຄື່ອງດົນຕີ
- 5) ສະແດງລາຍການລາຍລະອຽດກ່ຽວກັບເຄື່ອງດົນຕີ ຂອງແຕ່ລະເຄື່ອງດົນຕີ




ຮູບທີ 4.9: ໜ້າຈໍການດຳເນີນງານຕ່ວນ ແລະ ການເຊື່ອມຕໍ່

ຈາກຮູບທີ 4.9 ອະທິບາຍໄດ້ດັ່ງນີ້:

- 1) ບັນທຶກ & ຈຳແນກ - ສຳລັບການບັນທຶກສຽງ ແລະ ການຈຳແນກ
- 2) ດາວໂຫລດເອກະສານ - ສາມາດດາວໂຫລດ PDF ແລະ Word
- 3) ມະຫາວິທະຍາໄລແຫ່ງຊາດລາວ - ລິ້ງໄປຫາເວັບໄຊຕ໌ມະຫາວິທະຍາໄລ
- 4) ຄະນະວິທະຍາສາດທຳມະຊາດ - ລິ້ງໄປຫາເວັບໄຊຕ໌ຄະນະ
- 5) Dropdown GitHub Repositories - ເຂົ້າເຖິງໂຄດໂປຣແກຣມ
- 6) GitHub ກ່ຽວກັບ AI ແລະ ການຝຶກ - ຂໍ້ມູນກ່ຽວກັບ Deep Learning
- 7) GitHub Backend API - ການຈັດການລະບົບເຊີເວີ ແລະ API
- 8) GitHub ແອັບພລິເຄຊັນມືຖື - ໂຄດໂປຣແກຣມ Flutter


2) ໜ້າບັນທຶກສຽງເຄື່ອງດົນຕີ (Record Screen)



ຮູບທີ 4.10 ໜ້າຈຳການບັນທຶກສຽງ ແລະ ອັບໂຫລດໄຟລ໌

ຈາກຮູບທີ 4.10 ອະທິບາຍໄດ້ດັ່ງນີ້:

- 1) ແທັບກ່ຽວກັບບັນທຶກ - ປຸ່ມສີແດງ "ບັນທຶກ" ສະແດງໜ້າຈຳກ່ຽວກັບການບັນທຶກສຽງ
- 2) ແທັບກ່ຽວກັບຜົນລັບ- ປຸ່ມ "ຜົນລັບ" ສະແດງໜ້າຈຳກ່ຽວກັບຜົນລັບ
- 3) ຄຳແນະນຳການບັນທຶກ
- 4) ປຸ່ມບັນທຶກ "ແຕະເຜື້ອເລີ່ມບັນທຶກ"
- 5) ຝື່ນທີ່ອັບໂຫລດໄຟລ໌ "ແຕະເຜື້ອເລືອກໄຟລ໌ສຽງ"



ຮູບທີ 4.11: ໜ້າຈຳການວິເຄາະຜົນລັບ (Results Dialog)

ຈາກຮູບທີ 4.11 ອະທິບາຍໄດ້ດັ່ງນີ້:

- 1) Dialog ການວິເຄາະສຳເລັດ - Dialog ໂຕ້ຕອບສະແດງຜົນການຈຳແນກເຄື່ອງດົນຕີທີ່ສຳເລັດ
- 2) ປຸ່ມເບິ່ງລາຍລະອຽດ - ປຸ່ມສຳລັບເຂົ້າເບິ່ງຂໍ້ມູນລະອຽດເຄື່ອງດົນຕີ
- 3) ປຸ່ມຮຽນຮູ້ກ່ຽວກັບເຄື່ອງດົນຕີ


- 4) Confidence Level - ສະແດງລະດັບຄວາມເຊື່ອໝັ້ນຂອງການຈຳແນກ (%)
- 5) Dialog ບໍ່ຮູ້ຈັກ (Unknown) - Dialog ໂຕ້ຕອບເມື່ອ AI ບໍ່ສາມາດຈຳແນກເຄື່ອງດົນຕີໄດ້
- 6) ປຸ່ມ "ລອງອີກຄັ້ງ" ສຳລັບການບັນທຶກໃໝ່



ຮູບທີ 4.12: ໜ້າຈໍຜົນລັບການວິເຄາະທີ່ຍັງບໍ່ມີຂໍ້ມູນ

ຈາກຮູບທີ 4.12 ອະທິບາຍໄດ້ດັ່ງນີ້:

- 1) ສະແດງໜ້າຈໍຜົນລັບທີ່ຍັງບໍ່ມີຂໍ້ມູນ (Empty State)
- 2) ປຸ່ມສີແດງ "ເລີ່ມບັນທຶກ" ສຳລັບໄປຫາໜ້າບັນທຶກສຽງ




ຮູບທີ 4.13: ໜ້າຈໍຜົນລັບການວິເຄາະສຳເລັດ (Successful Analysis Results)

ຈາກຮູບທີ 4.13 ອະທິບາຍໄດ້ດັ່ງນີ້:

1. ຫົວຂໍ້ - "ຜົນການວິເຄາະ AI Analysis Complete" ສະແດງສະຖານະການວິເຄາະສຳເລັດ
2. ສະແດງຮູບພາບເຄື່ອງດົນຕີ

3. ສະແດງຊື່ເຄື່ອງດົນຕີ ທັງລາວ ແລະ ອັງກິດ
4. ຄຳຄວາມໝັ້ນໃຈຂອງເຄື່ອງດົນຕີ
5. Confident Prediction
6. ປຸ່ມຮຽນຮູ້ເພີ່ມເຕີມ - ປຸ່ມສື່ຟາ "ຮຽນຮູ້ເພີ່ມເຕີມ" ກ່ຽວກັບເຄື່ອງດົນຕີ
7. ປຸ່ມລອງບັນທຶກອີກຄັ້ງ - ປຸ່ມສື່ແດງ "ລອງບັນທຶກອີກ" ສຳລັບການບັນທຶກໃໝ່


3) ໜ້າຄູ່ມືການໃຊ້ງານ (Guide Screen)



ຮູບທີ 4.14: Tutorial & Guide - ຄູ່ມືການໃຊ້ງານແອັບ

ຈາກຮູບທີ 4.14 ອະທິບາຍໄດ້ດັ່ງນີ້:

ຮູບນີ້ສະແດງໜ້າຄູ່ມືການໃຊ້ງານທີ່ມີ 4 ຂັ້ນຕອນຄົບຖ້ວນ ແຕ່ລະຂັ້ນຕອນມີສື່ປະຈຳຕົວແຕກຕ່າງກັນ (ຟາ, ແດງ, ສີ່ມ, ຂຽວ) ພ້ອມດ້ວຍໂອກາດທີ່ສື່ຄວາມໝາຍຊັດເຈນ. ມີແຖບຄວາມຄືບໜ້າ (Progress Bar) ສະແດງສະຖານະປັດຈຸບັນ ແລະ ປຸ່ມນຳທາງ "ກ່ອນໜ້າ" ແລະ "ຕັດໄປ" ເພື່ອໃຫ້ຜູ້ໃຊ້ສາມາດເລື່ອນໄປມາລະຫວ່າງຂັ້ນຕອນໄດ້ງ່າຍ. ແຕ່ລະຂັ້ນຕອນຈະອະທິບາຍລາຍລະອຽດການໃຊ້ງານແອັບຕັ້ງແຕ່ການເປີດແອັບ, ການບັນທຶກສຽງ, ການອັບໂຫຼດໄຟລ໌, ຈົນເຖິງການເບິ່ງຜົນການວິເຄາະຈາກ AI.




ຮູບທີ 4.15: ໜ້າຈໍຄູ່ມືລະອຽດ & FAQ - ການແກ້ໄຂບັນຫາ

ຈາກຮູບທີ 4.15 ອະທິບາຍໄດ້ດັ່ງນີ້:

ການອະທິບາຍລວມກ່ຽວກັບໜ້າຈໍຄູ່ມືແລະການແກ້ໄຂບັນຫາ:

ຮູບນີ້ສະແດງໜ້າຈໍຄູ່ມືລະອຽດທີ່ແບ່ງອອກເປັນ 3 ສ່ວນຫຼັກ: ສ່ວນທຳອິດເປັນຄຳແນະນຳການໃຊ້ງານພື້ນຖານລວມທັງການຕັ້ງຄ່າອິນເຕີເນັດ, ການອັບໂຫລດໄຟລ໌, ແລະການຮັບຮູ້ກ່ຽວກັບຄວາມຕ້ອງການ WiFi ຫຼື Mobile Data. ສ່ວນທີສອງເປັນພາກ FAQ (ຖາມຕອບ) ທີ່ມີຄຳຖາມທີ່ພົບເລື້ອຍເຊັ່ນ: ຍ້ອນຫຍັງແອັບບໍ່ເຊື່ອມຕໍ່ໄດ້, ການວິເຄາະໃຊ້ເວລານານ, ຄວາມແມ່ນຍຳຕ່ຳ, ແລະ ບັນຫາການອັບໂຫລດໄຟລ໌. ແຕ່ລະຄຳຖາມມີໄອຄອນສີສັນສົດໃສ ແລະ ການອະທິບາຍວິທີແກ້ໄຂທີ່ລະອຽດ ເຮັດໃຫ້ຜູ້ໃຊ້ສາມາດແກ້ໄຂບັນຫາໄດ້ດ້ວຍຕົນເອງ.

4) ໜ້າຕັ້ງຄ່າ (Settings Screen)



ຮູບທີ 4.16: ໜ້າຈໍການຕັ້ງຄ່າ & ການເລືອກພາສາ (Settings Screen)

ຈາກຮູບທີ 4.16 ອະທິບາຍໄດ້ດັ່ງນີ້:

1. ປຸ່ມປ່ຽນພາສາ ເມື່ອເລືອກການຕັ້ງຄ່າພາສາ ຈະມີໜ້າຈໍ popup ຂຶ້ນມາໃຫ້ເລືອກລະຫວ່າງພາສາອັງກິດ (English) ຫຼື ພາສາລາວ
2. ສະແດງຂໍ້ມູນແອັບເວີຊັນ 1.0.0
3. ສະແດງການຕິດຕໍ່ສໍາລັບການຊ່ວຍເຫຼືອ
4. ການສົ່ງຄໍາຄິດເຫັນຫຼືຂໍສະເໜີແນະ
5. Popup ປ່ຽນພາສາ ແລະ ສະແດງພາສາທີ່ເລືອກໃຊ້ຢູ່ໃນປັດຈຸບັນ.

ບົດທີ 5

ສະຫຼຸບ ແລະ ຂໍ້ສະເໜີ

5.1. ສະຫຼຸບຜົນການຄົ້ນຄວ້າ

ຜ່ານການສ້າງ ແບບຈຳລອງ ແລະ ແອັບພິເຄຊັນຈຳແນກສຽງເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍນຳໃຊ້ ເຕັກນິກຂອງ Deep Learning, ເຮັດໃຫ້ພວກຂ້າພະເຈົ້າໄດ້ຮຽນຮູ້ບົດຮຽນຈາກປະສົບການຕົວຈິງໂດຍ ສະເພາະການເຮັດວຽກເປັນທີມໃນການວາງແຜນດຳເນີນໂຄງການ, ການສຶກສາບັນຫາທີ່ສາມາດແກ້ໄຂໄດ້ ດ້ວຍການນຳເອົາສຽງເຄື່ອງດົນຕີລາວມາປະມວນຜົນເພື່ອພັດທະນາແບບຈຳລອງສຳລັບການຈຳແນກສຽງ ເຄື່ອງລາວດົນຕີທັງ 6 ປະເພດເຊັ່ນ: ແຄນ, ຄ້ອງວົງ, ຂໍອຸ້, ຝິນ, ລະນາດ ແລະ ຊິງ ໂດຍພວກຂ້າພະເຈົ້ານຳໃຊ້ ຫຼັກການຟື້ນຖານຂອງການພັດທະນາແບບຈຳລອງໂດຍນຳໃຊ້ຂະບວນການ CRISP-DM (Cross-industry standard process for data mining) ເປັນມາດຕະຖານການປະມວນຜົນເພື່ອສ້າງແບບຈຳລອງ ໃນຮູບແບບຂອງການຊຸດຄົ້ນຂໍ້ມູນເຊິ່ງ ເຮັດໃຫ້ພວກຂ້າພະເຈົ້າເຂົ້າໃຈຜ່ານການປະຕິບັດຕົວຈິງທີ່ຈະເປັນ ປະໂຫຍດໃນການປະກອບອາຊີບໃນອະນາຄົດ. ຈຸດປະສົງໃນການຄົ້ນຄວ້າຄັ້ງນີ້ແມ່ນເພື່ອສຶກສາຫາວິທີການ ຈຳແນກເຄື່ອງດົນຕີລາວໂດຍການນຳໃຊ້ຂອງເຄື່ອງດົນຕີແຕ່ລະປະເພດ ແລະ ສິ່ງເສີມວັດທະນະທຳຂອງຊາດ ລາວໂດຍການເຜີຍແຜ່ຂໍ້ມູນຂອງປະເພດເຄື່ອງດົນຕີ ແລະ ປະຫວັດຄວາມເປັນມາຜ່ານການນຳໃຊ້ແອັບພິເຄ ຊັນ. ເຊິ່ງໃນການຄົ້ນຄວ້າຄັ້ງນີ້ໄດ້ນຳໃຊ້ຄວາມຮູ້ດ້ານການສະກັດຄຸນລັກສະນະຂອງສຽງແບບ (HPSS & Muilti-Channel Features) ໃຫ້ຢູ່ໃນຮູບແບບທີ່ສາມາດນຳເອົາໄປໃຫ້ຄອມພິວເຕີຮຽນຮູ້ໄດ້ໂດຍສະເພາະ ແມ່ນເຕັກນິກທີ່ນຳໃຊ້ຄື: Convolutional Neural Network (CNN) ເປັນເຕັກນິກໜຶ່ງທີ່ຢູ່ໃນຂະແໜ ງຂອງ Deep Learning ແລະ ພວກຂ້າພະເຈົ້າກໍໄດ້ນຳໃຊ້ຄວາມຮູ້ທາງດ້ານການພັດທະນາແອັບພິເຄຊັນເພື່ອ ນຳເອົາແບບຈຳລອງໄປນຳໃຊ້ໃນແອັບພິເຄຊັນເທິງມືຖື.

ການດຳເນີນໂຄງການຂອງພວກຂ້າພະເຈົ້າປະກອບມີດັ່ງນີ້:

- ໄດ້ເກັບຮວບຮວມຂໍ້ມູນສຽງເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດເຊັ່ນ: ແຄນ, ຄ້ອງວົງ, ຂໍອຸ້, ຝິນ, ລະນາດ ແລະ ຊິງ ແລະ ສຽງລົບກວນອື່ນໆ ເປັນຟາຍ .wav ທີ່ມີຄວາມຍາວສະເລ່ຍ 7 ວິນາທີເຊິ່ງໄດ້ຂໍ້ມູນທັງ 7 class ລວມທັງໝົດແມ່ນ 2,113 ຟາຍ.
- ໄດ້ນຳເອົາຂໍ້ມູນຟາຍສຽງແຕ່ລະຢ່າງໄປກະກຽມຂໍ້ມູນໂດຍຜ່ານການອະນາໄມຂໍ້ມູນ (Data Cleaning) ໃຫ້ຖືກຕ້ອງບໍ່ວ່າຈະເປັນການກັ່ນກອງຟາຍສຽງທີ່ສັ່ນເກີນໄປ, ການຄັດເລືອກຊ່ວງສຽງ ທີ່ດີທີ່ສຸດ, ການກຳນົດຄວາມລະອຽດຂອງສຽງເປັນຕົ້ນ ແລະ ກຳນົດໝວດໝູ່ແກ່ຂໍ້ມູນມີ 7 ໝວດ ໝູ່: khean, khong_vong, ranad, saw, sing, pin, unknown.
- ໄດ້ນຳເອົາຂໍ້ມູນທີ່ຜ່ານການທຳຄວາມສະອາດແລ້ວມາປະມວນຜົນສຽງຂັ້ນຕົ້ນເຊິ່ງເປັນຂັ້ນຕອນໃນ ການແບ່ງຂໍ້ມູນຈາກຟາຍສຽງໄປເປັນຮູບແບບຂອງຂໍ້ມູນທີ່ຄອມພິວເຕີສາມາດເຂົ້າໃຈໄດ້ໂດຍນຳໃຊ້

ເຕັກນິກ (HPSS & Multi-Channel Features) ຈະໄດ້ກາຍເປັນຂໍ້ມູນຕົວຢ່າງທັງໝົດແມ່ນ 2,536 ຕົວຢ່າງ.

- ໄດ້ສ້າງແບບຈຳລອງໂດຍໄດ້ເລືອກເອົາຂັ້ນຕອນວິທີ Convolutional Neural Network (CNN) ໂດຍນຳໃຊ້ອັດຕາສ່ວນ 80-20 (ຊຸດຂໍ້ມູນຝຶກສອນ 80% ແລະ ຊຸດຂໍ້ມູນທົດສອບ 20%) ເຊິ່ງຂໍ້ມູນຕົວຢ່າງທີ່ໃຊ້ຝຶກສອນແມ່ນມີ 2,114 ຕົວຢ່າງລວມມີ ແຄນ 368 ຕົວຢ່າງ, ຄ້ອງວົງ 292 ຕົວຢ່າງ, ຟິນ 247 ຕົວຢ່າງ, ລະນາດ 274 ຕົວຢ່າງ, ຊໍອູ້ 285 ຕົວຢ່າງ, ຊິ່ງ 321 ຕົວຢ່າງ ແລະ ສຽງອື່ນອີກ 327 ຕົວຢ່າງ. ພ້ອມທັງໃຊ້ K-Fold Cross Validation ເພື່ອກວດສອບຄວາມຖືກຕ້ອງຂອງແບບຈຳລອງເຊິ່ງກຳນົດເອົາ K=3 ຜົນຂອງການຝຶກສອນແບບຈຳລອງທັງ 3 ຄັ້ງ ແມ່ນຄັ້ງທີ 1 ເປັນຄັ້ງທີ່ດີທີ່ສຸດມີຄວາມຖືກຕ້ອງ 96.73% ດ້ວຍຄ່າສູນເສຍ 0.0535, ແລະ ຄະແນນຄວາມຖືກຕ້ອງຂອງການກວດສອບຄວາມຖືກຕ້ອງ 99.43% ດ້ວຍຄ່າສູນເສຍ 0.0391.
- ໄດ້ປະເມີນແບບຈຳລອງໂດຍໃຊ້ Confusion Matrix ກັບຈຳນວນຕົວຢ່າງທີ່ແບ່ງໄວ້ພົບວ່າ ຄ້ອງວົງ ຜິດພາດ 1 ຄັ້ງ (ສັບສິນກັບ pin), ຟິນຜິດພາດ 1 ຄັ້ງ (ສັບສິນກັບ saw), ຊໍອູ້ຜິດພາດ 2 ຄັ້ງ (ສັບສິນກັບ unknown), ສຽງທີ່ບໍ່ຮູ້ຈັກ (unknown) ຜິດພາດ 3 ຄັ້ງ (ສັບສິນກັບ ranad 1 ຄັ້ງ ແລະ saw 2 ຄັ້ງ) ງແບບຈຳລອງໂດຍລວມ (Accuracy) ໄດ້ແມ່ນ 98.34% ແລະ ພະຍາກອນຜິດແມ່ນ 1.66%.
- ໄດ້ນຳເອົາແບບຈຳລອງໄປສ້າງແອັບພິເຄຊັນໂດຍນຳໃຊ້ Flutter Framework ເປັນເຄື່ອງມືຫຼັກໃນການພັດທະນາແອັບພິເຄຊັນແບບ Cross-Platform ທີ່ສາມາດເຮັດວຽກໄດ້ທັງລະບົບ Android ແລະ iOS ພ້ອມກັບ Fast API ເປັນ Backend API ສຳລັບການເຊື່ອມຕໍ່ລະຫວ່າງແອັບພິເຄຊັນແບບຈຳລອງ AI.

5.2. ຂໍ້ຈຳກັດຂອງການຄົ້ນຄວ້າ

ຜ່ານການຄົ້ນຄວ້າໃນການສ້າງແບບຈຳລອງ ແລະ ສ້າງແອັບພິເຄຊັນເຖິງມືຖືແມ່ນຍັງພົບຂໍ້ຈຳກັດ, ເຖິງແມ່ນວ່າແບບຈຳລອງຈະມີຄວາມຖືກຕ້ອງທີ່ຂ້ອນຂ້າງສູງຈາກສຸດຂໍ້ມູນໃນການຄົ້ນຄວ້າ ແຕ່ກໍຍັງບໍ່ສາມາດເຮັດໃຫ້ມີຄວາມຖືກຕ້ອງ ກັບສຽງເຄື່ອງດົນຕີທີ່ມີສຽງອື່ນປະສົມ ແລະ ຈັງຫວະສຽງຂອງເຄື່ອງດົນຕີທີ່ໃຊ້ໃນການຫຼິ້ນອາດມີຄວາມຄ້າຍຄືກັນຖ້າວິທີຫຼິ້ນແບບດຽວກັນນອກນັ້ນຍັງມີຂໍ້ຈຳກັດອື່ນໆດັ່ງນີ້:

- ອາດຈະຍັງເຮັດບໍ່ໄດ້ດີໃນການຈຳແນກປະເພດເຄື່ອງດົນຕີທີ່ມີສຽງຄ້າຍຄືກັນເຄື່ອງດົນຕີລາວທັງ 6 ປະເພດ.
- ຂໍ້ມູນທີ່ນຳມາໃຊ້ໃນການຄົ້ນຄວ້າຍັງບໍ່ທັນມີຂໍ້ມູນສຽງທີ່ມີຄວາມຊັບຊ້ອນທາງດ້ານຂອງຈັງຫວະສຽງເຄື່ອງດົນຕີທີ່ຫຼາກຫຼາຍພຽງພໍ.
- ແບບຈຳລອງບໍ່ສາມາດທີ່ຈະຈຳແນກສຽງທີ່ໃຊ້ທົດສອບນັ້ນມີເຄື່ອງດົນຕີທັງ 6 ປະເພດຢູ່ໃນສຽງດຽວກັນແລ້ວຈຳແນກວ່າໃນສຽງທີ່ໃຊ້ທົດສອບນັ້ນມີເຄື່ອງດົນຕີປະເພດໃດແນ່ເພາະແບບຈຳລອງນີ້ຖືກອອກແບບມາເພື່ອແຍກສຽງເຄື່ອງດົນຕີລາວແບບດ່ຽວເທົ່ານັ້ນ.

5.3. ຂໍ້ສະເໜີໃນການຄົ້ນຄວ້າຕໍ່ໄປ

ໃນການສຶກສາ ແລະ ຄົ້ນຄວ້າການສ້າງແບບຈຳລອງການຈຳແນກເຄື່ອງດົນຕີລາວດ້ວຍສຽງໂດຍນຳໃຊ້ ເຕັກນິກ Deep Learning ແມ່ນໄດ້ນຳໃຊ້ການປະມວນຜົນສຽງຫຼາກຫຼາຍຮູບແບບເຊັ່ນ (HPSS & Multi-Channel Features) ເພື່ອໃຫ້ໄດ້ຂໍ້ມູນໄປຝຶກສອນແບບຈຳລອງທີ່ດີທີ່ສຸດ. ສຳລັບລຸ້ນນ້ອງນັກສຶກສາ ຫຼື ຜູ້ທີ່ມີຄວາມສົນໃຈໃນການຄົ້ນຄວ້າ ແລະ ພັດທະນາແບບຈຳລອງຕໍ່ ຫຼື ເປັນແນວທາງໃນການປັບປຸງໃຫ້ດີຂຶ້ນ, ຈຶ່ງມີຂໍ້ສະເໜີແນະນາງານດັ່ງນີ້:

- ເພີ່ມອັດຕາຂອງຂໍ້ມູນສຳລັບການຝຶກສອນແບບຈຳລອງໃຫ້ຫຼາຍຂຶ້ນໂດຍການເພີ່ມຈັງຫວະວິທີການຫຼິ້ນເຄື່ອງດົນຕີແຕ່ລະປະເພດ.
- ເພີ່ມຄວາມຫຼາກຫຼາຍຂອງຂໍ້ມູນສຽງອື່ນໃຫ້ຫຼາຍຂຶ້ນເພື່ອຈັດການກັບບັນຫາ out of distribution ຂອງແບບຈຳລອງ
- ພັດທະນາແບບຈຳລອງການຈຳແນກເຄື່ອງດົນຕີທີ່ບໍ່ແມ່ນແຕ່ຈຳແນກພຽງສຽງເຄື່ອງດົນຕີດ່ຽວຈາກສຽງທີ່ໄດ້ຍົນມາພຽງສຽງດຽວເທົ່ານັ້ນແຕ່ໃຫ້ຈຳແນກວ່າມີສຽງເຄື່ອງດົນຕີໃດແດ່ທີ່ຢູ່ໃນສຽງເພງດັ່ງກ່າວເປັນຕົ້ນ.

ເອກະສານອ້າງອີງ (Reference)

- Author(s). (Year). Title of the article. Journal Name, Volume(Issue), page range.
https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-55462021000200351
- Toghiani-Rizi, B., & Windmark, M. (2017). Musical instrument recognition using their distinctive characteristics in artificial neural networks. *arXiv preprint arXiv:1705.04971*. <https://arxiv.org/abs/1705.04971>
- Han, Y., Kim, J., & Lee, K. (2016). Deep convolutional neural networks for predominant instrument recognition in polyphonic music. *arXiv preprint arXiv:1605.09507*. <https://arxiv.org/abs/1605.09507>
- UNESCO. (n.d.). *Khaen music of the Lao people*. UNESCO Intangible Cultural Heritage. Retrieved January 5, 2025, from <https://ich.unesco.org/en/RL/khaen-music-of-the-lao-people-01296>
- Deep Learning for Audio Classification [Video playlist]. (n.d.). YouTube. https://youtube.com/playlist?list=PLhA3b2k8R3t2Ng1WW_7MiXeh1pfQJQi_P
- Kratimenos, A., Avramidis, K., Garoufis, C., Zlatintsi, A., & Maragos, P. (2019). *Augmentation methods on monophonic audio for instrument classification in polyphonic music*. arXiv preprint arXiv:1911.12505. Retrieved from <https://arxiv.org/pdf/1911.12505>
- AltexSoft Editorial Team. (2021, October 22). *Deep learning: What is it and how does it work?* AltexSoft. <https://www.altexsoft.com/blog/deep-learning/>
- A guide to Mel-frequency cepstral coefficients (MFCCs). (n.d.). Practical Cryptography. Retrieved from <http://practicalcryptography.com/miscellaneous/machine-learning/guide-mel-frequency-cepstral-coefficients-mfccs/>
- Fayek, H. (2016, April 21). *Speech processing for machine learning: Filter banks, Mel-frequency cepstral coefficients (MFCCs) and what's in-between*. Retrieved from <https://haythamfayek.com/2016/04/21/speech-processing-for-machine-learning.html>
- The mathematics of the discrete cosine transform (DCT). (2012, November 3). DataGenetics. Retrieved from <http://datagenetics.com/blog/november32012/index.html>
- Fitzgerald, D. (2010). Harmonic/Percussive Separation Using Median Filtering. *Proceedings of the 13th International Conference on Digital Audio Effects (DAFx-10)*. Retrieved from <https://www.audiolabs-erlangen.de/media/pages/resources/aps->

[w23/papers/7ef50065d9-1663763115/2010_FitzGerald_HarmonicPercussiveSep_DAFx.pdf](https://arxiv.org/abs/1603.01587)

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). *Scikit-learn: Machine learning in Python*. Journal of Machine Learning Research, 12(Oct), 2825–2830. Retrieved from https://scikit-learn.org/stable/modules/cross_validation.html
- Eronen, A., & Klapuri, A. (2000). Musical instrument recognition using cepstral coefficients and temporal features. In Proceedings of the IEEE International Conference on Acoustics, Speech, and Signal Processing (Vol. 2, pp. II753-II756). <https://doi.org/10.1109/ICASSP.2000.859069>
- Eyben, F., Weninger, F., Gross, F., & Schuller, B. (2015). Recent developments in openSMILE, the munich open-source multimedia feature extractor. In Proceedings of the 21st ACM international conference on Multimedia (pp. 835-838). <https://doi.org/10.1145/2502081.2502224>
- Fuhrmann, F., & Herrera, P. (2010). Polyphonic instrument recognition for exploring semantic similarities in music. In Proceedings of the 13th International Conference on Digital Audio Effects (DAFx-10). http://dafx10.iem.at/papers/FuhrmannHerrera_DAFx10_P112.pdf
- Han, Y., Kim, J., & Lee, K. (2017). Deep convolutional neural networks for predominant instrument recognition in polyphonic music. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 25(1), 208-221. <https://doi.org/10.1109/TASLP.2016.2632307>
- Gu, J., Wang, Z., Kuen, J., Ma, L., Shahroudy, A., Shuai, B., Liu, T., Wang, X., Wang, G., Cai, J., & Chen, T. (2018). Recent advances in convolutional neural networks. Pattern Recognition, 77, 354-377. <https://arxiv.org/pdf/1512.07108>
- Khan, A., Sohail, A., Zahoora, U., & Qureshi, A. S. (2020). A survey of the recent architectures of deep convolutional neural networks. Artificial Intelligence Review, 53(8), 5455-5516. <https://journalofbigdata.springeropen.com/articles/10.1186/s40537-021-00444-8>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In Advances in Neural Information Processing Systems (Vol. 25, pp. 1097-1105). <https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks>
- O'Shea, K., & Nash, R. (2015). An Introduction to Convolutional Neural Networks. arXiv preprint arXiv:1511.08458. <https://arxiv.org/abs/1511.08458>

- Piczak, K. J. (2015). Environmental sound classification with convolutional neural networks. In 2015 IEEE 25th International Workshop on Machine Learning for Signal Processing (MLSP) (pp. 1-6). IEEE.
https://www.researchgate.net/publication/308732057_Environmental_sound_classification_with_convolutional_neural_networks
- Sufian, A., Ghosh, A., Sadiq, A. S., & Smarandache, F. (2020). A survey on deep transfer learning to edge computing for mitigating the COVID-19 pandemic. *Journal of Systems Architecture*, 108, 101830.
https://www.researchgate.net/publication/337401161_Fundamental_Concepts_of_Convolutional_Neural_Network
- Vakalopoulou, M., Christodoulidis, S., Burgos, N., Colliot, O., & Lepetit, V. (2023). Deep learning: basics and convolutional neural networks (CNN). ResearchGate.
https://www.researchgate.net/publication/371207468_Deep_learning_basics_and_convolutional_neural_networks_CNN
- Wang, X., Xiao, Z., & Rajasekaran, S. (2021). Environmental sound classification using temporal-frequency attention based convolutional neural network. *Scientific Reports*, 11, 21457. <https://www.nature.com/articles/s41598-021-01045-4>
- Wu, J. (2017). Introduction to Convolutional Neural Networks. National Key Lab for Novel Software Technology, Nanjing University, China.
<https://cs.nju.edu.cn/wujx/paper/CNN.pdf>
- Herrera, P., Amatriain, X., Batlle, E., & Serra, X. (2003). Towards instrument segmentation for music content description: a critical review of instrument classification techniques. In *Proceedings of the International Symposium on Music Information Retrieval (ISMIR)*. https://ismir2000.ismir.net/papers/herrera_abs.pdf
- Li, P., Qian, J., & Wang, T. (2015). Automatic instrument recognition in polyphonic music using convolutional neural networks. arXiv preprint arXiv:1511.05520.
<https://arxiv.org/pdf/1511.05520>
- Lostanlen, V., Andén, J., & Lagrange, M. (2018). Extended playing techniques: the next milestone in musical instrument recognition. In *Proceedings of the 5th International Conference on Digital Libraries for Musicology* (pp. 1-10).
<https://doi.org/10.1145/3273024.3273027>
- McFee, B., Raffel, C., Liang, D., Ellis, D. P., McVicar, M., Battenberg, E., & Nieto, O. (2015). librosa: Audio and music signal analysis in python. In *Proceedings of the 14th python in science conference* (Vol. 8, pp. 18-25).
https://conference.scipy.org/proceedings/scipy2015/pdfs/brian_mcfree.pdf
- Müller, M. (2015). *Fundamentals of Music Processing: Audio, Analysis, Algorithms, Applications*. Springer. <https://doi.org/10.1007/978-3-319-21945-5>

- Pons, J., Lidy, T., & Serra, X. (2017). Experimenting with musically motivated convolutional neural networks. In 2016 14th International Workshop on Content-Based Multimedia Indexing (CBMI) (pp. 1-6). <https://doi.org/10.1109/CBMI.2016.7500246>
- Schedl, M., Gómez, E., & Urbano, J. (2014). Music information retrieval: Recent developments and applications. *Foundations and Trends in Information Retrieval*, 8(2-3), 127-261. <https://doi.org/10.1561/15000000042>
- Siedenburg, K., Fujinaga, I., & McAdams, S. (2016). A comparison of approaches to timbre descriptors in music information retrieval and music psychology. *Journal of New Music Research*, 45(1), 27-41. <https://doi.org/10.1080/09298215.2015.1132737>
- Virtanen, T., Plumbley, M. D., & Ellis, D. (2018). Computational analysis of sound scenes and events. Springer. <https://doi.org/10.1007/978-3-319-63450-0>
- Baumgartner, M., Mitschke, C., & De Bin, R. (2022). A review of cross-validation strategies for evaluating time series forecasting models. *International Journal of Forecasting*, 38(3), 1032-1045. <https://arxiv.org/pdf/2104.00864.pdf>
- Prechelt, L. (1998). Early stopping-but when?. In *Neural Networks: Tricks of the trade* (pp. 55-69). Springer, Berlin, Heidelberg. https://page.mi.fu-berlin.de/prechelt/Biblio/stop_tricks1997.pdf
- Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning* (pp. 448-456). <https://arxiv.org/pdf/1502.03167.pdf>
- Xu, Y., & Goodacre, R. (2018). On splitting training and validation set: A comparative study of cross-validation, bootstrap and systematic sampling for estimating the generalization performance of supervised learning. *Journal of Analysis and Testing*, 2(3), 249-262. <https://link.springer.com/article/10.1007/s41664-018-0068-2>
- ມະນີຣັດ ວັດຕະນະມົງຄົນ. (2013, September 26). ແຄນ – ຂໍ້ມູນທີ່ໜ້າຮູ້. ມະຫາວິທະຍາໄລຮາມຄຳແຫງ. <https://www.lib.ru.ac.th/journal2/?p=3619>
- Wikipedia. (2024, December 13). ຊໍຣູ້. In Wikipedia ສາລານຸກົມເສລີ. Retrieved July 9, 2025, from <https://th.wikipedia.org/wiki/ซอจุ้>
- ກົມສິລະປະກອນ. (n.d.). ເພງປະກອບລະບຳທວາລະວະທິ. ກົມສິລະປະກອນແຫ່ງໄທ. Retrieved July 9, 2025, from <https://www.finearts.go.th/main/view/21014->
- Rajadamnern Stadium. (2025, January 10). Traditional Muay Thai music for rituals and fights. Rajadamnern Stadium. <https://www.rajadamnern.com/blog/muay-thai-music/>

ສຳນັກວິຊາການ ມະຫາວິທະຍາໄລຣາຊະພັດຮ້ອຍເອັດ. (n.d.). ປະເພດເຄື່ອງດົນຕີດິດ – ຝົນ, ຫິນ, ກະຣະຈັບປີ່.

Retrieved July 9, 2025, from <https://www.lib.ru.ac.th/journal/isan/music/index.html>

ຄູ່ຕູ້ຍ. (2017, ກໍລະກົດ 4). ປະຫວັດ ແລະ ສ່ວນປະກອບຂອງຄໍ່ອງວົງໃຫຍ່. ບລັອກດົນຕີບັນເລງເພງໄທ

(Thaimusicbykrutui Blog). Retrieved July 9, 2025, from

<https://thaimusicbykrutui.blogspot.com/2017/07/blog-post.html>

Wikipedia. (2025, ພຶດສະພາ 24). ລະນາດ. In Wikipedia ສາລານຸກົມເສລີ. Retrieved July 9, 2025,

from <https://th.wikipedia.org/wiki/ระนาด>

ປະຫວັດຫຍໍ້ຜູ້ຂຽນ

ປະຫວັດຫຍໍ້ຜູ້ຂຽນ



ຊື່ ແລະ ນາມສະກຸນ: ທ້າວ ເອກທະວິພິນ ທອງເພັດ

ລະຫັດນັກສຶກສາ: 205Q0004/21

ວັນເດືອນປີເກີດ: 14 ຕຸລາ 2003

ບ້ານເກີດ: ບ້ານ ສີສະຫວາດ, ເມືອງ ຈັນທະບູລີ, ນະຄອນຫຼວງວຽງຈັນ.

ບ້ານຢູ່ປັດຈຸບັນ: ບ້ານ ສີວິໄລ, ເມືອງ ໄຊທານີ, ນະຄອນຫຼວງວຽງຈັນ.

ການສຶກສາ: ປີ 2025 ສຳເລັດການສຶກສາລະດັບປະລິນຍາຕີ ສາຂາວິທະຍາສາດຄອມພິວເຕີ, ຄະນະວິທະຍາສາດທຳມະຊາດ, ມະຫາວິທະຍາໄລແຫ່ງຊາດ (ມຊ).

ປີ 2018-2021 ສຳເລັດການສຶກສາ ມັດທະຍົມຕອນປາຍ ທີ່ໂຮງຮຽນປະຖົມ ແລະ ມັດທະຍົມສົມບູນສິນໄຊ.

ປີ 2014-2018 ສຳເລັດການສຶກສາ ມັດທະຍົມຕອນຕົ້ນ ທີ່ໂຮງຮຽນປະຖົມ ແລະ ມັດທະຍົມສົມບູນສິນໄຊ.

ປີ 2009-2014 ສຳເລັດການສຶກສາ ປະຖົມສົມບູນ ທີ່ໂຮງຮຽນປະຖົມ ແລະ ມັດທະຍົມສົມບູນສິນໄຊ.

ເບີໂທ: (+85620) 59179444

Email: Ekthaviphonhthongphet@gmail.com

ປະຫວັດຫຍໍ້ຜູ້ຂຽນ



ຊື່ ແລະ ນາມສະກຸນ: ທ້າວ ສິດທິພອນ ບຸດຕະວົງ

ລະຫັດນັກສຶກສາ: 205N0086/21

ວັນເດືອນປີເກີດ: 21 ພະຈິກ 2001

ບ້ານເກີດ: ບ້ານ ນາແກ, ນະຄອນ ໄກສອນ ຝົມວິຫານ, ສະຫວັນນະເຂດ.

ບ້ານຢູ່ປັດຈຸບັນ: ບ້ານ ນາແກ, ນະຄອນ ໄກສອນ ຝົມວິຫານ, ສະຫວັນນະເຂດ.

ການສຶກສາ: ປີ 2025 ສຳເລັດການສຶກສາລະດັບປະລິນຍາຕີ ສາຂາວິທະຍາສາດຄອມພິວເຕີ, ຄະນະ
ວິທະຍາສາດທຳມະຊາດ, ມະຫາວິທະຍາໄລແຫ່ງຊາດ (ມຊ).
ປີ 2017-2020 ສຳເລັດການສຶກສາ ມັດທະຍົມຕອນປາຍ ທີ່ໂຮງຮຽນມັດທະຍົມສົມບູນ
ສະຫວັນ.
ປີ 2013-2017 ສຳເລັດການສຶກສາ ມັດທະຍົມຕອນຕົ້ນ ທີ່ໂຮງຮຽນມັດທະຍົມຕົ້ນໂພນ
ສະຫວ່າງໃຕ້.
ປີ 2008-2013 ສຳເລັດການສຶກສາ ປະຖົມສົມບູນ ທີ່ໂຮງຮຽນປະຖົມສົມບູນໂພນສະຫວ່າງໃຕ້.

ເບີໂທ: (+85620) 77717904

Email: sitthiphone.pv@gmail.com

ໄລຍະເວລາການດຳເນີນໂຄງການ

ລຳດັບ	ໜ້າວຽກທີ່ດຳເນີນງານ	ເວລາທີ່ໃຊ້	ໄລຍະເວລາ																																			
			2024				2025																															
			ທັນວາ				ມັງກອນ				ກຸມພາ				ມີນາ				ເມສາ				ພຶດສະພາ				ມິຖຸນາ				ກໍລະກົດ				ສິງຫາ			
			1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4				
1	ຈັດຕັ້ງທີມ	1 ອາທິດ																																				
2	ກຳນົດຫົວຂໍ້	1 ອາທິດ																																				
3	ລົງມືຂຽນບົດສະເໜີໂຄງການ	2 ອາທິດ																																				
4	ກຳນົດບັນຫາ ແລະ ຂອບເຂດ	1 ອາທິດ																																				
5	ສົ່ງບົດສະເໜີໂຄງການ	1 ອາທິດ																																				
6	ປ້ອງກັນບົດສະເໜີໂຄງການ	1 ອາທິດ																																				
7	ລົງມືຂຽນບົດຈົບຊັ້ນ	20 ອາທິດ																																				
8	ສຶກສາທິດສະດີທີ່ກ່ຽວຂ້ອງ	15 ອາທິດ																																				
9	ຮວບຮວມ ແລະ ສຶກສາຂໍ້ມູນ	10 ອາທິດ																																				
10	ກະກຽມຂໍ້ມູນ	19 ອາທິດ																																				
11	ສ້າງແບບຈຳລອງຂໍ້ມູນ	8 ອາທິດ																																				
12	ປະເມີນຜົນແບບຈຳລອງ	2 ອາທິດ																																				
13	ນຳໄປໃຊ້ງານ	4 ອາທິດ																																				
14	ອອກແບບໜ້າຕາແອັບພິເຄຊັນ	1 ອາທິດ																																				
15	ລົງມືຂຽນແອັບພິເຄຊັນ	2 ອາທິດ																																				
16	ທົດສອບແອັບພິເຄຊັນ	2 ອາທິດ																																				
17	ແກ້ໄຂຂໍ້ຜິດພາດຂອງແອັບພິເຄຊັນ	4 ອາທິດ																																				
18	ສົ່ງບົດໃຫ້ຜູ້ຊ່ວຍນຳພາ	1 ອາທິດ																																				
19	ກວດແກ້ບົດ	2 ອາທິດ																																				
20	ສ້າງຄູ່ມືນຳໃຊ້ແອັບພິເຄຊັນ	1 ອາທິດ																																				
21	ຊ້ອມປ້ອງກັນບົດ	2 ອາທິດ																																				
22	ປ້ອງກັນບົດ	1 ອາທິດ																																				
23	ແກ້ໄຂບົດ	2 ອາທິດ																																				
24	ສົ່ງບົດສົມບູນ	1 ອາທິດ																																				
25	ລວມເວລາທີ່ໃຊ້		36 ອາທິດ																																			

36 ອາທິດ

